


媒体与认知

Media and Cognition

——一种现代机器学习方法

第3讲 机器学习

Machine learning



清华大学电子系 王生进 李亚利

3.1 机器学习概要

3.2 感知机

3.3 回归方法与线性分类器

3.4 支持向量机SVM

3.4 支持向量机

Support Vector Machine (SVM)

统计学习的一个典型方法

➤ SVM是一种基于统计学习理论的机器学习方法

- ◆ 由Boser, Guyon, Vapnik在1992年国际会议ACM Conference on Computational Learning Theory上发表论文首次提出
- ◆ Vapnik 于1995年出版相关专著 《The Nature of Statistical Learning Theory》



V. Vapnik


➤ 支持向量机SVM的基本原理

支持向量机的核心概念是间隔最大化！

间隔最大化的直观解释：


对训练数据集找到几何间隔最大的超平面，以最大的置信度对训练数据进行分类。即不仅将正负实例分开，而且对难分的样本点（离超平面最近的点）也有足够大的置信度将其分开。这样超平面对未知的新样本似有较好的分类预测能力。

寻找一个置信度最大的分类面



➤ 支持向量机SVM的基本原理


SVM核心是间隔最大化 置信度最大分类面—最安全



统计模式分类回顾：过拟合

► 过拟合(overfitting)与欠拟合(underfitting):



- ◆ 过拟合：训练样本学的“太好”，缺乏对本质的理解，出现泛化性能下降



统计模式分类回顾：欠拟合

➤ 过拟合(overfitting)与欠拟合(underfitting):

- ◆ 欠拟合：训练样本的性质没学好，表现为训练误差大



小样本统计学习方法

➤ 传统方法

- ◆ 传统的统计学研究的主要是渐近理论，即当样本趋向于无穷多时的统计性质。

➤ 支持向量机

- ◆ 小样本条件下的统计学习方法
- ◆ 具备严格的数学理论基础和直观集合解释
- ◆ 处理不均匀、离散、稀疏的数据有明显优势
- ◆ 适用于样本有限情况下的优化求解

线性判别函数


➤ $g(\mathbf{x})$ 为线性判别函数:

$$g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$$

■ 是特征空间中的超平面

■ 超平面的单位法向量:


$$\mathbf{n} = \frac{\mathbf{w}}{\|\mathbf{w}\|}$$



线性判别函数


➤ 如何选择超平面?

存在多个超平面可以将样本分开



线性判别函数

➤ 如何选择超平面?




线性判别函数

➤ 如何选择超平面?

- 哪个最优?
- 如何选择一个最优超平面?

分类超平面1~N




最大间隔线性分类器

■ **问题：** 何为最优分类器？

□ 泛化能力强


■ **目标：**

□ 找到一个超平面，使得其能够尽可能得将两类数据正确的分开，
且分开的两类数据点距离分类界面最远



最大间隔线性分类器

实际上，要解决的问题是，寻找一个最大间隔线性分类器



分布

分类器1

分类器2


最大间隔线性分类器

■ **问题：** 何为最优分类器？

□ 泛化能力强


■ **方案：**

□ 构造约束条件下的优化问题（约束二次优化问题），求解该问题，从而获得最优分类器。




SVM分类问题讨论

➤ 通常有三种：线性可分问题、近似线性可分问题、线性不可分问题。




线性可分问题



近似线性可分问题

非线性分类问题



3.4 支持向量机：线性可分问题

SVM要解决的是——最优分类器设计问题


对于超平面 $\mathbf{w}^T \mathbf{x}_i + b = 0$

➤ 选取训练样本:

$\{(\mathbf{x}_i, y_i)\}, i = 1, 2, \dots, n$, 其中

对于类别 $y_i = +1$, $\mathbf{w}^T \mathbf{x}_i + b > 0$

对于类别 $y_i = -1$, $\mathbf{w}^T \mathbf{x}_i + b < 0$



3.4 支持向量机：线性可分问题


● denotes +1
○ denotes -1

在超平面 $w'x+b=0$ 确定的情况下， $|w'x+b|$ 代表点 x 距离超平面的距离，

当 $w'x+b>0$ 时，表示 x 在超平面的一侧（正类，类标为1），

当 $w'x+b<0$ 时，则表示 x 在超平面的另外一侧（负类，类别为-1），

因此 $y(w'x+b)$ 的正负性恰能表示数据点 x 是否被分类正确。



3.4 支持向量机：线性可分问题

● denotes +1
○ denotes -1

➤ 因此，对所有正确分类点，有：

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) > 0$$


➤ 对最大间隔超平面点，则有：

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) = r$$

■ 通过合理选取 $\mathbf{w}$ 和 b （如两边都除以 r ），上式等价于

对于类别 $y_i = +1$, $\mathbf{w}^T \mathbf{x}_i + b \geq 1$

对于类别 $y_i = -1$, $\mathbf{w}^T \mathbf{x}_i + b \leq -1$



最大间隔线性分类器

➤ 如图所示

$$\mathbf{w}^T \mathbf{x}^+ + b = 1$$

$$\mathbf{w}^T \mathbf{x}^- + b = -1$$


■ 间隔宽度为：

$$M = (\mathbf{x}^+ - \mathbf{x}^-) \cdot \mathbf{n} = (\mathbf{x}^+ - \mathbf{x}^-) \cdot \frac{\mathbf{w}}{\|\mathbf{w}\|}$$

两个向量差在 $\mathbf{n}$ 上的投影

$$= (\mathbf{w}^T \mathbf{x}^+ - \mathbf{w}^T \mathbf{x}^-) \cdot \frac{1}{\|\mathbf{w}\|}$$

$$= (1 - b - (-1 - b)) \cdot \frac{1}{\|\mathbf{w}\|} = \frac{2}{\|\mathbf{w}\|}$$



两个边界上的点分别是 $\mathbf{w}\mathbf{x}+b= +1$ 和 -1 ，相减=2

3.4 支持向量机：线性可分问题


进一步解释：若前页间隔宽度计算没理解，可再看以下推导：

数据中的**支持向量**在影响着最大间隔，那么假设两个支持向量 x_1 和 x_2 分别为正负，最大间隔就应该是 $x_2 - x_1$ 在法向量上的投影：

所以求取 d 的过程为：

$$d = \frac{w^T \cdot (x_+ - x_-)}{\|w\|}$$

$$d = \frac{1 - b - (-1 - b)}{\|w\|} = \frac{2}{\|w\|}$$



最大间隔线性分类器

► 优化目标: 第1步: 定义目标函数

$$\text{maximize } \frac{2}{\|\mathbf{w}\|}$$

◆ 等价于优化:

$$\text{minimize } \frac{1}{2} \|\mathbf{w}\|^2$$

使得

对于类别 $y_i = +1$, $\mathbf{w}^T \mathbf{x}_i + b \geq 1$


对于类别 $y_i = -1$, $\mathbf{w}^T \mathbf{x}_i + b \leq -1$

$$\text{即 } y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$$

第2步: 优化目标函数

此即为: 有线性约束的优化算法求解

● denotes +1
○ denotes -1



更有效的求解方法—定义Lagrange函数

有线性约束的优化问题

$$\text{minimize } \frac{1}{2} \|\mathbf{w}\|^2 \quad \text{s.t.} \quad y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1 \geq 0$$

上式即为支持向量机的基本型

上述问题的Lagrange 函数定义为：

$$L(\mathbf{w}, b, \alpha) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i (y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1) \quad \alpha_i \geq 0$$

乘子符号的正负看约束符号，约束是小于等于0时候是正

更有效的求解方法—原问题等价表达

上述问题的Lagrange 函数定义为：

$$L(\mathbf{w}, b, \alpha) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i (y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1) \quad \alpha_i \geq 0$$

原问题等价于：

$$\underset{\mathbf{w}, b}{\text{minimize}} \left(\underset{\alpha}{\text{maximize}} L(\mathbf{w}, b, \alpha) \right) \quad \alpha_i \geq 0$$

$$\underset{\alpha}{\text{maximize}} L(\mathbf{w}, b, \alpha) = - \sum_{i=1}^n \alpha_i (y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1)$$

分析此处为什么定义为 max

直观理解，由约束条件，此项有负号，最小为 $-\infty$ ，所以应有最大值

更有效的求解方法—Lagrange对偶问题

原问题：

$$\underset{w,b}{\text{minimize}} \left(\underset{\alpha}{\text{maximize}} L(w,b,\alpha) \right) \quad \alpha_i \geq 0$$



Lagrange 对偶问题：可给出原问题的最优解

$$\underset{\alpha}{\text{maximize}} \left(\underset{w,b}{\text{minimize}} L(w,b,\alpha) \right) \quad \alpha_i \geq 0$$

原始问题与对偶问题的关系

定理1：若原始问题和对偶问题都有最优值，则

$$d^* = \max(\min(L(x, \alpha, \beta))) \leq \min(\max(L(x, \alpha, \beta))) = p^*$$

当满足约束条件时 $d^*=p^*$

更有效的求解方法

上述问题的Lagrange 函数定义为：

$$L(\mathbf{w}, b, \alpha) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i (y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1) \quad \alpha_i \geq 0$$

原问题等价于：

$$\underset{\mathbf{w}, b}{\text{minimize}} \left(\underset{\alpha}{\text{maximize}} L(\mathbf{w}, b, \alpha) \right) \quad \alpha_i \geq 0$$

Lagrange 对偶问题：可给出原问题的最优解

$$\underset{\alpha}{\text{maximize}} \left(\underset{\mathbf{w}, b}{\text{minimize}} L(\mathbf{w}, b, \alpha) \right) \quad \alpha_i \geq 0$$

求解过程

拉格朗日对偶

$$\underset{\alpha}{\text{maximize}} \left(\underset{\mathbf{w}, b}{\text{minimize}} L(\mathbf{w}, b, \alpha) \right)$$

$$\underset{\mathbf{w}, b}{\text{minimize}} \quad L(\mathbf{w}, b, \alpha) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i (y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1) \quad \alpha_i \geq 0$$

$$\frac{\partial L}{\partial \mathbf{w}} = 0 \quad \longrightarrow \quad \mathbf{w} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i$$

$$\frac{\partial L}{\partial b} = 0 \quad \longrightarrow \quad \sum_{i=1}^n \alpha_i y_i = 0$$

最优分类面的权系数向量是训练样本向量的线性组合



代入原式中

$$\underset{\mathbf{w}, b}{\text{minimize}} \quad L(\mathbf{w}, b, \alpha) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i (y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1)$$

求解过程

拉格朗日对偶

$$\underset{\alpha}{\text{maximize}} \left(\underset{\mathbf{w}, b}{\text{minimize}} L(\mathbf{w}, b, \alpha) \right)$$

$$\underset{\mathbf{w}, b}{\text{minimize}} \quad L(\mathbf{w}, b, \alpha) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i (y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1) \quad \alpha_i \geq 0$$

$$\mathbf{w} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i \quad \sum_{i=1}^n \alpha_i y_i = 0$$

最优分类面的权系数向量是训练样本向量的线性组合

代入原式中

$$\theta(\alpha) = \min_{\mathbf{w}, b} L(\mathbf{w}, b, \alpha) = \frac{1}{2} \left(\sum_{i=1}^n \alpha_i y_i \mathbf{x}_i \right)^T \left(\sum_{j=1}^n \alpha_j y_j \mathbf{x}_j \right) - \sum_{i=1}^n \alpha_i \left\{ y_i \left[\sum_{j=1}^n \alpha_j y_j \mathbf{x}_j^T \mathbf{x}_i + b \right] - 1 \right\}$$

$$\underset{\alpha}{\text{maximize}} \quad \left(\sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \right)$$

$$\text{且} \quad \alpha_i \geq 0; \quad \sum_{i=1}^n \alpha_i y_i = 0$$

最大间隔线性分类器


$$\min \frac{1}{2} \|\mathbf{w}\|^2 \quad s.t. \quad y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$$



$$\max_{\alpha} \left(\sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \right)$$

$$s.t. \quad \alpha_i \geq 0;$$

$$\sum_{i=1}^n \alpha_i y_i = 0$$



对于上式采用序列最小优化算法（SMO）可得到最优解 α^*

3.4 支持向量机：数值优化算法

序列最小优化算法，其核心思想很简单：每次只优化二个参数，其他参数先固定住，仅求当前这个优化参数的极值。

➤ Sequential Minimal Optimization (SMO) :

- ◆ 由Platt1998年提出，用于解决多变量凸优化问题
- ◆ 依次选取两个坐标维度来进行优化
- ◆ 不失一般性，假设现在选取 α_1 和 α_2 为变量，其余为常量，则根据约束条件有：

$$\sum_{i=1}^n \alpha_i y_i = 0 \Rightarrow \alpha_2 = \frac{1}{y_2} \left(-\sum_{i=3}^n \alpha_i y_i - \alpha_1 y_1 \right) = y_2 (K - \alpha_1 y_1)$$

i 改为从3开始

$$0 \leq \alpha_1 \leq C \quad 0 \leq y_2 (K - \alpha_1 y_1) \leq C$$

因 $y_2 = \pm 1$,
 $y_2 = \frac{1}{y_2}$

其中， C 是惩罚因子，用于近似线性可分的场合，由自己确定

3.4 支持向量机：数值优化算法


- ◆ SMO，选取 α_1 和 α_2 为变量，其余为常量，则由约束条件：

$$\sum_{i=1}^n \alpha_i y_i = 0 \Rightarrow \alpha_2 = \frac{1}{y_2} \left(-\sum_{i=3}^n \alpha_i y_i - \alpha_1 y_1 \right) = y_2 (K - \alpha_1 y_1)$$


$$0 \leq \alpha_1 \leq C \quad 0 \leq y_2 (K - \alpha_1 y_1) \leq C$$

alpha2代入，只有alpha1，其他都是常数，然后求导，得到alpha1

$$\underset{\alpha}{\text{maximize}} \quad \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j$$



最大间隔线性分类器


$$\min \frac{1}{2} \|\mathbf{w}\|^2 \quad \text{s.t. } y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$$

$$\max_{\alpha} \left(\sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \right)$$
$$\text{s.t. } \alpha_i \geq 0, \quad \sum_{i=1}^n \alpha_i y_i = 0$$

KKT条件：优化问题在最优值处，必须满足KKT条件：

② 满足KKT条件

首先，本优化问题显然是一个凸优化问题，


$$\begin{cases} \alpha_i \geq 0 \\ y_i (\mathbf{w}_i \cdot \mathbf{x}_i + b) - 1 \geq 0 \\ \alpha_i (y_i (\mathbf{w}_i \cdot \mathbf{x}_i + b) - 1) = 0 \end{cases}$$



$$\alpha_i \geq 0 \quad \text{来自KKT条件}$$
$$\alpha_i [y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1] = 0$$


↓ X正好是支持向量

$$\alpha_i > 0 \Rightarrow y_i (\mathbf{w}^T \mathbf{x}_i + b) = 1$$



$$\alpha=0, y(w\mathbf{x}+b)-1>0$$

$$L(\mathbf{w}, b, \alpha) = \frac{1}{2} \|\mathbf{w}\|^2$$



$$\alpha > 0, y(w\mathbf{x}+b)-1=0$$

$$L(\mathbf{w}, b, \alpha) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i (y_i(\mathbf{w}^T \mathbf{x}_i + b) - 1)$$

Q8: 思考同时 $\alpha=0$ 与 $y(w\mathbf{x}+b)-1=0$ 如何?

最大间隔线性分类器

KKT条件


$$\begin{cases} \alpha_i \geq 0 \\ y_i (\mathbf{w}_i \cdot \mathbf{x}_i + b) - 1 \geq 0 \\ \alpha_i (y_i (\mathbf{w}_i \cdot \mathbf{x}_i + b) - 1) = 0 \end{cases}$$

$\alpha_i \geq 0$ 来自KKT条件

$$\alpha_i [y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1] = 0$$

$\Downarrow$ $\mathbf{x}$ 正好是支持向量

$$\alpha_i > 0 \Rightarrow y_i (\mathbf{w}^T \mathbf{x}_i + b) = 1$$



一般支持向量仅占训练样本中很少部分，即 α 是稀疏的（大部分 α 取值为0，非支持向量）


最大间隔线性分类器

$$\alpha_i > 0 \Rightarrow y_i(\mathbf{w}^T \mathbf{x}_i + b) = 1$$

$$\mathbf{w} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i \quad \text{前面求出的}$$

$$\mathbf{a}^* \text{ 是最优解} \Rightarrow \mathbf{w}^* = \sum_{i=1}^n \alpha_i^* y_i \mathbf{x}_i$$

表明：最优分类面的权系数向量由支持向量决定，是支持向量的线性组合




最大间隔线性分类器

- denotes +1
- denotes -1

$$\mathbf{a}^* \text{ 是最优解} \Rightarrow \mathbf{w}^* = \sum_{i=1}^n \alpha_i^* y_i \mathbf{x}_i$$

选一个 $\mathbf{x}_j$ 代入 $y_i(\mathbf{w}^* \cdot \mathbf{x}_j + b^*) = 1$

可求得 $b^* = y_i - \sum_{i=1}^n \alpha_i^* y_i (\mathbf{x}_i \cdot \mathbf{x}_j)$



最大间隔线性分类器

$$\min \frac{1}{2} \|\mathbf{w}\|^2 \quad \text{s.t.} \quad y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$$



$$\max_{\alpha} \left(\sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \right) \quad \text{s.t.} \quad \alpha_i \geq 0; \quad \sum_{i=1}^n \alpha_i y_i = 0$$



$$\boldsymbol{\alpha}^* \text{ 是最优解} \Rightarrow \mathbf{w}^* = \sum_{i=1}^n \alpha_i^* y_i \mathbf{x}_i$$

选一个 $\mathbf{x}_j$ 代入 $y_i(\mathbf{w}^* \cdot \mathbf{x}_j + b^*) = 1$

可求得 $b^* = y_i - \sum_{i=1}^n \alpha_i^* y_i (\mathbf{x}_i \cdot \mathbf{x}_j)$

例1：利用线性SVM求解分类问题

$$\omega_1 : \{(1,1)^T, (0,1)^T, (2,0)^T, (0,0)^T\}$$


$$\omega_2 : \{(2,2)^T, (2,3)^T, (0,3)^T\}$$

解答：通过观察法获取支持向量为

$$\omega_1 : (1,1)^T ; \quad \omega_2 : (0,3)^T, (2,2)^T$$

$$\mathbf{w}^T \begin{pmatrix} 1 \\ 1 \end{pmatrix} + b = 1, \mathbf{w}^T \begin{pmatrix} 0 \\ 3 \end{pmatrix} + b = -1, \mathbf{w}^T \begin{pmatrix} 2 \\ 2 \end{pmatrix} + b = -1$$

$$\mathbf{w} = \begin{pmatrix} 2/3 \\ 4/3 \end{pmatrix}, b = -3 \quad (2/3)x_1 + (4/3)x_2 = 3$$



Q8: 思考一下从支持向量系数 α 角度的解法?

3.4 支持向量机：近似线性可分问题

● denotes +1
○ denotes -1

- 噪声和样本异常值的出现等因素，数据有时是近似线性可分的。
- 有特异点(outlier)，个别样本出现在异类区域

- 为每个样本点引入松弛因子 ξ_i


$$y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i$$

$$\xi_i \geq 0$$

- 松弛因子的含义：

使函数间隔加上松弛变量后大于等于1。

容错范围，即容许你错多远




3.4 支持向量机：近似线性可分问题

■ 求解：

$$\text{minimize } \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i$$

$$\text{使得 } y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i$$

$$\xi_i \geq 0$$



3.4 支持向量机：近似线性可分问题

■ 求解：

$$\text{minimize } \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i$$

使得

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i$$
$$\xi_i \geq 0$$

- 引入参数 C 防止过拟合，是一个大于 0 常数，可以理解为错误样本的惩罚程度， C 越大松弛因子就只能越小，容忍度就越小
- 当 C 趋于无穷大时，就是不允许出现分类误差的样本存在，那这就是一个 hard-margin SVM 问题（过拟合）
- 当 C 趋于 0 时，即不再关注分类是否正确，只要求间隔越大越好，那么我们将无法得到有意义的解且算法不会收敛。（欠拟合）

3.4 支持向量机：近似线性可分问题求解方法

- 定义Lagrange函数

$$L(\mathbf{w}, b, \alpha, \gamma) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i - \sum_{i=1}^n \alpha_i (y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1 + \xi_i) - \sum_{i=1}^n \gamma_i \xi_i$$

s.t. $\alpha_i \geq 0 \quad \gamma_i \geq 0$

$$\text{minimize } \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i - \sum_{i=1}^n \alpha_i (y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1 + \xi_i) - \sum_{i=1}^n \gamma_i \xi_i$$

s.t. $\alpha_i \geq 0 \quad \gamma_i \geq 0$

$$\frac{\partial L}{\partial \mathbf{w}} = 0$$



$$\mathbf{w} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i$$

$$\frac{\partial L}{\partial b} = 0$$



$$\sum_{i=1}^n \alpha_i y_i = 0$$

系数有了一个上限

$$\frac{\partial L}{\partial \xi_i} = 0$$



$$C - \alpha_i - \gamma_i = 0$$



$$0 \leq \alpha_i \leq C$$

3.4 支持向量机

线性可分问题

$$\underset{w,b}{\text{minimize}} \quad \frac{1}{2} \|\mathbf{w}\|^2$$

$$\text{s.t.} \quad y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$$

$$\underset{\alpha}{\text{maximize}} \quad \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j$$

$$\text{s.t.} \quad 0 \leq \alpha_i; \quad \sum_{i=1}^n \alpha_i y_i = 0$$

近似线性可分问题

$$\underset{\mathbf{w}, b, \xi}{\text{minimize}} \quad \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i$$





$$\text{s.t.} \quad y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i$$

$$\xi_i \geq 0$$

$$\underset{\alpha}{\text{maximize}} \quad \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j$$

$$\text{s.t.} \quad 0 \leq \alpha_i \leq C; \quad \sum_{i=1}^n \alpha_i y_i = 0$$

3.4 支持向量机：近似线性可分问题




C 与 ξ_i 的关系

C 为错误样本的惩罚程度，若 C 无穷大，松弛必然无穷小，SVM 就又变成线性可分；当 C 为有限值的时候，才能容错

某二分类问题的数据分布如右图所示，试问根据线性SVM对其进行分类，支持向量为（ ）

- ☐ A $(0,1),(1,-1);(0,5),(5,0)$
- ☐ B $(0,1);(0,5)$
- ☐ C $(0,1),(1,-1);(0,5)$
- ☒ D $(0,1);(0,5),(5,0)$




某二分类问题的数据分布如右图所示，试问根据线性SVM对其进行分类，其分类界面为（ ）

A $x+2y=5$

B $x+2y=3$

C $x+y=3$


D $x+y=2$



提交

3.4 支持向量机：非线性问题


■ 线性可分



■ 复杂情况




■ 解决思路:



特征空间至核空间：利用SVM求解非线性问题

- 核函数思想：将样本映射到高维空间使之线性可分



$$\max_{\alpha} \left(\sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \right) \quad \mathbf{x} \rightarrow \varphi(\mathbf{x})$$

$$\mathbf{x}_i^T \mathbf{x}_j \rightarrow \underbrace{\varphi(\mathbf{x}_i)^T}_{\text{映射}} \cdot \varphi(\mathbf{x}_j) = \underbrace{K(\mathbf{x}_i, \mathbf{x}_j)}_{\text{核函数}} = \langle \varphi(\mathbf{x}_i)^T, \varphi(\mathbf{x}_j) \rangle$$

3.4 支持向量机：核函数法(kernel function)

■ 核函数的意义：

提问：映射后，只是做个内积运算，就可以，那为什么要有核函数的呢

原因：低维空间映射到高维空间后维度可能会很大，如果将全部样本的点乘全部计算好，这样的计算量太大

意义：如果找到一个核函数 $k(x, x')$ ，在高维空间的内积，等于在原始样本空间通过函数 $k(x, x')$ 的计算结果，就不需要计算高维甚至无穷维空间的内积了

3.4 支持向量机：核函数法(kernel function)

■ 常用核函数：

□ Linear kernel: $K(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^T \mathbf{x}_j$

□ Polynomial kernel: $K(\mathbf{x}_i, \mathbf{x}_j) = (1 + \mathbf{x}_i^T \mathbf{x}_j)^d$


□ Gaussian (Radial-Basis Function (RBF)) kernel:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma^2}\right)$$

□ Sigmoid:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \tanh\left(\beta_0 \mathbf{x}_i^T \mathbf{x}_j + \beta_1\right)$$

$$y = \tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$



多项式核函数

➤ 假设 $\mathbf{x} = [x_1, x_2, \dots, x_p]^T$, 则其 d 阶多项式定义为

$$C_d(\mathbf{x}) = [z_{j_1}, z_{j_2}, \dots, z_{j_m}]^T, \text{ 其中 } z_j \text{ 为乘积 } x_{k_1} x_{k_2} \cdots x_{k_d} \\ j_m = p^d, (k_1, k_2, \dots, k_d) \in \{1, 2, \dots, p\}$$

◆ 例如: $p = 2, d = 2, \mathbf{x} = [x_1, x_2]^T, C_d(\mathbf{x}) = [x_1^2, x_2^2, x_1 x_2, x_2 x_1]^T$

$$C_d(\mathbf{x}) \cdot C_d(\mathbf{x}') = x_1^2 x_1'^2 + x_2^2 x_2'^2 + x_1 x_2 x_1' x_2' + x_2 x_1 x_2' x_1' = (\mathbf{x} \cdot \mathbf{x}')^2$$

核函数可以简化多项式空间的向量内积计算

➤ 有序单项式空间 即扩充为所有不超过 d 阶的有序单项式

$$\phi_d(\mathbf{x}) = [x_{k_1} x_{k_2} \cdots x_{k_d}, \sqrt{d} x_{k_1} x_{k_2} \cdots x_{k_{d-1}}, \dots, \sqrt{d} x_1, \sqrt{d} x_2, \dots, \sqrt{d} x_n, 1]^T$$

◆ 例如: $p = 2, d = 2, \mathbf{x} = [x_1, x_2]^T \quad \phi_d(\mathbf{x}) = [x_1^2, x_2^2, x_1 x_2, x_2 x_1, \sqrt{2} x_1, \sqrt{2} x_2, 1]^T$

➤ 有序单项式空间核函数 $K_d(\mathbf{x}, \mathbf{x}') = \phi_d(\mathbf{x}) \cdot \phi_d(\mathbf{x}') = (1 + \mathbf{x} \cdot \mathbf{x}')^d$

多项式核函数 $K(\mathbf{x}_i, \mathbf{x}_j) = (1 + \mathbf{x}_i^T \mathbf{x}_j)^d$

➤ 假设 $\mathbf{x} = [x_1, x_2, \dots, x_p]^T$, 则其 d 阶多项式定义为

$$C_d(\mathbf{x}) = [z_{j_1}, z_{j_2}, \dots, z_{j_m}]^T, \text{ 其中 } z_{j_*} \text{ 为乘积 } x_{k_1} x_{k_2} \cdots x_{k_d} \\ j_m = p^d, (k_1, k_2, \dots, k_d) \in \{1, 2, \dots, p\}$$

◆ 例如: $p = 2, d = 2, \mathbf{x} = [x_1, x_2]^T, C_d(\mathbf{x}) = [x_1^2, x_2^2, x_1 x_2, x_2 x_1]^T$

$$j_m = 4, \quad C_2(\mathbf{x}) = [z_1, z_2, z_3, z_4]^T$$

核函数 $C_d(\mathbf{x}) \cdot C_d(\mathbf{x}') = x_1^2 x_1'^2 + x_2^2 x_2'^2 + x_1 x_2 x_1' x_2' + x_2 x_1 x_2' x_1' = (\mathbf{x} \cdot \mathbf{x}')^2$

2阶齐次多项式核函数

以上为有序齐次多项式: 所有的二阶单项式为有序单项式

多项式核函数

$$K(\mathbf{x}_i, \mathbf{x}_j) = (1 + \mathbf{x}_i^T \mathbf{x}_j)^d$$

➤ 有序单项式空间 即扩充为所有不超过d阶的有序单项式

$$\phi_d(\mathbf{x}) = [x_{k_1} x_{k_2} \cdots x_{k_d}, \sqrt{d} x_{k_1} x_{k_2} \cdots x_{k_{d-1}}, \dots, \sqrt{d} x_1, \sqrt{d} x_2, \dots, \sqrt{d} x_n, 1]^T$$

◆ 例如: $p = 2, d = 2, \mathbf{x} = [x_1, x_2]^T$ $\phi_d(\mathbf{x}) = [x_1^2, x_2^2, x_1 x_2, x_2 x_1, \sqrt{2} x_1, \sqrt{2} x_2, 1]^T$

➤ 有序单项式空间核函数 $K_d(\mathbf{x}, \mathbf{x}') = \phi_d(\mathbf{x}) \cdot \phi_d(\mathbf{x}') = (1 + \mathbf{x} \cdot \mathbf{x}')^d$

核函数可以简化多项式空间的向量内积计算

 d阶多项式核函数

3.4 支持向量机：核函数法(kernel function)

最大间隔分类器

- 求解: (Lagrange 对偶问题)

$$\text{maximize} \quad \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j)$$

$$\text{使得} \quad 0 \leq \alpha_i \leq C; \quad \sum_{i=1}^n \alpha_i y_i = 0$$

非线性分类决策函数

$$\mathbf{w}^T \phi(\mathbf{x}) + b = \sum_{i \in SV} y_i \alpha_i K(x_i, x) + b = f(x; \alpha, b)$$


SV是支持向量集合

$$\alpha^* \text{是最优解} \Rightarrow \mathbf{w}^* = \sum_{i=1}^n \alpha_i^* y_i \mathbf{x}_i$$

例2： 利用非线性SVM求解XOR问题

输入向量x	期望输出y
(-1, -1)	-1
(-1, +1)	+1
(+1, -1)	+1
(+1, +1)	-1

试试 $k(x_1, x_2) = (x_1, x_2, (x_1 - x_2)^2)$, 记为 Z , 则 $Z = \{(0, 0, 0), (1, 1, 0), (0, 1, 1), (1, 0, 1)\}$ 。
特征空间是三维的



分类超平面

$$\mathbf{a}^* \text{ 是最优解} \Rightarrow \mathbf{w}^* = \sum_{i=1}^n \alpha_i^* y_i \mathbf{x}_i$$


根据最大间隔分类超平面的定义, $g(\mathbf{x}) = \mathbf{w}^T \varphi(\mathbf{x}) + b$

$\varphi(\mathbf{x}) = [1, x_1^2, \sqrt{2}x_1x_2, x_2^2, \sqrt{2}x_1, \sqrt{2}x_2]^T$ 选择一个映射函数 $k(x_1, x_2) = (1 + x_1^2 + x_2^2)^2$


得到: $g(\mathbf{x}) = -x_1x_2 = 0$ 在核函数空间找到的最佳超平面, 间隔 $\sqrt{2}$

$\sqrt{2}x_1x_2 = \pm 1$ 通过支持向量的超平面, 4个点均为支持向量

输入向量 $\mathbf{x}$	期望输出 y
$(-1, -1)$	-1
$(-1, +1)$	+1
$(+1, -1)$	+1
$(+1, +1)$	-1




原始空间双曲线



56 $\sqrt{2}x_1$
六维空间的二维投影

右图所示二维样本 $x = [x_1, x_2]^T$ 分布，试问下面 () 映射函数产生的一维空间中，样本是线性可分的。


- ☐ A $\varphi(x_1, x_2) = x_1 + x_2$
- ☐ B $\varphi(x_1, x_2) = x_1 x_2$
- ☒ C $\varphi(x_1, x_2) = x_1^2 + \left(\frac{x_2}{2}\right)^2$
- ☐ D $\varphi(x_1, x_2) = x_1^2 + x_2^2 - 2x_1 x_2$




应用：手写数字识别

- **Feature vectors:** each image is 28 x 28 pixels.
Rearrange as a 784-vector x
- **Training:** learn $k=10$ two-class 1-vs-the-rest SVM classifiers $f_k(x)$
- **Classification:** choose class with most positive score


$$f(x) = \max_k f_k(x)$$



应用：基于SVM的手势识别



深度图像 去除背景 检测手部区域




数字1-5手势识别结果；红色为识别错误
识别率 94.7% (142/150)

<http://cv.cs.nthu.edu.tw/upload/undergraduate/9762231/>

应用：行人检测

➤ 基于HOG+SVM的直立行人检测

- ◆ HOG(Histogram of gradients)
- ◆ 边缘梯度方向直方图特征，提取轮廓特征
- ◆ 线性SVM区分行人/背景区域提取Patch



<https://cs.brown.edu/courses/csci1430/2011/lectures/DPM.pdf>

N. Dalal and B. Triggs. Histograms of Oriented Gradients for Human Detection. CVPR 2005

应用：行人检测

➤ 基于HOG+SVM的直立行人检测

- ◆ HOG(Histogram of gradients)
- ◆ 边缘梯度方向直方图特征，提取轮廓特征
- ◆ 线性SVM区分行人/背景区域提取Patch






Figure 6. Our HOG detectors cue mainly on silhouette contours (especially the head, shoulders and feet). The most active blocks are centred on the image background just *outside* the contour. (a) The average gradient image over the training examples. (b) Each “pixel” shows the maximum positive SVM weight in the block centred on the pixel. (c) Likewise for the negative SVM weights. (d) A test image. (e) It’s computed R-HOG descriptor. (f,g) The R-HOG descriptor weighted by respectively the positive and the negative SVM weights.

Matlab中的 SVM工具

```
load fisheriris
data = [meas(:,1), meas(:,2)];
groups = ismember(species,'setosa');
[train, test] = crossvalind('holdOut',groups);
cp = classperf(groups);
svmStruct =
svmtrain(data(train,:),groups(train),'showplot',true);
title(sprintf('Kernel Function: %s',...
             func2str(svmStruct.KernelFunction)),...
       'interpreter','none');
classes =
svmclassify(svmStruct,data(test,:), 'showplot',true);
```



参考文献

- 边肇祺,张学工.模式识别. 清华大学出版社, 2000
- Duda R O, Hart P E, Stork D G. Pattern classification. John Wiley & Sons, 2012.
- Vapnik V.张学工,译.统计学习理论的本质.清华大学出版社, 2000

小结

➤ 机器学习的基本任务

- ◆ 回归：线性回归方法
- ◆ 分类：
 - 两类问题：感知机
 - 多类问题：多层感知机（第3讲）
- ◆ 线性分类器

➤ 支持向量机SVM

- ◆ 最大间隔线性分类器
- ◆ 核函数

讨论与思考


- 机器学习的回归和分类任务有何区别与联系？
- 回归和分类问题的目标函数分别如何定义？

论文阅读任务

► 参考书

- ◆ 周志华,机器学习, 清华大学出版社, 2016年
 - 第三章第3.1-3.2节
- ◆ 李航,统计学习方法, 清华大学出版社, 2012
 - 第二章
- ◆ 动手学深度学习(PyTorch版)
 - 第二章、第三章第3.1-3.7节

<https://tangshusen.me/Dive-into-DL-PyTorch/#/>



上机编程作业

- 利用支持向量机SVM方法进行特征分类。
对提供的三类特征分别进行分类，考察结果
- 上机编程作业，网络学堂提交


谢 谢！

SVM详细解释

<https://zhuanlan.zhihu.com/p/31886934?from=groupmessage>

SVM算法原理

SVM学习的基本想法是求解能够正确划分训练数据集并且几何间隔最大的分离超平面。如下图所示， $w \cdot x + b = 0$ 即为分离超平面，对于线性可分的数据集来说，这样的超平面有无穷多个（即感知机），但是几何间隔最大的分离超平面却是唯一的。



在推导之前，先给出一些定义。假设给定一个特征空间上的训练数据集

$$T = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_N, y_N)\}$$

SVM详细解释

在推导之前，先给出一些定义。假设给定一个特征空间上的训练数据集

$$T = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_N, y_N)\}$$

其中， $\mathbf{x}_i \in \mathbb{R}^n$ ， $y_i \in \{+1, -1\}$ ， $i = 1, 2, \dots, N$ ， $\mathbf{x}_i$ 为第 i 个特征向量， y_i 为类标记，当它等于+1时为正例；为-1时为负例。再假设训练数据集是**线性可分**的。

几何间隔：对于给定的数据集 T 和超平面 $w \cdot x + b = 0$ ，定义超平面关于样本点 (x_i, y_i) 的几何间隔为

$$\gamma_i = y_i \left(\frac{w}{\|w\|} \cdot \mathbf{x}_i + \frac{b}{\|w\|} \right)$$

超平面关于所有样本点的几何间隔的最小值为

$$\gamma = \min_{i=1,2,\dots,N} \gamma_i$$

实际上这个距离就是我们所谓的**支持向量**到超平面的距离。

SVM详细解释

根据以上定义，SVM模型的求解最大分割超平面问题可以表示为以下约束最优化问题

$$\max_{w,b} \gamma$$

$$s.t. \quad y_i \left(\frac{\mathbf{w}}{\|\mathbf{w}\|} \cdot \mathbf{x}_i + \frac{b}{\|\mathbf{w}\|} \right) \geq \gamma, i = 1, 2, \dots, N$$

将约束条件两边同时除以 γ ，得到

$$y_i \left(\frac{\mathbf{w}}{\|\mathbf{w}\|\gamma} \cdot \mathbf{x}_i + \frac{b}{\|\mathbf{w}\|\gamma} \right) \geq 1$$

因为 $\|\mathbf{w}\|$ ， γ 都是标量，所以为了表达式简洁起见，令

$$\mathbf{w} = \frac{\mathbf{w}}{\|\mathbf{w}\|\gamma}$$

$$b = \frac{b}{\|\mathbf{w}\|\gamma}$$

得到

SVM详细解释

得到

$$y_i (\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1, i = 1, 2, \dots, N$$

又因为最大化 γ ，等价于最大化 $\frac{1}{\|\mathbf{w}\|}$ ，也就等价于最小化 $\frac{1}{2} \|\mathbf{w}\|^2$ （ $\frac{1}{2}$ 是为了后面求导以后形式简洁，不影响结果），因此SVM模型的求解最大分割超平面问题又可以表示为以下约束最优化问题

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2$$

$$s. t. \quad y_i (\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1, i = 1, 2, \dots, N$$

这是一个含有不等式约束的凸二次规划问题，可以对其使用拉格朗日乘子法得到其对偶问题（dual problem）。

首先，我们将有约束的原始目标函数转换为无约束的新构造的拉格朗日目标函数

$$L(\mathbf{w}, b, \alpha) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^N \alpha_i (y_i (\mathbf{w} \cdot \mathbf{x}_i + b) - 1)$$

SVM详细解释

$$L(\mathbf{w}, b, \alpha) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^N \alpha_i (y_i (\mathbf{w} \cdot \mathbf{x}_i + b) - 1)$$

其中 α_i 为拉格朗日乘子, 且 $\alpha_i \geq 0$ 。现在我们令

$$\theta(\mathbf{w}) = \max_{\alpha_i \geq 0} L(\mathbf{w}, b, \alpha)$$

当样本点不满足约束条件时, 即在可行解区域外:

$$y_i (\mathbf{w} \cdot \mathbf{x}_i + b) < 1$$

此时, 将 α_i 设置为无穷大, 则 $\theta(\mathbf{w})$ 也为无穷大。

当样本点满足约束条件时, 即在可行解区域内:

$$y_i (\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1$$

此时, $\theta(\mathbf{w})$ 为原函数本身。于是, 将两种情况合并起来就可以得到我们新的目标函数

$$\theta(\mathbf{w}) = \begin{cases} \frac{1}{2} \|\mathbf{w}\|^2, & \mathbf{x} \in \text{可行区域} \\ +\infty, & \mathbf{x} \in \text{不可行区域} \end{cases}$$

于是原约束问题就等价于

SVM详细解释

于是原约束问题就等价于

$$\min_{\mathbf{w}, b} \theta(\mathbf{w}) = \min_{\mathbf{w}, b} \max_{\alpha_i \geq 0} L(\mathbf{w}, b, \alpha) = p^*$$

看一下我们的新目标函数，先求最大值，再求最小值。这样的话，我们首先就要面对带有需要求解的参数 $\mathbf{w}$ 和 b 的方程，而 α_i 又是不等式约束，这个求解过程不好做。所以，我们需要使用拉格朗日函数**对偶性**，将最小和最大的位置交换一下，这样就变成了：

$$\max_{\alpha_i \geq 0} \min_{\mathbf{w}, b} L(\mathbf{w}, b, \alpha) = d^*$$

要有 $p^* = d^*$ ，需要满足两个条件：

① 优化问题是凸优化问题

② 满足KKT条件

首先，本优化问题显然是一个凸优化问题，所以条件一满足，而满足条件二，即要求

$$\begin{cases} \alpha_i \geq 0 \\ y_i (\mathbf{w}_i \cdot \mathbf{x}_i + b) - 1 \geq 0 \\ \alpha_i (y_i (\mathbf{w}_i \cdot \mathbf{x}_i + b) - 1) = 0 \end{cases}$$

SVM详细解释

为了得到求解对偶问题的具体形式, 令 $L(\mathbf{w}, b, \alpha)$ 对 $\mathbf{w}$ 和 b 的偏导为0, 可得

$$\mathbf{w} = \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i$$

$$\sum_{i=1}^N \alpha_i y_i = 0$$

将以上两个等式带入拉格朗日目标函数, 消去 $\mathbf{w}$ 和 b , 得

$$\begin{aligned} L(\mathbf{w}, b, \alpha) &= \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (\mathbf{x}_i \cdot \mathbf{x}_j) - \\ &\sum_{i=1}^N \alpha_i y_i \left(\left(\sum_{j=1}^N \alpha_j y_j \mathbf{x}_j \right) \cdot \mathbf{x}_i + b \right) + \sum_{i=1}^N \alpha_i \\ &= -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (\mathbf{x}_i \cdot \mathbf{x}_j) + \sum_{i=1}^N \alpha_i \end{aligned}$$

即

$$\min_{\mathbf{w}, b} L(\mathbf{w}, b, \alpha) = -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (\mathbf{x}_i \cdot \mathbf{x}_j) + \sum_{i=1}^N \alpha_i$$

求 $\min_{\mathbf{w}, b} L(\mathbf{w}, b, \alpha)$ 对 α 的极大, 即是对偶问题

$$\max_{\alpha} -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (\mathbf{x}_i \cdot \mathbf{x}_j) + \sum_{i=1}^N \alpha_i$$

SVM详细解释

$$s.t. \quad \sum_{i=1}^N \alpha_i y_i = 0$$

$$\alpha_i \geq 0, i = 1, 2, \dots, N$$

把目标式子加一个负号，将求解极大转换为求解极小

$$\min_{\alpha} \quad \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (\mathbf{x}_i \cdot \mathbf{x}_j) - \sum_{i=1}^N \alpha_i$$

$$s.t. \quad \sum_{i=1}^N \alpha_i y_i = 0$$

$$\alpha_i \geq 0, i = 1, 2, \dots, N$$

现在我们的优化问题变成了如上的形式。对于这个问题，我们有更高效的优化算法，即序列最小优化（SMO）算法。这里暂时不展开关于使用SMO算法求解以上优化问题的细节，下一篇文章再加以详细推导。

我们通过这个优化算法能得到 α^* ，再根据 α^* ，我们就可以求解出 w 和 b ，进而求得我们最初的目的：找到超平面，即“决策平面”。

前面的推导都是假设满足KKT条件下成立的，KKT条件如下

$$\begin{cases} \alpha_i \geq 0 \end{cases}$$

SVM详细解释

前面的推导都是假设满足KKT条件下成立的，KKT条件如下

$$\begin{cases} \alpha_i \geq 0 \\ y_i (\mathbf{w}_i \cdot \mathbf{x}_i + b) - 1 \geq 0 \\ \alpha_i (y_i (\mathbf{w}_i \cdot \mathbf{x}_i + b) - 1) = 0 \end{cases}$$

另外，根据前面的推导，还有下面两个式子成立

$$\mathbf{w} = \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i$$

$$\sum_{i=1}^N \alpha_i y_i = 0$$

由此可知在 $\boldsymbol{\alpha}^*$ 中，至少存在一个 $\alpha_j^* > 0$ （反证法可以证明，若全为0，则 $\mathbf{w} = 0$ ，矛盾），对此 j 有

$$y_j (\mathbf{w}^* \cdot \mathbf{x}_j + b^*) - 1 = 0$$

因此可以得到

$$\mathbf{w}^* = \sum_{i=1}^N \alpha_i^* y_i \mathbf{x}_i$$

$$b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (\mathbf{x}_i \cdot \mathbf{x}_j)$$

SVM详细解释

对于任意训练样本 $(\mathbf{x}_i, y_i)$ ，总有 $\alpha_i = 0$ 或者 $y_j (\mathbf{w} \cdot \mathbf{x}_j + b) = 1$ 。若 $\alpha_i = 0$ ，则该样本不会在最后求解模型参数的式子中出现。若 $\alpha_i > 0$ ，则必有 $y_j (\mathbf{w} \cdot \mathbf{x}_j + b) = 1$ ，所对应的样本点位于最大间隔边界上，是一个支持向量。这显示出支持向量机的一个重要性质：**训练完成后，大部分的训练样本都不需要保留，最终模型仅与支持向量有关。**

到这里都是基于训练集数据线性可分的假设下进行的，但是实际情况几乎不存在完全线性可分的数据，为了解决这个问题，引入了“软间隔”的概念，即允许某些点不满足约束

$$y_j (\mathbf{w} \cdot \mathbf{x}_j + b) \geq 1$$

采用hinge损失，将原优化问题改写为

$$\min_{\mathbf{w}, b, \xi_i} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i$$

$$s.t. \quad y_i (\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1 - \xi_i$$

$$\xi_i \geq 0, \quad i = 1, 2, \dots, N$$

其中 ξ_i 为“松弛变量”， $\xi_i = \max(0, 1 - y_i (\mathbf{w} \cdot \mathbf{x}_i + b))$ ，即一个hinge损失函数。每一个样本都有一个对应的松弛变量，表征该样本不满足约束的程度。 $C > 0$ 称为惩罚参数， C 值越大，对分类的惩罚越大。跟线性可分求解的思路一致，同样这里先用拉格朗日乘子法得到拉格朗日函数，再求其对偶问题。

SVM详细解释

综合以上讨论，我们可以得到线性支持向量机学习算法如下：

输入：训练数据集 $T = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_N, y_N)\}$ 其中, $\mathbf{x}_i \in \mathbb{R}^n$, $y_i \in \{+1, -1\}, i = 1, 2, \dots, N$;

输出：分离超平面和分类决策函数

(1) 选择惩罚参数 $C > 0$, 构造并求解凸二次规划问题

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (\mathbf{x}_i \cdot \mathbf{x}_j) - \sum_{i=1}^N \alpha_i$$

$$s.t. \quad \sum_{i=1}^N \alpha_i y_i = 0$$

$$0 \leq \alpha_i \leq C, i = 1, 2, \dots, N$$

得到最优解 $\boldsymbol{\alpha}^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_N^*)^T$

(2) 计算

$$\mathbf{w}^* = \sum_{i=1}^N \alpha_i^* y_i \mathbf{x}_i$$

选择 $\boldsymbol{\alpha}^*$ 的一个分量 α_j^* 满足条件 $0 < \alpha_j^* < C$, 计算

SVM详细解释

$$b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (\mathbf{x}_i \cdot \mathbf{x}_j)$$

(3) 求分离超平面

$$\mathbf{w}^* \cdot \mathbf{x} + b^* = 0$$

分类决策函数:

$$f(\mathbf{x}) = \text{sign}(\mathbf{w}^* \cdot \mathbf{x} + b^*)$$

非线性SVM算法原理

对于输入空间中的非线性分类问题，可以通过非线性变换将它转化为某个维特征空间中的线性分类问题，在高维特征空间中学习线性支持向量机。由于在线性支持向量机学习的对偶问题里，目标函数和分类决策函数都**只涉及实例和实例之间的内积**，所以不需要显式地指定非线性变换，而是用核函数替换当中的内积。核函数表示，通过一个非线性转换后的两个实例间的内积。具体地， $K(\mathbf{x}, \mathbf{z})$ 是一个函数，或正定核，意味着存在一个从输入空间到特征空间的映射 $\phi(\mathbf{x})$ ，对任意输入空间中的 $\mathbf{x}, \mathbf{z}$ ，有

$$K(\mathbf{x}, \mathbf{z}) = \phi(\mathbf{x}) \cdot \phi(\mathbf{z})$$

SVM详细解释

在线性支持向量机学习的对偶问题中，用核函数 $K(x, z)$ 替代内积，求解得到的就是非线性支持向量机

$$f(x) = \text{sign} \left(\sum_{i=1}^N \alpha_i^* y_i K(x, x_i) + b^* \right)$$

综合以上讨论，我们可以得到**非线性支持向量机学习算法**如下：

输入：训练数据集 $T = \{(\mathbf{x}_1, y_1), (\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$ 其中, $\mathbf{x}_i \in \mathbb{R}^n$, $y_i \in \{+1, -1\}, i = 1, 2, \dots, N$;

输出：分离超平面和分类决策函数

(1) 选取适当的核函数 $K(x, z)$ 和惩罚参数 $C > 0$, 构造并求解凸二次规划问题

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j) - \sum_{i=1}^N \alpha_i$$

$$s.t. \quad \sum_{i=1}^N \alpha_i y_i = 0$$

$$0 \leq \alpha_i \leq C, i = 1, 2, \dots, N$$

得到最优解 $\boldsymbol{\alpha}^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_N^*)^T$

SVM详细解释

(2) 计算

选择 α^* 的一个分量 α_j^* 满足条件 $0 < \alpha_j^* < C$, 计算

$$b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i K(x_i, x_j)$$

(3) 分类决策函数:

$$f(x) = \text{sign} \left(\sum_{i=1}^N \alpha_i^* y_i K(x, x_i) + b^* \right)$$

介绍一个常用的核函数——**高斯核函数**

$$K(x, z) = \exp \left(-\frac{\|x-z\|^2}{2\sigma^2} \right)$$

对应的SVM是高斯径向基函数分类器, 在此情况下, 分类决策函数为

$$f(x) = \text{sign} \left(\sum_{i=1}^N \alpha_i^* y_i \exp \left(-\frac{\|x-z\|^2}{2\sigma^2} \right) + b^* \right)$$



统计学习方法 (第2版)

京东

Lagrange 乘数 的原问题可以 等价max的解释

$$\frac{2}{\|w\|} y_i (w^\top x_i + b) \left(\frac{2}{\|w\|} |w^\top x_i + b| \right) \quad (16)$$

描述的优化问题属于
变量, m 项约束.

$$\left] , t := 0, \quad (17)$$

$$= 1, \quad (18)$$

的凸二次规划软件包
过, 通过借助拉格朗
问题, 我们可以将问

式

约束优化问题的重要

证明.

$$\begin{aligned} & \min_{\mathbf{u}} \max_{\alpha, \beta} \mathcal{L}(\mathbf{u}, \alpha, \beta) \\ &= \min_{\mathbf{u}} \left(f(\mathbf{u}) + \max_{\alpha, \beta} \left(\sum_{i=1}^m \alpha_i g_i(\mathbf{u}) + \sum_{j=1}^n \beta_j h_j(\mathbf{u}) \right) \right) \\ &= \min_{\mathbf{u}} \left(f(\mathbf{u}) + \begin{cases} 0 & \text{若 } \mathbf{u} \text{ 满足约束;} \\ \infty & \text{否则} \end{cases} \right) \\ &= \min_{\mathbf{u}} f(\mathbf{u}), \text{ 且 } \mathbf{u} \text{ 满足约束,} \end{aligned} \quad (22)$$

其中, 当 g_i 不满足约束时, 即 $g_i(\mathbf{u}) > 0$, 我们可以取 $\alpha_i = \infty$, 使得 $\alpha_i g_i(\mathbf{u}) = \infty$; 当 h_j 不满足约束时, 即 $h_j(\mathbf{u}) \neq 0$, 我们可以取 $\beta_j = \text{sign}(h_j(\mathbf{u}))\infty$, 使得 $\beta_j h_j(\mathbf{u}) = \infty$. 当 $\mathbf{u}$ 满足约束时, 由于 $\alpha_i \geq 0$, $g_i(\mathbf{u}) \leq 0$, 则 $\alpha_i g_i(\mathbf{u}) \leq 0$. 因此 $\alpha_i g_i(\mathbf{u})$ 最大值为 0.

推论 8 (KKT 条件). 公式 21 描述的优化问题在最优值处必须满足如下条件.

- 主问题可行: $g_i(\mathbf{u}) \leq 0, h_i(\mathbf{u}) = 0$;
- 对偶问题可行: $\alpha_i \geq 0$;
- 互补松弛 (complementary slackness): $\alpha_i g_i(\mathbf{u}) = 0$.

证明. 由引理 7 可知, $\mathbf{u}$ 必须满足约束, 即主问题可行. 对偶问题可行是公式 21 描述的优化问题的约束项, $\alpha_i g_i(\mathbf{u}) = 0$ 是在主问题和对偶问题都可行的条件下的最大值.

■ 核函数定义：

- 设 H 为特征空间，如果存在一个从 X 到 H 的映射：

$$\phi(\mathbf{x}): X \rightarrow H$$

使得对所有 $x, z \in X$ ，函数 $K(x,z)$ 满足条件

$$K(\mathbf{x}, z) = \phi(x) \cdot \phi(z)$$

则称 $K(x,z)$ 为核函数， $\phi(x)$ 为映射函数，式中 $\phi(x) \cdot \phi(z)$ 为 $\phi(x)$ 和 $\phi(z)$ 的内积



设 $\mathcal{H}$ 为特征空间（希尔伯特空间），如果存在一个从 $\mathcal{X}$ 到 $\mathcal{H}$ 的映射

$$\phi(x): \mathcal{X} \rightarrow \mathcal{H} \quad (7.65)$$


使得对所有 $x, z \in \mathcal{X}$ ，函数 $K(x,z)$ 满足条件

$$K(x, z) = \phi(x) \cdot \phi(z) \quad (7.66)$$

则称 $K(x,z)$ 为核函数， $\phi(x)$ 为映射函数，式中 $\phi(x) \cdot \phi(z)$ 为 $\phi(x)$ 和 $\phi(z)$ 的内积。



核函数的概念：即 x_i 和 x_j 在特征空间的内积等于它们在原始样本空间中通过函数 $k(\cdot, \cdot)$ 计算的结果



我来举一个核函数把低维空间映射到高维空间的例子。

下面这张图位于第一、二象限内。我们关注红色的门，以及“[北京四合院](#)”这几个字下面的紫色的字母。我们把红色的门上的点看成是“+”数据，紫色字母上的点看成是“-”数据，它们的横、纵坐标是两个特征。显然，在这个二维空间内，“+”“-”两类数据不是线性可分的。

<https://www.zhihu.com/question/24627666/answer/28440943>

我们现在考虑核函数 $K(v_1, v_2) = \langle v_1, v_2 \rangle^2$ ，即“内积平方”。

这里面 $v_1 = (x_1, y_1)$, $v_2 = (x_2, y_2)$ 是二维空间中的两个点。

这个核函数对应着一个二维空间到三维空间的映射，它的表达式是：


$$P(x, y) = (x^2, \sqrt{2}xy, y^2)$$

可以验证，

$$\begin{aligned} \langle P(v_1), P(v_2) \rangle &= \langle (x_1^2, \sqrt{2}x_1y_1, y_1^2), (x_2^2, \sqrt{2}x_2y_2, y_2^2) \rangle \\ &= x_1^2x_2^2 + 2x_1x_2y_1y_2 + y_1^2y_2^2 \\ &= (x_1x_2 + y_1y_2)^2 \\ &= \langle v_1, v_2 \rangle^2 \\ &= K(v_1, v_2) \end{aligned}$$


在P这个映射下，原来二维空间中的图在三维空间中的像是这个样子：

在P这个映射下，原来二维空间中的图在三维空间中的像是这个样子：



注意到绿色的平面可以完美地分割红色和紫色，也就是说，两类数据在三维空间中变成线性可分的了。

而三维中的这个判决边界，再映射回二维空间中是这样的：



这是一条双曲线，它不是线性的。如上面的例子所说，核函数的作用就是隐含着一个从低维空间到高维空间的映射，而这个映射可以把低维空间中线性不可分的两类点变成线性可分的。