



媒体与认知

Media and Cognition

清华大学电子工程系

王生进 李亚利

Email: liyali13@tsinghua.edu.cn

第7讲 模式识别基础

7.1 基本概念

7.2 特征提取与变换

7.3 贝叶斯决策

7.4 参数估计方法

7.5 模式识别系统


7.1 模式识别

➤ 模式(Pattern)

◆ **模式(认知心理学)**: 由若干元素或成分按一定关系形成的某种刺激结构。

◆ **模式(机器学习)**: 人们在一定条件环境下, 根据一定需要, 对自然事物的一种抽象的分类概念。模式集合记为 $\Omega = \{\omega_1, \omega_2, \dots, \omega_C\}$

视觉模式



不同形状的椅子

听觉模式与触觉模式

听觉模式

风铃声

打字机声

掌声

拍照声音

触觉模式

坚硬/柔软

粗糙/细腻

热/冷

金属/棉布 等

7.1 模式识别

➤ 样本/对象 (sample, object)

- 自然界的具體事物，具有一定的类别特性，是抽象模式的具体体现。
- 样本的观测量记为： $\mathbf{x} = (x_1, x_2, \dots, x_N)^T$

7.1 模式识别

➤ 样本/对象 (sample, object)





7.1 模式识别

➤ 模式识别

◆ 寻求样本观测量与类别属性的联系：


◆ $g(\mathbf{x}) = \omega_i$

$$\mathbf{x} = (x_1, x_2, \dots, x_N)^T$$



7.1 模式识别


➤ 模式识别与计算机视觉任务



7.1 模式识别

➤特征(Feature)


- ◆ **认知心理学**：特征是构成模式的元素或成分，以及关系。
- ◆ **机器学习**：对被识别对象经观察、测量或计算产生的要素。
- ◆ **特征空间**：预处理之后分类识别依赖的数据空间。
- ◆ **两个概念**：特征提取器和模式分类器
- ◆ 特征的类内一致性 (intra-class invariance) 和类间差异性 (inter-class discriminativeness)



基本问题：模式类的紧致性

- 临界点的数量与总的点数相比很少
- 集合内的任意两点的连线，在线上的点属于同一集合
- 集合内的每一个点都有足够大的邻域，在邻域内只包含同一集合的点

分类难度提升，分类错误率增加




(a) 没有临界点

(b) 有较多临界点

(c) 临界点过多

模式识别



第7讲 模式识别基础

7.1 基本概念

7.2 特征提取与变换

7.3 贝叶斯决策

7.4 参数估计方法

7.5 模式识别系统



层次化的特征

➤ 特征具有天然的层次结构


任务领域	原始输入	浅层特征	中层特征	高层特征	训练目标			
语音	样本	频段	声音	音调	音素	单词	语音识别	
图像	像素	线条	纹理	图案	局部	物体	图像识别	
文本	字母	单词	词组	短语	句子	段落	文章	语义理解

视觉系统的分级信息处理

- 从低级的V1区提取边缘特征，再到V2区的形状或者目标的部分等，再到更高层，整个目标、目标的行为等
- 高层的特征是低层特征的组合，从低层到高层的特征表示越来越抽象，越来越能表现语义或者意图



7.2.1 特征提取：深度表征学习




7.2.1 特征提取：深度表征学习

➤ 浅层表示学习与深度学习：

- ◆ 浅层学习的局限性在于有限样本和计算单元情况下对复杂函数的表示能力有限
- ◆ 深层非线性网络结构，实现复杂函数逼近，通常有5~10层的隐层节点；
- ◆ “深度模型”是手段，“特征学习”是目的。

深度学习模型与特征表征




基于深度卷积神经网络的特征表征学习

□ 离散卷积

$$H(x, y) = I * K(x, y) = \sum_m \sum_n I(m, n) K(x - m, y - n)$$


□ 卷积运算(深度学习)

$$z_j^l = \sum_{i \in M_j} x_j^l * w_{ij}^l + b_j^l$$




深度特征可视化—CNN

ZFNet




Layer 1



Zeiler and Fergus, Visualizing and Understanding Convolutional Networks, ECCV 2014

深度特征可视化—CNN


ZFNet



Zeiler and Fergus, Visualizing and Understanding Convolutional Networks, ECCV 2014

深度特征可视化—CNN


ZFNet



Zeiler and Fergus, Visualizing and Understanding Convolutional Networks, ECCV 2014

深度特征可视化—CNN


ZFNet



Zeiler and Fergus, Visualizing and Understanding Convolutional Networks, 2014

深度特征可视化—CNN


ZFNet



Zeiler and Fergus, Visualizing and Understanding Convolutional Networks, ECCV 2014

深度特征可视化—CNN


卷积神经网络的第一层卷积滤波器




AlexNet:
 $64 \times 3 \times 11 \times 11$




ResNet-18:
 $64 \times 3 \times 7 \times 7$



ResNet-101:
 $64 \times 3 \times 7 \times 7$




DenseNet-121:
 $64 \times 3 \times 7 \times 7$



深度特征-语义聚集性

测试图像 通过最近邻(L2)法则检索到的相似图像 - 原始像素



对比
↔

测试图像 通过最近邻(L2)法则检索到的相似图像-fc7特征




Slide credit: CS231n, Stanford University

Krizhevsky et al, "ImageNet Classification with Deep Convolutional Neural Networks", NIPS 2012.

深度特征-语义聚集性


通过特征降维获取的对比可视化

- structure, construction
- covering
- commodity, trade good, good
- conveyance, transport
- invertebrate
- bird
- hunting dog




(b) GIST

传统视觉特征



(c) DeCAF₁

Deep CNN-第一层特征



(d) DeCAF₆

Deep CNN-第六层特征

基于梯度的卷积网络特征可视化



dumbbell




cup



dalmatian



bell pepper




lemon




husky

基于梯度的卷积网络特征可视化



washing machine



computer keyboard




kit fox



goose




ostrich



limousine

基于梯度的卷积网络特征可视化



基于梯度的卷积网络特征可视化



基于梯度的卷积网络特征可视化



基于梯度的卷积网络特征可视化

➤ DeepDream



深度特征可视化—Transformer与注意机制

BERT: Bidirectional Encoder Representation from Transformers


- Transformer architecture
- Unsupervised pre-training

Sentence A: I went to the store.

Sentence B: At the store, I bought fresh strawberries.

The actual input sequence is:


[CLS] i went to the store . [SEP] at the store , i bought fresh straw ##berries . [SEP]



深度特征可视化—Transformer与注意机制

注意系数可视化

- Visualizes attention as lines connecting the position being updated (left) with the position being attended to (right)
- Colors identify the corresponding attention head(s)
- Line thickness reflects the attention score.





<https://github.com/jessevig/bertviz#-paper>

Deconstructing BERT: Distilling 6 Patterns from 100 Million Parameters

<https://towardsdatascience.com/deconstructing-bert-distilling-6-patterns-from-100-million-parameters-b49113672f77>

深度特征可视化—Transformer与注意机制

1) Attention to next word




<https://github.com/jessevig/bertviz#-paper>

Deconstructing BERT: Distilling 6 Patterns from 100 Million Parameters

<https://towardsdatascience.com/deconstructing-bert-distilling-6-patterns-from-100-million-parameters-b49113672f77>

深度特征可视化—Transformer与注意机制

2) Attention to previous word




<https://github.com/jessevig/bertviz#-paper>

Deconstructing BERT: Distilling 6 Patterns from 100 Million Parameters

<https://towardsdatascience.com/deconstructing-bert-distilling-6-patterns-from-100-million-parameters-b49113672f77>

深度特征可视化—Transformer与注意机制

3) Attention to identical/related words




<https://github.com/jessevig/bertviz#-paper>

Deconstructing BERT: Distilling 6 Patterns from 100 Million Parameters

<https://towardsdatascience.com/deconstructing-bert-distilling-6-patterns-from-100-million-parameters-b49113672f77>

深度特征可视化—Transformer与注意机制

4) Attention to identical/related words in other sentence




<https://github.com/jessevig/bertviz#-paper>

Deconstructing BERT: Distilling 6 Patterns from 100 Million Parameters

<https://towardsdatascience.com/deconstructing-bert-distilling-6-patterns-from-100-million-parameters-b49113672f77>

深度特征可视化—Transformer与注意机制

5) Attention to other words predictive of word




<https://github.com/jessevig/bertviz#-paper>

Deconstructing BERT: Distilling 6 Patterns from 100 Million Parameters

<https://towardsdatascience.com/deconstructing-bert-distilling-6-patterns-from-100-million-parameters-b49113672f77>

深度特征可视化—Transformer与注意机制

6) Attention to delimiter tokens




<https://github.com/jessevig/bertviz#-paper>

Deconstructing BERT: Distilling 6 Patterns from 100 Million Parameters

<https://towardsdatascience.com/deconstructing-bert-distilling-6-patterns-from-100-million-parameters-b49113672f77>

深度特征可视化—Transformer与注意机制




<https://github.com/jessevig/bertviz#-paper>

Deconstructing BERT: Distilling 6 Patterns from 100 Million Parameters

<https://towardsdatascience.com/deconstructing-bert-distilling-6-patterns-from-100-million-parameters-b49113672f77>

深度特征可视化—Transformer与注意机制


注意系数可视化



<https://github.com/jessevig/bertviz#-paper>


Deconstructing BERT: Distilling 6 Patterns from 100 Million Parameters

<https://towardsdatascience.com/deconstructing-bert-distilling-6-patterns-from-100-million-parameters-b49113672f77>



深度特征可视化—Transformer与注意机制

注意系数计算 - query/key的内积运算



深度特征可视化—Transformer与注意机制

多头注意机制的注意权重分布-视觉




7.2.2 特征变换：降维

► 机器学习中的维度灾难

- ◆ 在给定精度下，准确地对某维度变量的函数进行估计，所需样本量会随着样本维度的增加而呈指数形式增长；



如果训练集可以达到理论上的无限个，那么就不存在维度灾难，我们可以用无限个维度去得到一个完美的分类器。训练集样本越少，越应该用少量的特征，如果 N 个训练样本足够覆盖一个一维的特征空间（区间大小为一个单位），那么需要 N^2 个样本去覆盖一个同样密度的二维的特征空间，需要 N^3 个样本去覆盖三维的特征空间。换句话说，就是训练样本多少需要随着维度指数增长。



7.2.2 特征变换：降维


➤ 机器学习中的维度灾难

- ◆ 在给定精度下，准确地对某些变量的函数进行估计，所需样本量会随着样本维数的增加而呈**指数**形式增长；
- ◆ **过拟合**：维度增加时，有限的样本空间会越来越稀疏。因此模型出现在训练集上表现良好，但对新数据缺乏泛化能力的现象。




7.2.2 特征变换：降维

➤ 机器学习中的维数灾难 $\implies$ 特征降维




7.2.2 特征变换：降维

➤ 机器学习中的维数灾难 $\implies$ 特征降维




7.2.2 特征变换：降维

➤ 机器学习中的维数灾难 $\Rightarrow$ 特征降维



➤ 特征降维的意义

- 克服维数灾难；
- 获取本质特征；
- 节省存储空间；
- 去除无用噪声；
- 实现数据可视化



7.2.2 特征变换：降维

- 由原始特征产生出对分类识别最有效、数目最少的特征
 - ◆ 同类样本的不变性(Invariant)
 - ◆ 异类样本的鉴别性(Discriminative)
 - ◆ 对噪声的鲁棒性(Robust)
- 特征降维常见方法
 - ◆ 特征选择
 - ◆ 特征变换

Recap: 数学基础

➤ 拉格朗日乘子法

- ◆ 利用拉格朗日乘子法求解有约束条件的优化问题


➤ 矩阵求导方法

➤ 矩阵计算

- ◆ 对称矩阵特征值与特征向量
- ◆ 向量与矩阵的范数


特征变换: 主成分分析

➤ 引子



特征变换: 主成分分析

➤ 引子



特征变换: 主成分分析

➤ 输入: n 个 p 维的样本 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$

➤ 目标: 寻找最优(方差保留)的 k 个投影方向并进行特征变换降维

1. 计算样本点 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ 的均值 μ 和协方差矩阵 Σ
2. 对协方差矩阵 Σ 进行特征值分解
3. 选取 k 个最大特征值对应的特征向量 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k$
4. 将样本点投影到由 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k$ 构成的特征子空间上

$$\mathbf{z} = V^T(\mathbf{x} - \mu), V = [\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k]$$

5. (重建) k 维投影子空间里某向量 $\mathbf{z}$, 可重构原始空间里的向量为


$$\tilde{\mathbf{x}} = V\mathbf{z} + \mu$$

特征变换: 主成分分析

➤ **示例:** 计算PCA投影方向, 并样本特征维数压缩成一维

$$\omega_1: X_1 = [2, 2]^T, X_2 = [2, 3]^T, X_3 = [3, 3]^T$$

$$\omega_2: X_4 = [-2, -2]^T, X_5 = [-2, -3]^T, X_6 = [-3, -3]^T$$



求解: 第一步: 计算协方差矩阵 (此处零均值)

$$E\{XX^T\} = \frac{1}{6} \sum_{j=1}^6 X_j X_j^T = \begin{bmatrix} 5.7 & 6.3 \\ 6.3 & 7.3 \end{bmatrix}$$


第二步: 计算协方差矩阵的特征值, 并根据大小排序。 $\lambda_1=12.85$, $\lambda_2=0.15$ 。

选择 $\lambda_1=12.85$ 所对应的特征向量作为投影向量

$$U = \mathbf{u}_1 = [0.66, 0.75]^T$$

第三步: 利用 U 对样本集中每个样本进行PCA变换。得到:

$$X_1^* = 2.82, X_2^* = 3.57, X_3^* = 4.23 \\ X_4^* = -2.82, X_5^* = -3.57, X_6^* = -4.23$$




应用案例：基于PCA变换的人脸识别

给定训练图像 $T_i, i = 1, 2, \dots, N$ ，要求对图像集做主成分分析

1. 均值为 $m = \sum_{i=1}^N T_i$ ，对图像集去均值得到 $X_i = T_i - m$ ，计算协方差矩阵 $E_{xx'}$
2. 计算 $E_{xx'}$ 的特征值和特征向量，并选取最大的s个特征值的所对应的特征向量作为子空间的基
3. 对图像集做PCA变换

特征脸(Eigen Faces)

子空间的7个基
(特征人脸)




$$\text{Input Face} = 0.9569 \times \text{1st} - 0.1945 \times \text{2nd} + 0.0461 \times \text{3rd} + 0.0573 \times \text{4th} - \dots$$

某一幅人脸图像做PCA变换



新坐标系下的坐标: $x' = [0.9569, -0.1945, 0.0461, 0.0573, \dots]$

应用案例：基于PCA变换的人脸识别

Faces




EigenFaces



应用案例：基于PCA变换的人脸识别

➤ PCA人脸重构

Reconstruction

$$\mathbf{x} = y_1 \mathbf{w}_1 + y_2 \mathbf{w}_2 + \dots + y_k \mathbf{w}_k$$


重构结果示意：
每次增加8个维度




特征变换: 主成分分析

➤ 主成分分析的几何意义:

- ◆ 样本 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ 在 p 维空间上形成一个 p 维椭球状云团
- ◆ 散度矩阵/协方差矩阵的特征向量即为椭球状云团的主轴

- ◆ 主成分分析提取云团散度最大的主轴方向进行特征降维




- ◆ 问题: 散度最大不一定最利于区分样本类别。

PCA的优缺点分析

- 采用样本协方差矩阵的特征向量作为变换的基向量，与样本的统计特性完全匹配
 - ◆ 在最小均方误差准则下，是最佳变换。
- 数据分布的最优表示空间 == 最优分类空间？
 - ◆ 利用类别信息选择投影空间 => 更好的分类效果？
 - 最大化类间距离
 - 最小化类内距离

举例：印刷体字符识别
区分Q和O



变换矩阵随样本数据而异，无快速算法

特征变换：降维

➤ t-SNE (Maaten & Hinton, 2008)

◆ t-distributed stochastic neighbor embedding

- ◆ 高维空间：以数据点在 x_i 为中心的高斯分布中所占概率密度为标准选择近邻

$$p_{j|i} = \frac{\exp(-\|x_i - x_j\|/2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|x_i - x_k\|/2\sigma_i^2)}$$
$$p_{ij} = (p_{i|j} + p_{j|i})/2N$$

- ◆ 低维空间：以t分布替代高斯分布表达距离

$$q_{ij} = \frac{\left(1 + \|y_i - y_j\|^2\right)^{-1}}{\sum_{k \neq l} \left(1 + \|y_k - y_l\|^2\right)^{-1}}$$

特征变换：降维

➤ t-SNE (Maaten & Hinton, 2008)

◆ t-distributed stochastic neighbor embedding

- ◆ 优化目标：高维空间和低维空间的概率分布之间距离——KL散度 (Kullback-Leibler divergences)

$$C = \sum_i KL(P_i \| Q_i) = \sum_i \sum_j p_{ij} \log \frac{p_{ij}}{q_{ij}}$$





- ◆ 推导 C 对于 y_i 的梯度ⁱ为

$$\frac{\partial C}{\partial y_i} = 4 \sum_j (p_{ij} - q_{ij}) (y_i - y_j) \left(1 + \|y_i - y_j\|^2 \right)^{-1}$$

- ◆ 利用梯度下降求解 x_i 的低维映射 y_i



特征变换：降维

➤ t-SNE 可视化



特征变换：降维

深度学习特征--可视化



第7讲 模式识别基础

7.1 基本概念

7.2 特征提取与变换

7.3 贝叶斯决策

7.4 参数估计方法

7.5 模式识别系统

7.3 贝叶斯决策：数学基础

➤ 条件概率和联合概率：

- ◆ 假设A和B是一个样本空间中的两个事件，在假定B发生的条件下，A发生的条件概率为

$$P(A|B) = \frac{P(A, B)}{P(B)}$$

- ◆ 事件A和事件B的联合概率为

$$P(A, B) = P(A|B)P(B) = P(B|A)P(A)$$



7.3 贝叶斯决策：数学基础

► 贝叶斯定理：

全事件空间

- ◆ 假设 A_1 和 A_2 是互斥的两个事件，且 $A_1 \cup A_2 = S$ ，事件 B 发生的概率（边际概率）为

$$P(B) = P(B|A_1)P(A_1) + P(B|A_2)P(A_2)$$

- ◆ 两事件的贝叶斯定理为：

$$P(A_i|B) = \frac{P(A_i)P(B|A_i)}{P(A_1)P(B|A_1) + P(A_2)P(B|A_2)}, i = 1, 2$$

- ◆ n 事件的贝叶斯定理为：

$$P(A_i|B) = \frac{P(A_i)P(B|A_i)}{P(A_1)P(B|A_1) + P(A_2)P(B|A_2) + \dots + P(A_n)P(B|A_n)}, i = 1, 2, \dots, n$$



7.3 贝叶斯决策：数学基础

➤ 贝叶斯定理：

◆ 两事件的贝叶斯定理为：

$$P(A_i|B) = \frac{P(A_i)P(B|A_i)}{P(B)}, i=1,2$$

◆ 模式识别中的贝叶斯定理表示：

$$P(\omega_i|x) = \frac{P(\omega_i)P(x|\omega_i)}{P(x)}, i=1,2$$

通过观测 x 将先验概率 $P(\omega_i)$ 转化为后验概率 $P(\omega_i|x)$

后验概率 先验概率 似然度

$\text{posterior} = \frac{\text{prior} \times \text{likelihood}}{\text{evidence}}$

7.3 贝叶斯决策：数学基础

➤ 示例：

- ◆ 假设某种病毒检测方法，感染者检测阳性率为80%，未感染者的检测阳性率为5%；在某高风险地区参加检测的人群中有2%是真实病人；假设某人检测结果为阳性，试问这个人感染病毒的概率是多少？

$$P(\omega_i | x) = \frac{P(\omega_i)P(x|\omega_i)}{P(x)}, i = 1, 2$$

7.3 贝叶斯决策：数学基础

► 示例：

- ◆ 假设某种病毒检测方法，感染者检测阳性率为80%，未感染者的检测阳性率为5%；在某高风险地区参加检测的人群中有2%是真实病人；假设某人检测结果为阳性，试问这个人感染病毒的概率是多少？
- ◆ 解答：记 ω_1 为感染者， ω_2 为未感染者，则可获取先验概率

$$P(\omega_1) = 0.02, P(\omega_2) = 0.98$$

记 x 是病毒检测阳性，则

$$P(x|\omega_1) = 0.8, P(x|\omega_2) = 0.05$$

代入得

$$P(\omega_1|x) = \frac{P(\omega_1)P(x|\omega_1)}{P(\omega_1)P(x|\omega_1) + P(\omega_2)P(x|\omega_2)} = \frac{0.02 \times 0.8}{0.02 \times 0.8 + 0.98 \times 0.05} = 0.246$$

7.3 贝叶斯决策：数学基础

➤ 示例：

- ◆ 假设某疫苗接种方法有四种可能状态 $\{0,1,2,3\}$ ，感染者疫苗对应接种比例为 $\{0.4,0.3,0.2,0.1\}$ ，未感染者对应接种比例为 $\{0.1,0.2,0.3,0.4\}$ ；在某疫情高风险地区参加检测的人群中有30%是真实感染者；试根据某个体疫苗接种情况预测感染病毒的概率？

$$P(\omega_i|x) = \frac{P(\omega_i)P(x|\omega_i)}{P(x)}, i = 1, 2$$

7.3 贝叶斯决策：数学基础

► 示例：

- ◆ 假设某疫苗接种方法有四种可能状态 $\{0,1,2,3\}$ ，感染者疫苗对应接种比例为 $\{0.4,0.3,0.2,0.1\}$ ，未感染者对应接种比例为 $\{0.1,0.2,0.3,0.4\}$ ；在某疫情高风险地区参加检测的人群中有30%是真实感染者；试根据某个体疫苗接种情况预测感染病毒的概率？
- ◆ 解答：记 ω_1 为感染者， ω_2 为未感染者，则可获取先验概率

$$P(\omega_1) = 0.30, P(\omega_2) = 0.70$$

记 $x \in \{0,1,2,3\}$ 是疫苗接种情况，则

$$P(x = 0|\omega_1) = 0.4, P(x = 0|\omega_2) = 0.1$$

$$P(x = 1|\omega_1) = 0.3, P(x = 1|\omega_2) = 0.2$$

$$P(x = 2|\omega_1) = 0.2, P(x = 2|\omega_2) = 0.3$$

$$P(x = 3|\omega_1) = 0.1, P(x = 3|\omega_2) = 0.4$$

7.3 贝叶斯决策：数学基础

► 示例：

- ◆ 假设某疫苗接种方法有四种可能状态 $\{0,1,2,3\}$ ，感染者疫苗对应接种比例为 $\{0.4,0.3,0.2,0.1\}$ ，未感染者对应接种比例为 $\{0.1,0.2,0.3,0.4\}$ ；在某疫情高风险地区参加检测的人群中有30%是真实感染者；试根据某个体疫苗接种情况预测感染病毒的概率？

- ◆ 解答：

$$P(\omega_1|x=0) = \frac{P(\omega_1)P(x=0|\omega_1)}{P(\omega_1)P(x=0|\omega_1) + P(\omega_2)P(x=0|\omega_2)}$$

$$\text{计算得 } P(\omega_1|x=0) = \frac{0.30 \times 0.4}{0.30 \times 0.4 + 0.70 \times 0.1} = 0.631$$

类似的，可获取

$$P(\omega_1|x=1) = 0.391, \quad P(\omega_1|x=2) = 0.222, \quad P(\omega_1|x=3) = 0.097$$

7.3 贝叶斯决策：数学基础

► 示例：

- ◆ 假设某疫苗接种方法有四种可能状态 $\{0,1,2,3\}$ ，感染者疫苗对应接种比例为 $\{0.4,0.3,0.2,0.1\}$ ，未感染者对应接种比例为 $\{0.1,0.2,0.3,0.4\}$ ；在某疫情高风险地区参加检测的人群中有30%是真实感染者；试根据某个体疫苗接种情况给出最小分类错误率的病毒感染判别方法？

- ◆ 解答：

$$P(\omega_1|x=0) = 0.631, P(\omega_2|x=0) = 1 - 0.631$$

$$P(\omega_1|x=1) = 0.391, P(\omega_2|x=1) = 1 - 0.391$$

$$P(\omega_1|x=2) = 0.222, P(\omega_2|x=2) = 1 - 0.222$$


$$P(\omega_1|x=3) = 0.097, P(\omega_2|x=3) = 1 - 0.097$$

7.3 贝叶斯决策：数学基础

► 示例：

- ◆ 假设某病毒感染的观测特征为 x 为连续随机变量，感染者和未感染者的观测分布已知，分别记为 $P(x|\omega_1)$ 和 $P(x|\omega_2)$ ；在某疫情高风险地区参加检测的人群中有2%是真实病人；试根据某个体观测特征 x 判断其是否感染的情况？

$$P(\omega_i | x) = \frac{P(\omega_i) P(x | \omega_i)}{P(x)}, i = 1, 2$$



7.3 贝叶斯决策：数学基础

► 示例：


- ◆ 假设某病毒感染的观测特征为 x 为连续随机变量，感染者和未感染者的观测分布已知，分别记为 $P(x|\omega_1)$ 和 $P(x|\omega_2)$ ；在某疫情高风险地区感染几率已知，记为 $P(\omega_1)$ 和 $P(\omega_2)$ ，且 $P(\omega_1) + P(\omega_2) = 1$ ；**试根据某个体观测特征 x 给出最小化错误率的感染情况判别函数。**

$$P(\omega_i | x) = \frac{P(\omega_i) P(x | \omega_i)}{P(x)}, i = 1, 2$$

7.3 贝叶斯决策：数学基础

➤ 高斯(正态)分布：

$$p(\mathbf{x} | \omega_i) = \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma_i|^{\frac{1}{2}}} \exp\left\{-\frac{1}{2}(\mathbf{x} - \mu_i)^T \Sigma_i^{-1}(\mathbf{x} - \mu_i)\right\}$$




Q2: why
Gaussian?

7.3 贝叶斯决策

► 贝叶斯决策

- ◆ 概率框架下实施决策的基本方法
- ◆ 贝叶斯决策：在所有相关概率已知的条件下，考虑如何利用已知概率，以最小化**误判损失函数**为目标来选取最优的类别标记



7.3 贝叶斯决策

➤ 正态分布条件下的贝叶斯决策

- ◆ 假设类条件概率密度函数为正态分布

$$p(\mathbf{x} | \omega_i) = \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma_i|^{\frac{1}{2}}} \exp\left\{-\frac{1}{2}(\mathbf{x} - \mu_i)^T \Sigma_i^{-1}(\mathbf{x} - \mu_i)\right\}$$

- ◆ 判别函数定义为:

$$G_i(\mathbf{x}) = p(\mathbf{x} | \omega_i) p(\omega_i) = \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma_i|^{\frac{1}{2}}} \exp\left\{-\frac{1}{2}(\mathbf{x} - \mu_i)^T \Sigma_i^{-1}(\mathbf{x} - \mu_i)\right\} \cdot p(\omega_i)$$

- ◆ 取对数后判别函数为:

$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \mu_i)^T \Sigma_i^{-1}(\mathbf{x} - \mu_i) - \frac{d}{2} \ln(2\pi) - \frac{1}{2} \ln |\Sigma_i| + \ln p(\omega_i)$$

7.3 贝叶斯决策

► 误分类 $P(error|x) = \begin{cases} P(\omega_1|x) & \text{判定为 } \omega_2 \\ P(\omega_2|x) & \text{判定为 } \omega_1 \end{cases}$

► 平均误差概率

$$P(error) = \int_{-\infty}^{\infty} P(error, x) dx = \int_{-\infty}^{\infty} P(error|x)P(x) dx$$




$$\begin{cases} P(\omega_1|x) > P(\omega_2|x) & \text{判定为 } \omega_1 \\ P(\omega_1|x) < P(\omega_2|x) & \text{判定为 } \omega_2 \end{cases}$$

$$P(error|x) = \min \{ P(\omega_1|x), P(\omega_2|x) \}$$



$$\begin{cases} P(x|\omega_1)P(\omega_1) > P(x|\omega_2)P(\omega_2) & \text{判定为 } \omega_1 \\ P(x|\omega_1)P(\omega_1) < P(x|\omega_2)P(\omega_2) & \text{判定为 } \omega_2 \end{cases}$$



贝叶斯决策函数一般形式

$$G_i(x) = p(x|\omega_i)p(\omega_i)$$

7.3 贝叶斯决策




FIGURE 2.6. In this two-dimensional two-category classifier, the probability densities are Gaussian, the decision boundary consists of two hyperbolas, and thus the decision region $\mathcal{R}_2$ is not simply connected. The ellipses mark where the density is $1/e$ times that at the peak of the distribution. From: Richard O. Duda, Peter E. Hart, and David G. Stork, *Pattern Classification*. Copyright © 2001 by John Wiley & Sons, Inc.

7.3 贝叶斯决策

➤ 正态分布条件下的贝叶斯决策

假设各类先验概率相等，协方差矩阵的三种情况



(1) $\Sigma_i = \sigma^2 I$ 最小欧氏距离分类器

(2) $\Sigma_i = \Sigma$ 最小马氏距离分类器

马氏距离 Mahalanobis distance

$$d^2 = (x - \mu_i)^T \Sigma_i^{-1} (x - \mu_i)$$

(3) $\Sigma_i \neq \Sigma_j \quad i \neq j$, 二次判别函数



7.3 贝叶斯决策

➤ 正态分布条件下的贝叶斯决策




◆ 情况1: $\Sigma_i = \sigma^2 I$

$$g_i(x) = -\frac{1}{2}(x - \mu_i)^T \Sigma_i^{-1}(x - \mu_i) - \frac{d}{2} \ln(2\pi) - \frac{1}{2} \ln |\Sigma_i| + \ln p(\omega_i)$$









$$g_i(x) = -\frac{\|x - \mu_i\|^2}{2\sigma^2} + \ln p(\omega_i)$$

d维球状分布，判决超平面垂直于连接两类中心的连线。



7.3 贝叶斯决策



$P(\omega_i)$ 先验概率对
分类超平面的影响

7.3 贝叶斯决策

➤ 正态分布条件下的贝叶斯决策




◆ 情况2: $\Sigma_i = \Sigma$

$$g_i(x) = -\frac{1}{2}(x - \mu_i)^T \Sigma_i^{-1}(x - \mu_i) - \frac{d}{2} \ln(2\pi) - \frac{1}{2} \ln |\Sigma_i| + \ln p(\omega_i)$$



$$g_i(x) = -\frac{1}{2}(x - \mu_i)^T \Sigma^{-1}(x - \mu_i) + \ln p(\omega_i)$$

d维椭球状分布，判决超平面未必垂直于连接两类中心的连线。



7.3 贝叶斯决策


➤ 正态分布条件下的贝叶斯决策

◆ 情况3: $\Sigma_i \neq \Sigma_j \quad i \neq j$


$$g_i(x) = -\frac{1}{2}(x - \mu_i)^T \Sigma_i^{-1}(x - \mu_i) - \frac{d}{2} \ln(2\pi) - \frac{1}{2} \ln |\Sigma_i| + \ln p(\omega_i)$$



$$g_i(x) = -\frac{1}{2}(x - \mu_i)^T \Sigma_i^{-1}(x - \mu_i) - \frac{1}{2} \ln |\Sigma_i| + \ln p(\omega_i)$$



7.3 贝叶斯决策



任意三维高斯分布产生的二维超二次平面的贝叶斯判决边界。

7.3 贝叶斯决策

➤ 线性判别函数(Linear Discriminant Function, LDF)

$$g_i(x) = -\frac{1}{2}(x - \mu_i)^T \Sigma_i^{-1}(x - \mu_i) - \frac{d}{2} \ln(2\pi) - \frac{1}{2} \ln |\Sigma_i| + \ln p(\omega_i)$$

假设各类协方差矩阵都相等，去除判别函数公式中对各类别相同的项，并忽略先验概率，得到线性判别函数

$$g_{\text{LDF}}(x) = A_i^T x + b_i$$

$$A_i = \Sigma^{-1} \mu_i \quad b_i = -\frac{1}{2} \mu_i^T \Sigma^{-1} \mu_i$$

7.3 贝叶斯决策

➤ 二次判别函数(Quadratic Discriminant Function, QDF)

假设各类的协方差阵 Σ_i 不相等, 得二次判别函数:

$$g_{\text{QDF}}(x) = -\frac{1}{2}(x - \mu_i)^T \Sigma_i^{-1}(x - \mu_i) - \frac{1}{2} \ln |\Sigma_i|$$

对判别函数取负数并乘以系数2, 利用协方差矩阵的特征分解, 得到:

$$\begin{aligned} g'_{\text{QDF}}(x) &= -2g_{\text{QDF}}(x) = (x - \mu_M)^T \Sigma_M^{-1}(x - \mu_M) + \ln |\Sigma_M| \\ &= \sum_{i=1}^n \frac{1}{\lambda_i} \{\varphi_i^T (x - \mu_M)\}^2 + \ln \prod_{i=1}^n \lambda_i \end{aligned}$$

7.3 贝叶斯决策

➤ 二次判别函数(Quadratic Discriminant Function, QDF)

对判别函数取负数并乘以系数2，利用协方差矩阵的特征分解，得到：

$$\begin{aligned} g'_{QDF}(x) &= -2g_{QDF}(x) = (x - \mu_M)^T \Sigma_M^{-1} (x - \mu_M) + \ln |\Sigma_M| \\ &= \sum_{i=1}^n \frac{1}{\lambda_i} \{\varphi_i^T (x - \mu_M)\}^2 + \ln \prod_{i=1}^n \lambda_i \end{aligned}$$

其中， $\Sigma_M = \sum_{i=1}^n \lambda_i \varphi_i \varphi_i^T$ ， μ_M 、 Σ_M 为对应第 i （原类别下标 i 暂且省略）类均值和协方差矩阵的**最大似然估计**； Σ_M 的特征值及对应特征向量为 $\lambda_i (i=1, \dots, n)$ 、 φ_i ，特征值为降序排列。从式可以看出，计算结果对于较小特征值的估计误差更为敏感

7.3 贝叶斯决策

►例1：现有两类数据，分别满足高斯分布

$$\mu_1 = \begin{bmatrix} 3 \\ 6 \end{bmatrix}, \quad \Sigma_1 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \quad \mu_2 = \begin{bmatrix} 3 \\ -2 \end{bmatrix}, \quad \Sigma_2 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix},$$

假设两类分布的先验概率相等，试给出两类的分类判别边界。

$$g_i(x) = -\frac{1}{2}(x - \mu_i)^T \Sigma_i^{-1}(x - \mu_i) - \frac{d}{2} \ln(2\pi) - \frac{1}{2} \ln |\Sigma_i| + \ln p(\omega_i)$$

7.3 贝叶斯决策

► 解答：两类分类判别边界满足 $g_1(x) = g_2(x)$

$$\begin{aligned} g_1(x) - g_2(x) &= \left[-\frac{1}{2}(x - \mu_1)^T \Sigma_1^{-1}(x - \mu_1) - \frac{1}{2} \ln |\Sigma_1| + \ln p(\omega_1) \right] \\ &\quad - \left[-\frac{1}{2}(x - \mu_2)^T \Sigma_2^{-1}(x - \mu_2) - \frac{1}{2} \ln |\Sigma_2| + \ln p(\omega_2) \right] \\ &= \left(-\frac{1}{2} x^T \Sigma_1^{-1} x + \frac{1}{2} x^T \Sigma_2^{-1} x \right) + \left(\mu_1^T \Sigma_1^{-1} - \mu_2^T \Sigma_2^{-1} \right) x \\ &\quad + \left(-\frac{1}{2} \mu_1^T \Sigma_1^{-1} \mu_1 + \frac{1}{2} \mu_2^T \Sigma_2^{-1} \mu_2 - \frac{1}{2} \ln |\Sigma_1| + \frac{1}{2} \ln |\Sigma_2| + \ln p(\omega_1) - \ln p(\omega_2) \right) \end{aligned}$$

7.3 贝叶斯决策

► 解答：两类分类判别边界满足 $g_1(x) = g_2(x)$

$$g_1(x) - g_2(x) = (\mu_1^T \Sigma_1^{-1} - \mu_2^T \Sigma_2^{-1})x + \left(-\frac{1}{2} \mu_1^T \Sigma_1^{-1} \mu_1 + \frac{1}{2} \mu_2^T \Sigma_2^{-1} \mu_2 \right)$$

$$\begin{aligned} \text{► 记 } x &= \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}, & g_1(x) - g_2(x) \\ &= \frac{1}{2} ([3 \ 6] - [3 \ -2])x + \frac{1}{2} \cdot \frac{1}{2} \left(-[3 \ 6] \begin{bmatrix} 3 \\ 6 \end{bmatrix} + [3 \ -2] \begin{bmatrix} 3 \\ -2 \end{bmatrix} \right) \\ &= [0 \ 4]x - 8 = 4x_2 - 8 \end{aligned}$$

$g_1(x) - g_2(x) > 0$ 第1类


$g_1(x) - g_2(x) < 0$ 第2类

7.3 贝叶斯决策

► 解答：两类分类判别边界满足 $g_1(x) = g_2(x)$

$$g_1(x) - g_2(x) = \left(\mu_1^T \Sigma_1^{-1} - \mu_2^T \Sigma_2^{-1} \right) x + \left(-\frac{1}{2} \mu_1^T \Sigma_1^{-1} \mu_1 + \frac{1}{2} \mu_2^T \Sigma_2^{-1} \mu_2 \right)$$

$$g_1(x) - g_2(x) = 4x_2 - 8$$



$g_1(x) - g_2(x) > 0$ 第1类
 $g_1(x) - g_2(x) < 0$ 第2类

7.3 贝叶斯决策

►例2：现有两类数据，分别满足高斯分布

$$\mu_1 = \begin{bmatrix} 3 \\ 6 \end{bmatrix}, \quad \Sigma_1 = \begin{bmatrix} 1.5 & 1 \\ 1 & 1.5 \end{bmatrix} \quad \mu_2 = \begin{bmatrix} 3 \\ -2 \end{bmatrix}, \quad \Sigma_2 = \begin{bmatrix} 1.5 & 1 \\ 1 & 1.5 \end{bmatrix}$$

假设两类分布的先验概率相等，试给出两类的分类判别边界。

$$g_i(x) = -\frac{1}{2}(x - \mu_i)^T \Sigma_i^{-1}(x - \mu_i) - \frac{d}{2} \ln(2\pi) - \frac{1}{2} \ln |\Sigma_i| + \ln p(\omega_i)$$

7.3 贝叶斯决策

► 解答：两类分类判别边界满足 $g_1(x) = g_2(x)$

$$g_1(x) - g_2(x) = \left(-\frac{1}{2} x^T \Sigma_1^{-1} x + \frac{1}{2} x^T \Sigma_2^{-1} x \right) + \left(\mu_1^T \Sigma_1^{-1} - \mu_2^T \Sigma_2^{-1} \right) x \\ + \left(-\frac{1}{2} \mu_1^T \Sigma_1^{-1} \mu_1 + \frac{1}{2} \mu_2^T \Sigma_2^{-1} \mu_2 - \frac{1}{2} \ln |\Sigma_1| + \frac{1}{2} \ln |\Sigma_2| + \ln p(\omega_1) - \ln p(\omega_2) \right)$$

$$g_1(x) - g_2(x) = \left(\mu_1^T \Sigma_1^{-1} - \mu_2^T \Sigma_2^{-1} \right) x + \left(-\frac{1}{2} \mu_1^T \Sigma_1^{-1} \mu_1 + \frac{1}{2} \mu_2^T \Sigma_2^{-1} \mu_2 \right)$$

7.3 贝叶斯决策

► 解答：两类分类判别边界满足 $g_1(x) = g_2(x)$

$$g_1(x) - g_2(x) = (\mu_1^T \Sigma_1^{-1} - \mu_2^T \Sigma_2^{-1})x + \left(-\frac{1}{2} \mu_1^T \Sigma_1^{-1} \mu_1 + \frac{1}{2} \mu_2^T \Sigma_2^{-1} \mu_2 \right)$$

► 记 $x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$, $\Sigma_1^{-1} = \Sigma_2^{-1} = \begin{bmatrix} 1.2 & -0.8 \\ -0.8 & 1.2 \end{bmatrix}$


$$\begin{aligned} & g_1(x) - g_2(x) \\ &= ([3 \ 6] - [3 \ -2]) \begin{bmatrix} 1.2 & -0.8 \\ -0.8 & 1.2 \end{bmatrix} x + \frac{1}{2} \left(-[3 \ 6] \begin{bmatrix} 1.2 & -0.8 \\ -0.8 & 1.2 \end{bmatrix} \begin{bmatrix} 3 \\ 6 \end{bmatrix} + [3 \ -2] \begin{bmatrix} 1.2 & -0.8 \\ -0.8 & 1.2 \end{bmatrix} \begin{bmatrix} 3 \\ -2 \end{bmatrix} \right) \\ &= [-6.4 \ 9.6]x = -6.4x_1 + 9.6x_2 \end{aligned}$$

7.3 贝叶斯决策

► 解答：两类分类判别边界满足 $g_1(x) = g_2(x)$

$$g_1(x) - g_2(x) = \left(\mu_1^T \Sigma_1^{-1} - \mu_2^T \Sigma_2^{-1} \right) x + \left(-\frac{1}{2} \mu_1^T \Sigma_1^{-1} \mu_1 + \frac{1}{2} \mu_2^T \Sigma_2^{-1} \mu_2 \right)$$

$$g_1(x) - g_2(x) = [-6.4 \quad 9.6] x = -6.4x_1 + 9.6x_2$$



$g_1(x) - g_2(x) > 0$ 第1类

$g_1(x) - g_2(x) < 0$ 第2类

7.3 贝叶斯决策

►例3：现有两类数据，分别满足高斯分布

$$\mu_1 = \begin{bmatrix} 3 \\ 6 \end{bmatrix}, \quad \Sigma_1 = \begin{bmatrix} 1/2 & 0 \\ 0 & 2 \end{bmatrix} \quad \mu_2 = \begin{bmatrix} 3 \\ -2 \end{bmatrix}, \quad \Sigma_2 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix},$$

假设两类分布的先验概率相等，试给出两类的分类判别边界。

$$g_i(x) = -\frac{1}{2}(x - \mu_i)^T \Sigma_i^{-1}(x - \mu_i) - \frac{d}{2} \ln(2\pi) - \frac{1}{2} \ln |\Sigma_i| + \ln p(\omega_i)$$

7.3 贝叶斯决策

►例3：现有两类数据，分别满足高斯分布

$$\mu_1 = \begin{bmatrix} 3 \\ 6 \end{bmatrix}, \quad \Sigma_1 = \begin{bmatrix} 1/2 & 0 \\ 0 & 2 \end{bmatrix} \quad \mu_2 = \begin{bmatrix} 3 \\ -2 \end{bmatrix}, \quad \Sigma_2 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix},$$

假设两类分布的先验概率相等，试给出两类的分类判别边界。

解答：首先计算

$$\Sigma_1^{-1} = \begin{bmatrix} 2 & 0 \\ 0 & 1/2 \end{bmatrix}, \quad \Sigma_2^{-1} = \begin{bmatrix} 1/2 & 0 \\ 0 & 1/2 \end{bmatrix}$$

7.3 贝叶斯决策

► 解答：两类分类判别边界满足 $g_1(x) = g_2(x)$

$$g_1(x) - g_2(x) = \left(-\frac{1}{2} x^T \Sigma_1^{-1} x + \frac{1}{2} x^T \Sigma_2^{-1} x \right) + \left(\mu_1^T \Sigma_1^{-1} - \mu_2^T \Sigma_2^{-1} \right) x \\ + \left(-\frac{1}{2} \mu_1^T \Sigma_1^{-1} \mu_1 + \frac{1}{2} \mu_2^T \Sigma_2^{-1} \mu_2 - \frac{1}{2} \ln |\Sigma_1| + \frac{1}{2} \ln |\Sigma_2| + \ln p(\omega_1) - \ln p(\omega_2) \right)$$

$$g_1(x) - g_2(x) = 0.1875x_1^2 - 1.125x_1 + 3.514 - x_2$$

► 记 $x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$

$$g_1(x) - g_2(x) = 0 \Rightarrow x_2 = 0.1875x_1^2 - 1.125x_1 + 3.514$$

7.3 贝叶斯决策

► 解答：两类分类判别边界满足 $g_1(x) = g_2(x)$


$$g_1(x) - g_2(x) = \left(-\frac{1}{2} x^T \Sigma_1^{-1} x + \frac{1}{2} x^T \Sigma_2^{-1} x \right) + \left(\mu_1^T \Sigma_1^{-1} - \mu_2^T \Sigma_2^{-1} \right) x \\ + \left(-\frac{1}{2} \mu_1^T \Sigma_1^{-1} \mu_1 + \frac{1}{2} \mu_2^T \Sigma_2^{-1} \mu_2 - \frac{1}{2} \ln |\Sigma_1| + \frac{1}{2} \ln |\Sigma_2| + \ln p(\omega_1) - \ln p(\omega_2) \right)$$

$$g_1(x) - g_2(x) = 0.1875x_1^2 - 1.125x_1 + 3.514 - x_2$$

$$g_1(x) - g_2(x) = 0 \Rightarrow x_2 = 0.1875x_1^2 - 1.125x_1 + 3.514$$

$$g_1(x) - g_2(x) > 0 \quad \text{第1类}$$

$$g_1(x) - g_2(x) < 0 \quad \text{第2类}$$



7.3 贝叶斯决策(小结)

➤ 数学基础：贝叶斯定理、高斯分布

➤ 名词概念：

- ◆ 先验概率、后验概率、似然概率
- ◆ 贝叶斯决策：先验概率至后验概率的转化

➤ 正态分布下的贝叶斯决策

- ◆ 三种情况分析
- ◆ 欧式距离、马氏距离
- ◆ 线性判别函数、二次判别函数
- ◆ 拓展：MQDF

参考文献

- 边肇祺,张学工.模式识别. 清华大学出版社, 2000
- Duda R O, Hart P E, Stork D G. Pattern classification. John Wiley & Sons, 2012.

谢谢大家！

欢迎提出宝贵意见！

数学基础：拉格朗日乘子法

目标函数极值问题

$$\min f(x)$$

式中, $x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$

$$\text{满足: } G_j(x) = 0, \quad j = 1, 2, \dots, m, \quad m < n$$

数学基础：拉格朗日乘子法

例： $\min f(x, y) = x^2 + y^2$

约束条件： $x + 2y = 1$

即： $G(x, y) = x + 2y - 1 = 0$


第一种解法：

解出： $y = \frac{1}{2}(1 - x) = \frac{1}{2} - \frac{1}{2}x$,

带入 $f(x, y(x))$

$$f(x, y(x)) = x^2 + \left(\frac{1}{2} - \frac{1}{2}x\right)^2$$

$$\frac{\partial f}{\partial x} = 2x - \left(\frac{1}{2} - \frac{1}{2}x\right) = 0$$



解得： $x = \frac{1}{5}; y = \frac{2}{5}$

数学基础：拉格朗日乘子法

第一种解法需要解出： $y = \frac{1}{2}(1-x) = \frac{1}{2} - \frac{1}{2}x$,

问题：如果不能由约束条件显式写出 y 的表达式，怎么办？

拉格朗日乘子法将受约束优化问题
转换为无约束优化问题

拉格朗日乘子法：

$\min f(x)$ 满足： $G_j(x) = 0, \quad j = 1, 2, \dots, m, \quad m < n$

构造拉格朗日函数

$$\min L = f(x, y) + \lambda G(x, y)$$

数学基础：拉格朗日乘子法

构造拉格朗日函数

$$L = f(x, y) + \lambda G(x, y) = x^2 + y^2 + \lambda(x + 2y - 1)$$

$$\frac{\partial L}{\partial x} = 2x + \lambda = 0$$

$$\frac{\partial L}{\partial y} = 2y + 2\lambda = 0$$

$$\text{解得: } x = -\frac{\lambda}{2}; \quad y = -\lambda$$

$$\text{约束条件: } x + 2y = 1$$

$$\text{代入约束方程 } -\frac{\lambda}{2} - 2\lambda = 1; \quad \text{解得 } \lambda = -\frac{2}{5}$$

$$\text{解得: } x = \frac{1}{5}; \quad y = \frac{2}{5}$$

结果与第一种解法一致

数学基础：矩阵求导方法

高等数学中函数的和、乘积、复合函数的求导法适用于函数
矩阵的微分

$$\frac{d}{dt}(A(t) + B(t)) = \frac{d}{dt}A(t) + \frac{d}{dt}B(t)$$

$$\frac{d}{dt}(A(t)B(t)) = \left(\frac{d}{dt}A(t)\right)B(t) + A(t)\left(\frac{d}{dt}B(t)\right)$$

$$\frac{d}{dt}(\lambda(t)A(t)) = \left(\frac{d}{dt}\lambda(t)\right)A(t) + \lambda(t)\left(\frac{d}{dt}A(t)\right)$$

$$\frac{d}{dt}A(u) = u'(t)\frac{d}{du}A(u)$$

数学基础：矩阵求导方法

例1

$$\mathbf{a} = \begin{pmatrix} a_1 \\ a_2 \\ \vdots \\ a_n \end{pmatrix} \quad \mathbf{x} = \begin{pmatrix} \xi_1 \\ \xi_2 \\ \vdots \\ \xi_n \end{pmatrix} \quad f(\mathbf{x}) = \mathbf{a}^T \mathbf{x} = \mathbf{x}^T \mathbf{a} \quad \frac{df}{d\mathbf{x}} = ?$$

解：

$$f(\mathbf{x}) = a_1 \xi_1 + a_2 \xi_2 + \cdots + a_n \xi_n$$

$$\frac{\partial f}{\partial \xi_i} = a_i \quad (i = 1, \cdots, n) \quad \frac{df}{d\mathbf{x}} = \begin{pmatrix} \frac{\partial f}{\partial \xi_1} \\ \vdots \\ \frac{\partial f}{\partial \xi_n} \end{pmatrix} = \begin{pmatrix} a_1 \\ \vdots \\ a_n \end{pmatrix} = \mathbf{a}$$

数学基础：矩阵求导方法

例2

$$f(x) = x^T A x \quad A = \begin{pmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{pmatrix} \quad x = \begin{pmatrix} \xi_1 \\ \xi_2 \\ \vdots \\ \xi_n \end{pmatrix} \quad \frac{df}{dx} = ?$$

$$f(x) = x^T A x = \begin{pmatrix} \xi_1 & \cdots & \xi_j & \cdots & \xi_n \end{pmatrix} \begin{pmatrix} a_{11}\xi_1 + \cdots + a_{1j}\xi_j + \cdots + a_{1n}\xi_n \\ a_{21}\xi_1 + \cdots + a_{2j}\xi_j + \cdots + a_{2n}\xi_n \\ \vdots \\ a_{n1}\xi_1 + \cdots + a_{nj}\xi_j + \cdots + a_{nn}\xi_n \end{pmatrix}$$

$$= \xi_1 (a_{11}\xi_1 + \cdots + a_{1j}\xi_j + \cdots + a_{1n}\xi_n) + \cdots + \xi_j (a_{j1}\xi_1 + \cdots + a_{jj}\xi_j + \cdots + a_{jn}\xi_n) \\ + \cdots + \xi_n (a_{n1}\xi_1 + \cdots + a_{nj}\xi_j + \cdots + a_{nn}\xi_n)$$

$$\sum_{k=1}^n a_{kj} \xi_k \qquad \sum_{k=1}^n a_{jk} \xi_k$$

数学基础：矩阵求导方法

$$\frac{\partial f}{\partial \xi_j} = \sum_{k=1}^n a_{kj} \xi_k + \sum_{k=1}^n a_{jk} \xi_k \quad (j=1, \dots, n)$$

$$\begin{aligned} \frac{df}{dx} &= \begin{pmatrix} \frac{\partial f}{\partial \xi_1} \\ \vdots \\ \frac{\partial f}{\partial \xi_n} \end{pmatrix} = \begin{pmatrix} \sum_{k=1}^n a_{k1} \xi_k + \sum_{k=1}^n a_{1k} \xi_k \\ \vdots \\ \sum_{k=1}^n a_{kn} \xi_k + \sum_{k=1}^n a_{nk} \xi_k \end{pmatrix} = \begin{pmatrix} \sum_{k=1}^n a_{k1} \xi_k \\ \vdots \\ \sum_{k=1}^n a_{kn} \xi_k \end{pmatrix} + \begin{pmatrix} \sum_{k=1}^n a_{1k} \xi_k \\ \vdots \\ \sum_{k=1}^n a_{nk} \xi_k \end{pmatrix} \\ &= A^T x + Ax = (A^T + A)x \end{aligned}$$

当A是对称矩阵时

$$f(x) = x^T Ax \quad \xrightarrow{A^T = A} \quad \frac{df}{dx} = 2Ax$$

数学基础：矩阵特征值分解

假设 A 是 n 阶方阵（ $n \times n$ 矩阵），存在常数 λ 以及非零列向量 $\mathbf{x}$ ，使得 $A\mathbf{x}=\lambda\mathbf{x}$ 成立。

$$A\mathbf{x}=\lambda\mathbf{x}$$

数学上求解

$$(A - \lambda I)\mathbf{x}=\mathbf{0}$$

$$|A - \lambda I|=0$$

性质： n 阶方阵 $A = (a_{ij})$ 的所有特征根为 $\lambda_1, \lambda_2, \dots, \lambda_n$ (包括重根)：

$$\begin{aligned}\lambda_1 + \lambda_2 + \dots + \lambda_n &= \sum_{i=1}^n a_{ii} = \text{trace}(A) \\ \lambda_1 \lambda_2 \dots \lambda_n &= \det(A)\end{aligned}$$

数学基础：向量范数

假设 $\mathbf{x}$ 是 n 维向量，其常见范数定义为

1-范数 $\|\mathbf{x}\|_1 = \sum_{i=1}^n |x_i|$ 向量绝对值之和

2-范数 $\|\mathbf{x}\|_2 = \sqrt{\sum_{i=1}^n x_i^2}$ 向量绝对值平方和再开方

无穷-范数 $\|\mathbf{x}\|_\infty = \max_i |x_i|$ 向量绝对值最大值

p-范数 $\|\mathbf{x}\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}}$ 向量绝对值p次方的1/p次幂


0-范数 非0元素的个数

特征变换: 主成分分析 – 数学推导

➤ 主成分分析 (PCA, principal component analysis)

- ◆ 假设有 n 个 p 维的样本 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$
- ◆ 如何用仅仅一个 p 维向量 $\mathbf{x}_0$ 进行表征?
- ◆ 代表向量 $\mathbf{x}_0$ 与样本集中各样本的均方距离最小;
- ◆ 定义均方准则函数

$$J(\mathbf{x}_0) = \sum_{m=1}^n \|\mathbf{x}_0 - \mathbf{x}_m\|^2$$



特征变换: 主成分分析 – 数学推导

➤ 主成分分析 (PCA, principal component analysis)

- ◆ 假设有 n 个 p 维的样本 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$
- ◆ 如何用仅仅一个 p 维向量进行表征?
- ◆ 代表向量 $\mathbf{x}_0$ 与样本集中各样本的均方距离最小;
- ◆ 定义均方准则函数

$$J(\mathbf{x}_0) = \sum_{m=1}^n \|\mathbf{x}_0 - \mathbf{x}_m\|^2$$

样本均值是样本数据集的零维表达, 但缺乏对样本差异性的信息。

- ◆ 定义样本均值(centroid):

$$\boldsymbol{\mu} = \sum_{m=1}^n \mathbf{x}_m$$

- ◆ $\mathbf{x}_0 = \boldsymbol{\mu}$ 即使上述均方准则函数最小的 p 维向量。

特征变换: 主成分分析 – 数学推导

➤ 主成分分析 (PCA, principal component analysis)

- ◆ 假设有 n 个 p 维的样本 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$
- ◆ 如何寻找最优投影方向 $\mathbf{v}$, 使得我们仅仅利用 $\boldsymbol{\mu} + z_m \mathbf{v}$ 对样本 $\mathbf{x}_m$ 进行表征?
- ◆ 定义均方准则函数

$$J_1(z, \mathbf{v}) = \sum_{m=1}^n \|\boldsymbol{\mu} + z_m \mathbf{v} - \mathbf{x}_m\|^2$$

- ◆ 定义样本协方差矩阵和散度矩阵:

$$C = \frac{1}{n-1} \sum_{m=1}^n (\mathbf{x}_m - \boldsymbol{\mu})(\mathbf{x}_m - \boldsymbol{\mu})^T$$

$$S = \sum_{m=1}^n (\mathbf{x}_m - \boldsymbol{\mu})(\mathbf{x}_m - \boldsymbol{\mu})^T$$

特征变换: 主成分分析 – 数学推导

➤ 主成分分析 (PCA, principal component analysis)

- ◆ 假设有 n 个 p 维的样本 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$
- ◆ 如何寻找最优投影方向 $\mathbf{v}$, 使得我们仅仅利用 $\boldsymbol{\mu} + z_m \mathbf{v}$ 对样本 $\mathbf{x}_m$ 进行表征?
- ◆ 定义均方准则函数

$$\begin{aligned} J_1(z, \mathbf{v}) &= \sum_{m=1}^n \|\boldsymbol{\mu} + z_m \mathbf{v} - \mathbf{x}_m\|^2 \\ &= -\mathbf{v}^T S \mathbf{v} + \sum_{m=1}^n \|\boldsymbol{\mu} - \mathbf{x}_m\|^2 \end{aligned}$$

常数项

- ◆ 上式可转化为 $\max_{\mathbf{v}} \mathbf{v}^T S \mathbf{v}$, subject to $\mathbf{v}^T \mathbf{v} = 1$

特征变换: 主成分分析 – 数学推导

➤ 主成分分析 (PCA, principal component analysis)

- ◆ 假设有 n 个 p 维的样本 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$
- ◆ 如何寻找最优投影方向 $\mathbf{v}$, 使得我们仅仅利用 $\boldsymbol{\mu} + z_m \mathbf{v}$ 对样本 $\mathbf{x}_m$ 进行表征?
- ◆ 优化问题 $\max_{\mathbf{v}} \mathbf{v}^T S \mathbf{v}$, subject to $\mathbf{v}^T \mathbf{v} = 1$
- ◆ 利用拉格朗日乘子法

$$L_1(z, \mathbf{v}, \lambda) = \mathbf{v}^T S \mathbf{v} - \lambda(\mathbf{v}^T \mathbf{v} - 1)$$

- ◆ 对上式求偏导并设为0

$$\frac{\partial L_1(z, \mathbf{v}, \lambda)}{\partial \mathbf{v}} = 2S\mathbf{v} - 2\lambda\mathbf{v}$$

- ◆ 可以发现 $\mathbf{v}$ 是散度矩阵的特征向量, λ 是对应的特征值;
- ◆ 最大化 $\mathbf{v}^T S \mathbf{v}$ 则对应于取最大特征值对应的特征向量。

样本数据集的一维表达:
设置散度矩阵的最大特征值对应的特征方向为投影方向。

特征变换: 主成分分析 – 数学推导

➤ 主成分分析 (PCA, principal component analysis)

- ◆ 假设有 n 个 p 维的样本 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$
- ◆ 如何寻找 $k (k < p)$ 个最优投影方向 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k$, 使得利用

$$\mathbf{x} = \boldsymbol{\mu} + \sum_{l=1}^k z_l \mathbf{v}_l$$

对样本进行最小均方准则下的表征?

$$J_k(\mathbf{z}, \mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k) = \sum_{m=1}^n \left\| \boldsymbol{\mu} + \sum_{l=1}^k z_{ml} \mathbf{v}_l - \mathbf{x}_m \right\|^2$$

- ◆ 将上述推导推广至 k 维情况
- ◆ 可以发现 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k$ 是散度矩阵 S 的 k 个最大特征值对应的特征向量。

课堂讨论

- 1 思考特征与模式的关系？如何评价特征的优劣？对于模式识别问题，如何设计或学习到高效特征提升模式识别精度？
- 2 思考手工设计的特征和基于深度学习的特征各有什么样的优缺点？