



媒体与认知

Media and Cognition

清华大学电子工程系

王生进 李亚利

Email: liyali13@tsinghua.edu.cn

第7讲 模式识别基础

7.1 基本概念

7.2 特征提取与变换

7.3 贝叶斯决策


7.4 参数估计方法

7.5 模式识别系统

频率学派和贝叶斯学派

- 相同点：最大似然函数在频率学派和贝叶斯学派都具有重要的作用，其思想是认为已观测数据的概率分布是最大概率，最大概率对应的模型就是需要找的模型，“存在即合理”。
- 不同点：频率学派认为模型是一成不变的，即模型参数是个常数；贝叶斯学派认为模型是一直在变的，当获取新的信息后，模型也相应的在改变，即模型参数是变量，用概率去描述模型参数的不确定性。

7.4.1 参数估计方法：最大似然估计



7.4.1 参数估计方法：最大似然估计

◆ 最大似然估计

$$l(\theta) \equiv \ln p(D|\theta) = \sum_{i=1}^n \ln p(x_i|\theta)$$
$$\hat{\theta} = \arg \max_{\theta} l(\theta)$$

◆ 高斯分布假设的最大似然估计

$$\hat{\mu} = \hat{\theta}_1 = \frac{1}{n} \sum_{k=1}^n x_k \quad \hat{\Sigma} = \hat{\theta}_2 = \frac{1}{n} \sum_{k=1}^n (x_k - \hat{\mu})(x_k - \hat{\mu})^T$$

◆ 无偏估计

样本协方差矩阵

$$C = \frac{1}{n-1} \sum_{k=1}^n (x_k - \hat{\mu})(x_k - \hat{\mu})^T$$

7.4.2 参数估计方法：最大后验估计

◆ 最大后验估计

$$l(\theta) \equiv \ln p(D|\theta) = \sum_{i=1}^n \ln p(x_i|\theta)$$
$$\hat{\theta}_{MAP} = \arg \max_{\theta} l(\theta) + \ln p(\theta)$$

◆ 高斯分布假设的最大后验估计(均值未知)

$$\begin{cases} \boldsymbol{\mu}_n = \Sigma_0 \left(\frac{1}{n} \Sigma + \Sigma_0 \right)^{-1} \left(\frac{1}{n} \sum_{k=1}^n \mathbf{x}_k \right) + \frac{1}{n} \Sigma \left(\frac{1}{n} \Sigma + \Sigma_0 \right)^{-1} \boldsymbol{\mu}_0 \\ \Sigma_n = \Sigma_0 \left(\frac{1}{n} \Sigma + \Sigma_0 \right)^{-1} \frac{1}{n} \Sigma \end{cases}$$

7.4.2 参数估计方法：最大后验估计

示例：设有样本 $x_1 = (-1, 6)^T$, $x_2 = (2, 6)^T$, $x_3 = (-7, -3)^T$

试问根据最大似然估计获取的均值和协方差分别是？

样本协方差矩阵是？

解答：


$$\hat{\mu} = \frac{1}{n} \sum_{k=1}^n x_k \quad \hat{\Sigma} = \frac{1}{n} \sum_{k=1}^n (x_k - \hat{\mu})(x_k - \hat{\mu})^T$$

$$\hat{\mu} = \begin{bmatrix} -2 \\ 3 \end{bmatrix} \quad \hat{\Sigma} = \begin{bmatrix} 14 & 15 \\ 15 & 18 \end{bmatrix}$$

$$C = \frac{1}{n-1} \sum_{k=1}^n (x_k - \hat{\mu})(x_k - \hat{\mu})^T$$
$$C = \begin{bmatrix} 21 & 22.5 \\ 22.5 & 27 \end{bmatrix}$$

7.4.3 参数估计方法：混合高斯模型


➤ 混合高斯模型（Gaussian Mixture Model）



多峰分布的高斯假设拟合

7.4.3 参数估计方法：混合高斯模型



➤ 混合高斯模型（Gaussian Mixture Model）



多峰分布的高斯假设拟合

7.4.3 参数估计方法：混合高斯模型

➤ 混合高斯模型（Gaussian Mixture Model）



多峰分布的高斯假设拟合

7.4.3 参数估计方法：混合高斯模型

实际字符样本特征分布的非高斯性


MNIST样本集

训练样本数：60,000

测试样本数：10,000

图像规一化为 28×28

7 2 1 0 4 1 4 9 5
9 0 6 9 0 1 5 9 7
3 4 9 6 6 5 4 0 7
4 0 1 3 1 3 4 7 2
7 1 2 1 1 7 4 2 3




手写数字0~9的特征分布
在前二维主分量平面上的投影显示

7.4.3 参数估计方法：混合高斯模型


- 混合高斯模型比高斯模型具有更强的描述能力，但其需要的参数也成倍增加，实际中通常对节点方差矩阵结构进行约束

$$p(\mathbf{x} | \omega) = \sum_{k=1}^K \pi_k N(\mathbf{x} | \boldsymbol{\mu}_k, \Sigma_k)$$


$$\sum_{k=1}^K \pi_k = 1$$



无约束的一般情况



对角方差



对角共享方差

7.4.3 参数估计方法：混合高斯模型

➤ 混合高斯模型的参数估计

$$p(\mathbf{x} | \omega) = \sum_{k=1}^K \pi_k N(\mathbf{x} | \mu_k, \Sigma_k) \quad \sum_{k=1}^K \pi_k = 1$$

➤ 期望最大值EM算法

◆ 给定一些观察数据 x ，假设 x 符合如下混合高斯分布：

$$p(x) = \sum_{k=1}^K \pi_k N(x | \mu_k, \Sigma_k)$$

◆ 求混合高斯分布的参数 π_k, μ_k, Σ_k

7.4.3 参数估计方法：混合高斯模型

➤ 混合高斯模型（Gaussian Mixture Model）


◆ 混合分布的概率密度估计问题：

1. 所有样本都来自于K种类别，K已知；
2. 每种类别的先验概率 $P(\omega_j)$ 未知；
3. 类条件概率的数学形式已知 $p(\mathbf{x}|\omega_j, \boldsymbol{\theta}_j)$ ，但参数 $\boldsymbol{\theta}_j$ 未知；
4. 样本类别未被标记。

$$p(\mathbf{x}|\boldsymbol{\theta}) = \sum_{j=1}^K p(\mathbf{x}|\omega_j, \boldsymbol{\theta}_j) P(\omega_j)$$

7.4.3 参数估计方法：混合高斯模型

- 该混合高斯分布一共有K个分布，并且对于每个观察到的x，如果我们同时还知道它属于K中的哪一个分布，则我们可以根据最大似然估计求出每个参数。



$$\mu_k = \frac{1}{N_k} \sum_{x_k} x_k$$


$$\Sigma_k = \frac{1}{N_k} \sum_{x_k} (x_k - \mu_k)(x_k - \mu_k)^T$$

$$\pi_k = \frac{N_k}{N}$$


7.4.3 参数估计方法：混合高斯模型

- 观察数据 x 属于哪个高斯分布是未知的，这时需要采用EM算法。

期望最大化



有监督：样本属于哪个
高斯分布已知



无监督：样本属于哪个
高斯分布未知

EM算法：混合高斯模型参数估计

- 1、初始化K个高斯分布参数 μ_k, Σ_k , 初始化 π_k 并保证 $\sum_{k=1}^K \pi_k = 1$
- 2、依据目前的高斯分布参数, 对样本 x 的类别隐藏变量 Z_{nk} 求期望

Expectation, $\gamma(z_{nk})$ 表示 x_n 属于第k类的概率

$$\gamma(z_{nk}) = \frac{\pi_k N(x_n | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j N(x_n | \mu_j, \Sigma_j)}$$

$$P(Z|X, \theta_t)$$

probability of x_n from k Gaussian
probability of x_n from all the mixed Gaussian

- 3、对高斯分布参数求最大似然估计 **Maximization**

$$\mu_k^{new} = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) x_n, \quad \Sigma_k^{new} = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) (x_n - \mu_k^{new})(x_n - \mu_k^{new})^T,$$


$$\pi_k^{new} = \frac{N_k}{N} \quad \text{其中, } N_k = \sum_{n=1}^N \gamma(z_{nk})$$

$$Q(\theta|\theta_t) = \sum_z P(Z|X, \theta_t) \ln \frac{P(X, Z|\theta)}{P(Z|X, \theta_t)}$$
$$\partial Q(\theta|\theta_t) / \partial \theta = 0$$

- 4、迭代计算第2、3步, 直到满足参数收敛条件或停止条件。


数据集

Old Faithful Data Set



美国黄石国家公园的间歇泉
Old Faithful Geyser

EM算法求解过程示例



应用示例：混合高斯模型



2019年4月10日， EHT项目组发布人类历史上拍到的第一张黑洞照片

应用示例：混合高斯模型




Figure 1. **Frequency Coverage:** (A) A sample of the telescope locations in the EHT. By observing a source over the course of a day, we obtain measurements corresponding to elliptical tracks in the source image’s spatial frequency plane (B). These frequencies, (u, v) , are the projected baseline lengths orthogonal to a telescope pair’s light of sight. Points of the same color correspond to measurements from the same telescope pair.

We use a Gaussian mixture model (GMM) patch prior to regularize our solution of $\hat{I}_\lambda(\mathbf{x})$. Although this is not an explicit prior on $\hat{I}_\lambda(\mathbf{x})$, patch priors have been shown to work well in the past [43, 44]. Building on ideas from [43], we maximize the EPLL by maximizing the probability of each of the N overlapping pulse patches in $\hat{I}_\lambda(\mathbf{x})$:

To optimize Eq. 9 we use “Half Quadratic Splitting” [43]. This method introduces a set of auxiliary patches $\{z^i\}_1^N$, one for each overlapping patch $P_i\mathbf{x}$ in the image. We can then solve this problem using an iterative framework:

(1) **Solve for $\{z^n\}$ given $\mathbf{x}$:** In order to complete this step we set $\{z^n\}$ to the most likely patch under the prior, given the corrupted measurements $P_n X$ and weighting parameter β (described further in [43]).

(2) **Solve for $\mathbf{x}$ given $\{z^n\}$:** If we were able to work with visibilities our problem would be quadratic in $\mathbf{x}$, and we could solve then for $\mathbf{x}$ in closed-form. However, since we use bispectrum measurements rather than visibilities, our energy is a 6th order polynomial that cannot be solved in closed-form. One possibility is to solve for the gradient and then use gradient descent to solve for a local minimum. However, this method is slow. Alternatively, we perform a 2nd order Taylor expansion around our current solution, $\mathbf{x}_0$, to obtain an approximation of the local minimum in closed-form. A detailed derivation of the gradient and local closed-form solution can be found in the supp. material [7].

As suggested in [43] we iterate between these two steps for increasing β values of 1, 4, 8, 16, 32, 64, 128, 256, 512.

7.4.4 隐含马尔可夫模型

➤ 序列识别:

- ◆ 语音识别、手写文字识别、行为识别等

手写文字识别

Foreign Minister.

FOREIGN MINISTER.

自然语言识别

Speech recognition



THE SOUND OF

机器翻译

Machine translation

我是电子工程
系的学生。

I am a student from
the Department of
Electronic Engineering.

行为识别

Activity recognition



Running

7.4.4 隐含马尔可夫模型：数学基础

➤ 假设 $Q = (q_1, q_2, \dots, q_T)$ 是一取值于有限集合 $S = \{s_1, s_2, \dots, s_N\}$ 的随机变量序列，满足

$$P(q_{t+1} = s_k | q_1, q_2, \dots, q_t) = P(q_{t+1} = s_k | q_t)$$

则称序列 Q 具有 **Markov性**，为 **Markov链**。

➤ 若进一步满足 $P(q_{t+1} = s_k | q_t) = P(q_2 = s_k | q_1)$ ，
则称序列 Q 是 **齐次Markov链**。



7.4.4 隐含马尔可夫模型：数学基础

➤ 齐次Markov链可以用状态转移概率矩阵 A 和初始概率 π 唯一确定表示

$$A = \{a_{ij}\}$$


$$a_{ij} = p(q_{t+1} = s_j | q_t = s_i), \text{其中 } a_{ij} \geq 0, \sum_{j=1}^N a_{ij} = 1, \forall i$$

$$\pi_i = P(q_1 = s_i), \text{其中, } \sum_{i=1}^N \pi_i = 1$$



7.4.4 隐含马尔可夫模型：数学基础

示例：假定一段时间的气象可由一个三状态的马尔可夫模型 M 描述， S_1 ：雨， S_2 ：多云， S_3 ：晴，状态转移概率矩阵为：



$$A = [a_{ij}] = \begin{array}{c|ccc} & S_1 & S_2 & S_3 \\ \hline S_1 & 0.4 & 0.3 & 0.3 \\ S_2 & 0.2 & 0.6 & 0.2 \\ S_3 & 0.1 & 0.1 & 0.8 \end{array}$$

7.4.4 隐含马尔可夫模型：数学基础


问题1: 假定今天为晴天，那么明天是晴天且后天是雨天的概率是多少？

问题2: 如果昨天是雨天，今天为多云天，那么明天是晴天的概率是多少？

问题3: 如果第一天为晴天，根据这一模型，在今后七天中天气为O=“晴雨雨晴云晴”的概率为：

$$\begin{aligned} P(O|M) &= P(S_3, S_3, S_3, S_1, S_1, S_3, S_2, S_3 | M) \\ &= P(S_3) \cdot P(S_3 | S_3) \cdot P(S_3 | S_3) \cdot P(S_1 | S_3) \cdot P(S_1 | S_1) \cdot \\ &\quad P(S_3 | S_1) \cdot P(S_2 | S_3) \cdot P(S_3 | S_2) \\ &= 1 \cdot a_{33} \cdot a_{33} \cdot a_{31} \cdot a_{11} \cdot a_{13} \cdot a_{32} \cdot a_{23} \\ &= (0.8)(0.8)(0.1)(0.4)(0.3)(0.1)(0.2) \\ &= 1.536 \times 10^{-4} \end{aligned}$$


$$A = [a_{ij}] = \begin{bmatrix} 0.4 & 0.3 & 0.3 \\ 0.2 & 0.6 & 0.2 \\ 0.1 & 0.1 & 0.8 \end{bmatrix}$$



7.4.4 隐含马尔可夫模型：原理

➤ 隐含马尔可夫模型（Hidden Markov Model, HMM）是一个双重随机过程：

- ◆ **状态序列**：是马尔可夫链，用**转移概率**描述
- ◆ **观测序列**：是一般随机过程，每一状态对应一个可以观察的事件，用**观测概率**描述




状态集 $S = \{s_1, s_2, \dots, s_N\}$ 观测符号集 $V = \{v_1, v_2, \dots, v_M\}$

HMM的基本要素

➤ 用三元组 $\lambda = (\pi, A, B)$ 用来描述

参数	含义	实例
A	与时间无关的状态转移概率矩阵	类间转移概率
B	给定状态下，观察值概率分布	给定类别，特征向量分布
π	初始状态空间的概率分布	初始时选择类别的概率



$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1N} \\ a_{21} & a_{22} & \cdots & a_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ a_{N1} & a_{N2} & \cdots & a_{NN} \end{bmatrix}$$
$$B = \begin{bmatrix} b_{11} & b_{12} & \cdots & b_{1M} \\ b_{21} & b_{22} & \cdots & b_{2M} \\ \vdots & \vdots & \ddots & \vdots \\ b_{N1} & b_{N2} & \cdots & b_{NM} \end{bmatrix}$$

$$\pi = (\pi_1, \cdots, \pi_N)$$

7.4.4 隐含马尔可夫模型：原理

基本假设

1：马尔可夫性

$$P(q_{t+1}|q_t, \dots, q_1) = P(q_{t+1}|q_t)$$

2：齐次性，状态转移概率与具体时刻无关

$$P(q_{t+1}|q_t) = P(q_{\tau+1}|q_{\tau}), \text{ 对任意 } t, \tau \text{ 成立}$$

3：观测序列独立性

$$P(O_1, \dots, O_T | q_1, \dots, q_T) = \prod_{t=1}^T P(O_t | q_t)$$

7.4.4 隐含马尔可夫模型：例子

➤ 两个随机过程

- ◆ 选择罐子——按照一定的转移概率选择罐子
- ◆ 选择彩球——在罐子中按照一定的概率取出一个彩球

放有彩色球的罐子，每个罐子都有编号，随机地从罐子中摸出彩球，



可观察序列 →



猜测隐藏
在幕后的
罐子序列

D	P	T	N	Y
A	N	D	V	V
A	P	V	N	V
.....				

Which one is
the best?



7.4.4 隐含马尔可夫模型：三个基本问题

➤ 评估问题：

如何根据给定 $O = \{O_1, O_2, \dots, O_T\}$ 和 λ 计算 $P(O|\lambda)$?

模型参数 λ 已知，评估观测序列 O 出现的概率

➤ 解码问题：

如何根据给定的 O 和 λ 计算最优路径 Q^* ?

模型参数 λ 和观测序列 O 已知，预测最可能出现的状态序列 Q^*

➤ 学习问题：

如何根据观测序列样本集合 O_{training} 进行模型 $\lambda = (A, B, \pi)$ 的参数估计?

给定观测序列的集合，训练模型参数，使得 $P(O_{\text{training}}|\lambda)$ 最大化

基本问题1：评估观测序列的概率


评估：如何根据模型参数 λ 和给定 $O = \{O_1, O_2, \dots, O_T\}$ 计算 $P(O|\lambda)$ ？

➤ 直接计算方法


- ◆ 直接计算可能的状态序列及相应观测值概率

$$P(O|\lambda) = \sum_Q P(O|Q, \lambda) P(Q|\lambda)$$

状态序列
马尔科夫链



观测序列



状态集 $S = \{s_1, s_2, \dots, s_N\}$ 观测符号集 $V = \{v_1, v_2, \dots, v_M\}$

基本问题1：评估观测序列的概率

评估：如何根据模型参数 λ 和给定 $O = \{O_1, O_2, \dots, O_T\}$ 计算 $P(O|\lambda)$ ？

➤ 直接计算方法

- ◆ 直接计算可能的状态序列及相应观测值概率


$$P(O|\lambda) = \sum_Q P(O, Q|\lambda) = \sum_Q P(O|Q, \lambda) P(Q|\lambda)$$

$$P(O|Q, \lambda) = \prod_{t=1}^T P(O_t|q_t, \lambda) = b_{q_1}(O_1) b_{q_2}(O_2) \cdots b_{q_T}(O_T)$$

$$P(Q|\lambda) = \pi_{q_1} a_{q_1 q_2} a_{q_2 q_3} \cdots a_{q_{t-1} q_t}$$

$$P(O, Q|\lambda) = P(O|Q, \lambda) P(Q|\lambda)$$

$$P(O|\lambda) = \sum_Q P(O|Q, \lambda) P(Q|\lambda) = \sum_{q_1, q_2, \dots, q_T} \pi_{q_1} b_{q_1}(O_1) a_{q_1 q_2} b_{q_2}(O_2) \cdots a_{q_{t-1} q_t} b_{q_t}(O_T)$$



计算复杂度为 $O(TN^T)$

基本问题1：评估观测序列的概率

评估：如何根据模型参数 λ 和给定 $O = \{O_1, O_2, \dots, O_T\}$ 计算 $P(O|\lambda)$ ？

$$\alpha_t(i) = P(O_1, O_2, \dots, O_t, q_t = s_i | \lambda) \quad 1 \leq t \leq T \quad \text{前向变量}$$

t 时刻由第 i 个状态 s_i 生成观测 O_t 且前时刻序列为 $O_1, O_2, \dots, O_{t-1}$ 的概率

$$\alpha_{t+1}(j) = P(O_1, O_2, \dots, O_t, O_{t+1}, q_{t+1} = s_j | \lambda)$$

$t+1$ 时刻由第 j 个状态 s_j 生成观测 O_{t+1} 且前时刻序列为 $O_1, O_2, \dots, O_t$ 的概率

齐次马尔科夫性 观测序列独立性

$$\begin{aligned} \alpha_{t+1}(j) &= \sum_{i=1}^N \underbrace{P(O_1, O_2, \dots, O_t, q_t = s_i | \lambda)}_{\alpha_t(i)} \underbrace{P(q_{t+1} = s_j | q_t = s_i, \lambda)}_{a_{ij}} \underbrace{P(O_{t+1} | q_{t+1} = s_j, \lambda)}_{b_j(O_{t+1})} \\ &= \left[\sum_{i=1}^N \alpha_t(i) a_{ij} \right] b_j(O_{t+1}), 1 \leq j \leq N, 1 \leq t \leq T-1 \end{aligned}$$

基本问题1：评估观测序列的概率

评估：如何根据模型参数 λ 和给定 $O = \{O_1, O_2, \dots, O_T\}$ 计算 $P(O|\lambda)$ ？

➤ 前向法：

◆ 采用前向变量 $\alpha_t(i) = P(O_1, \dots, O_t, q_t = s_i | \lambda)$

– 初始化：

$$\alpha_1(i) = \pi_i b_i(O_1) \quad 1 \leq i \leq N$$

$t = 1$ 时刻由第 i 个状态生成观测 O_1 的概率

– 递归： $t = 1, \dots, T - 1$

$$\alpha_{t+1}(j) = \left[\sum_{i=1}^N \alpha_t(i) a_{ij} \right] b_j(O_{t+1}), 1 \leq j \leq N, 1 \leq t \leq T - 1$$


– 终止：

$$P(O|\lambda) = \sum_{i=1}^N \alpha_T(i)$$

基本问题1：评估观测序列的概率


评估：如何根据模型参数 λ 和给定 $O = \{O_1, O_2, \dots, O_T\}$ 计算 $P(O|\lambda)$ ？

$$\alpha_{t+1}(j) = \left[\sum_{i=1}^N \alpha_t(i) a_{ij} \right] b_j(O_{t+1}), 1 \leq j \leq N, 1 \leq t \leq T-1$$



基本问题1：评估观测序列的概率

➤ 示例：HMM模型如下，初始概率矩阵 $\pi=(1,0,0)$ ；试根据前向算法计算产生观察符号序列 $O=\{ABAB\}$ 的概率。



A: 0.7 A: 0.4 A: 0.8

B: 0.3 B: 0.6 B: 0.2


———> 观察序列集 $O=\{A,B\}$

基本问题1：评估观测序列的概率

➤ 示例(续)：初始概率矩阵 $\pi=(1,0,0)$,即开始处于状态1。按照前向算法公式，我们依次递推解出 $\alpha_t(i)$ 。解法如下：

1.当 $t=1$ 时：

$$\alpha_1(1) = \pi_1 * b_1(A) = 1 * 0.7 = 0.7$$



A: 0.7 A:0.4 A:0.8

B:0.3 B:0.6 B:0.2

O={ABAB}


基本问题1：评估观测序列的概率

示例(续)：

2. 当 $t=2$ 时：

$$\alpha_2(1) = \alpha_1(1) * a_{11} * b_1(B) = 0.7 * 0.4 * 0.3 = 0.084 \leftarrow$$

$$\alpha_2(2) = \alpha_1(1) * a_{12} * b_2(B) = 0.7 * 0.6 * 0.6 = 0.252 \leftarrow$$



A: 0.7 A: 0.4 A: 0.8

B: 0.3 B: 0.6 B: 0.2

$O = \{ABAB\}$

3. 当 $t=3$ 时：

$$\alpha_3(1) = \alpha_2(1) * a_{11} * b_1(A) = 0.084 * 0.4 * 0.7 = 0.02352 \leftarrow$$

$$\alpha_3(2) = [\alpha_2(1) * a_{12} + \alpha_2(2) * a_{22}] * b_2(A) = [0.084 * 0.6 + 0.252 * 0.8] * 0.4 = 0.1008 \leftarrow$$

$$\alpha_3(3) = \alpha_2(2) * a_{23} * b_3(A) = 0.252 * 0.2 * 0.8 = 0.04032 \leftarrow$$

基本问题1： 评估观测序列的概率

示例(续)：


4. 当 $t=4$ 时：

$$\alpha_4(1) = \alpha_3(1) * a_{11} * b_1(B) = 0.02352 * 0.4 * 0.3 = 0.0028224 \leftarrow$$

$O=\{ABAB\}$

$$\alpha_4(2) = [\alpha_3(1) * a_{12} + \alpha_3(2) * a_{22}] * b_2(B) = [0.02352 * 0.6 + 0.1008 * 0.8] * 0.6 = 0.0568512$$

$$\alpha_4(3) = [\alpha_3(2) * a_{23} + \alpha_3(3) * a_{33}] * b_3(B) = [0.1008 * 0.2 + 0.04032 * 1] * 0.2 = 0.012096 \leftarrow$$



A: 0.7 A: 0.4 A: 0.8

B: 0.3 B: 0.6 B: 0.2


所以最终有：

$$P(O | \lambda) = \alpha_4(1) + \alpha_4(2) + \alpha_4(3) = 0.0717696$$

即观察序列O由HMM模型 λ 产生的概率

基本问题1：评估观测序列的概率

➤ 示例(续)：最后将其计算过程示意图表示如下：



基本问题1：评估观测序列的概率


➤ 示例：HMM模型如下，初始概率矩阵 $\pi=(1,0,0)$ ；试根据前向算法计算产生观察符号序列 $O=\{ABAB\}$ 的概率。

状态转移概率矩阵

$$\begin{array}{c} S_1 \\ S_2 \\ S_3 \end{array} \begin{array}{ccc} S_1 & S_2 & S_3 \\ \begin{bmatrix} 0.4 & 0.6 & 0 \\ 0 & 0.8 & 0.2 \\ 0 & 0 & 1 \end{bmatrix} \end{array}$$

观测概率矩阵

$$\begin{array}{c} S_1 \\ S_2 \\ S_3 \end{array} \begin{array}{cc} A & B \\ \begin{bmatrix} 0.7 & 0.3 \\ 0.4 & 0.6 \\ 0.8 & 0.2 \end{bmatrix} \end{array}$$



$$\pi = \begin{array}{c} S_1 \\ S_2 \\ S_3 \end{array} \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}$$

基本问题1：评估观测序列的概率

➤ 示例：HMM模型如下，初始概率矩阵 $\pi=(1,0,0)$ ；试根据前向算法计算产生观察符号序列 $O=\{ABAB\}$ 的概率。

解答： $t = 1$ $\alpha_1(i) = \pi_i b_i(O_1)$

$$\alpha_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} \star \begin{bmatrix} 0.7 \\ 0.4 \\ 0.8 \end{bmatrix} = \begin{bmatrix} 0.7 \\ 0 \\ 0 \end{bmatrix}$$

$$\pi = \begin{matrix} S_1 \\ S_2 \\ S_3 \end{matrix} \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}$$

	A	B
S_1	0.7	0.3
S_2	0.4	0.6
S_3	0.8	0.2

基本问题1：评估观测序列的概率

➤ 示例：HMM模型如下，初始概率矩阵 $\pi=(1,0,0)$ ；试根据前向算法计算产生观察符号序列 $O=\{ABAB\}$ 的概率。

解答： $t = 2$ $\alpha_{t+1}(j) = \left[\sum_{i=1}^N \alpha_t(i) a_{ij} \right] b_j(O_{t+1}), 1 \leq j \leq N, 1 \leq t \leq T-1$

$$\alpha_2: \begin{bmatrix} 0.7 \\ 0 \\ 0 \end{bmatrix} \begin{bmatrix} 0.4 & 0.6 & 0 \\ 0 & 0.8 & 0.2 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 0.28 & 0.42 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

$$\begin{bmatrix} 0.28 \\ 0.42 \\ 0 \end{bmatrix} \begin{bmatrix} 0.3 \\ 0.6 \\ 0.2 \end{bmatrix} = \begin{bmatrix} 0.084 \\ 0.252 \\ 0 \end{bmatrix}$$

基本问题1：评估观测序列的概率

➤ 示例：HMM模型如下，初始概率矩阵 $\pi=(1,0,0)$ ；试根据前向算法计算产生观察符号序列 $O=\{ABAB\}$ 的概率。

解答： $t = 3$ $\alpha_{t+1}(j) = \left[\sum_{i=1}^N \alpha_t(i) a_{ij} \right] b_j(O_{t+1}), 1 \leq j \leq N, 1 \leq t \leq T-1$

$$\alpha_3: \begin{bmatrix} 0.084 \\ 0.252 \\ 0 \end{bmatrix} \star \begin{bmatrix} 0.4 & 0.6 & 0 \\ 0 & 0.8 & 0.2 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 0.0336 \\ 0 \\ 0 \end{bmatrix} \begin{bmatrix} 0.0504 \\ 0.2016 \\ 0 \end{bmatrix} \begin{bmatrix} 0 \\ 0.0504 \\ 0 \end{bmatrix}$$

$[0.0336 \quad 0.2520 \quad 0.0504]$

$$\begin{bmatrix} 0.0336 \\ 0.2520 \\ 0.0504 \end{bmatrix} \star \begin{bmatrix} 0.7 \\ 0.4 \\ 0.8 \end{bmatrix} = \begin{bmatrix} 0.02352 \\ 0.1008 \\ 0.04032 \end{bmatrix}$$

基本问题1：评估观测序列的概率

➤ 示例：HMM模型如下，初始概率矩阵 $\pi=(1,0,0)$ ；试根据前向算法计算产生观察符号序列 $O=\{ABAB\}$ 的概率。

解答： $t = 4$ $\alpha_{t+1}(j) = \left[\sum_{i=1}^N \alpha_t(i) a_{ij} \right] b_j(O_{t+1}), 1 \leq j \leq N, 1 \leq t \leq T-1$

$\alpha_4:$

0.02352		0.4	0.6	0
0.1008	★	0	0.8	0.2
0.04032		0	0	1

 =

0.009408	0.014112	0
0	0.08064	0.02016
0	0	0.04032

[0.009408 0.094752 0.06048]

0.009408		0.3
0.094752	★	0.6
0.06048		0.2

 =

0.0028224
0.0568512
0.012096

$P(O|\lambda) = \sum_{i=1}^N \alpha_T(i)$

基本问题1：评估观测序列的概率

➤ 示例：HMM模型如下，初始概率矩阵 $\pi=(1,0,0)$ ；试根据前向算法计算产生观察符号序列 $O=\{ABAB\}$ 的概率。

解答： $t = 4$

$$\alpha_4 = \begin{bmatrix} 0.0028224 \\ 0.0568512 \\ 0.012096 \end{bmatrix}$$

$$P(O|\lambda) = \sum_{i=1}^N \alpha_T(i)$$

$$P(O|\lambda) = \sum_{i=1}^N \alpha_T(i) = 0.0028224 + 0.0568512 + 0.012096 = 0.0717696$$

基本问题1：评估观测序列的概率

评估：如何根据模型参数 λ 和给定 $O = \{O_1, O_2, \dots, O_T\}$ 计算 $P(O|\lambda)$ ？

$$\beta_{t+1}(j) = P(O_{t+2}O_{t+3} \cdots O_T | q_{t+1} = s_j, \lambda) \quad 1 \leq t \leq T-1$$

$$\beta_t(i) = P(O_{t+1}O_{t+2} \cdots O_T | q_t = s_i, \lambda)$$

后向变量

t 时刻在第 i 个状态的条件下， $t+1$ 到 T 的观测序列为 $O_{t+1}, O_{t+2}, \dots, O_T$ 的概率

齐次马尔科夫性 观测序列独立性

$$\begin{aligned} \beta_t(i) &= \sum_{j=1}^N P(\underbrace{O_{t+2}O_{t+3} \cdots O_T}_{\beta_{t+1}(j)} | \underbrace{q_{t+1} = s_j}_{a_{ij}} | \underbrace{q_t = s_i}_{b_j(O_{t+1})}, \lambda) P(q_{t+1} = s_j | q_t = s_i, \lambda) P(O_{t+1} | q_{t+1} = s_j, \lambda) \\ &= \sum_{j=1}^N \beta_{t+1}(j) a_{ij} b_j(O_{t+1}), 1 \leq j \leq N, 1 \leq t \leq T-1 \end{aligned}$$

基本问题1：评估观测序列的概率

评估：如何根据模型参数 λ 和给定 $O = \{O_1, O_2, \dots, O_T\}$ 计算 $P(O|\lambda)$ ？

➤ 后向法：

◆ 采用后向变量 $\beta_t(i) = P(O_{t+1}O_{t+2}\cdots O_T | q_t = s_i, \lambda)$

– 初始化：


$$\beta_T(i) = 1, 1 \leq i \leq N$$

– 递归：

$$\beta_t(i) = \sum_{j=1}^N \beta_{t+1}(j) a_{ij} b_j(O_{t+1}), 1 \leq i \leq N, 1 \leq t \leq T-1$$

– 终止：

$$P(O|\lambda) = \sum_{i=1}^N \pi_i b_i(O_1) \beta_1(i)$$



基本问题2：解码最佳状态序列

解码问题： 如何根据给定的 O 和 λ 计算最优路径 Q^* ?

➤ 对于给定模型 λ 和观察值序列 O ，求可能性最大(最大似然)的状态序列

独立选择最大似然的状态

$$\gamma_t(i) = P(q_t = s_i | O, \lambda) = \frac{\alpha_t(i) \beta_t(i)}{\sum_{i=1}^N \alpha_t(i) \beta_t(i)}$$

$$q_t = \arg \max_{1 \leq i \leq N} \gamma_i(t), 1 \leq t \leq T$$



基本问题2：解码最佳状态序列

解码问题： 如何根据给定的 O 和 λ 计算最优路径 Q^* ？

- 对于给定模型 λ 和观察值序列 O ，求可能性最大(最大似然)的状态序列
- **联合似然概率最大化：** 每一时刻状态序列出现相应观测值的可能达到最大

$$\max_{q_1, q_2, \dots, q_T} P(q_1, q_2, \dots, q_T, O_1, O_2, \dots, O_T | \lambda)$$

Viterbi算法：动态规划

思想：记录 t 时刻出现状态 i 的最大可能路径及其对应概率


$$\delta_t(i) = \max_{q_1, q_2, \dots, q_{t-1}} P(q_1, q_2, \dots, q_t = i, O_1, O_2, \dots, O_t | \lambda)$$

最大局部概率： t 时刻出现状态 i 的最大概率

基本问题2：解码最佳状态序列

解码：如何根据给定的 O 和 λ 计算最优路径 Q^* ？

引子：动态规划求解最优路径问题




如果从 S_0 到 S_3^2 的最优路径经过节点 S_2^1 ，那么该路径中必然包含从 S_0 到 S_2^1 的最优路径。

随着层的推进，逐步记录到每层各节点的最优路径，那么到最后一层时仅需考虑到前一层各节点的最优路径损耗+前层各节点到终点的损耗中最小的，依此反推。

基本问题2：解码最佳状态序列

解码：如何根据给定的 O 和 λ 计算最优路径 Q^* ?

引子：动态规划求解最优路径问题



第1步： $S_0 \rightarrow S_1$
 $\left\{ \begin{array}{l} S_0 \rightarrow S_1^1 \\ S_0 \rightarrow S_1^2 \\ S_0 \rightarrow S_1^3 \end{array} \right\}$

第2步： $S_0 \rightarrow S_2$
 $\left\{ \begin{array}{l} S_0 \rightarrow S_1^2 \rightarrow S_2^1 \\ S_0 \rightarrow S_1^1 \rightarrow S_2^2 \\ S_0 \rightarrow S_1^3 \rightarrow S_2^3 \end{array} \right\}$

第3步： $S_0 \rightarrow S_3$
 $\left\{ \begin{array}{l} S_0 \rightarrow S_1^2 \rightarrow S_2^1 \rightarrow S_3^1 \\ S_0 \rightarrow S_1^2 \rightarrow S_2^1 \rightarrow S_3^2 \\ S_0 \rightarrow S_1^1 \rightarrow S_2^2 \rightarrow S_3^2 \end{array} \right\}$

...

基本问题2：解码最佳状态序列

解码问题：如何根据给定的 O 和 λ 计算最优路径 Q^* ？

➤ **Viterbi算法**： $\delta_t(i) = \max_{q_1, q_2, \dots, q_{t-1}} P(q_1, q_2, \dots, q_t = i, O_1, O_2, \dots, O_t | \lambda)$

-**初始化**： $\delta_1(i) = \pi_i b_i(O_1), \quad 1 \leq i \leq N$
 $\varphi_1(i) = 0, \quad 1 \leq i \leq N$

-**递归**： $\delta_t(j) = \max_{1 \leq i \leq N} [\delta_{t-1}(i) a_{ij}] b_j(O_t), \quad 2 \leq t \leq T, 1 \leq j \leq N$
 $\varphi_t(j) = \arg \max_{1 \leq i \leq N} [\delta_{t-1}(i) a_{ij}], \quad 2 \leq t \leq T, 1 \leq j \leq N$

-**终止**： $P^* = \max_{1 \leq i \leq N} [\delta_T(i)], \quad q_T^* = \arg \max_{1 \leq i \leq N} [\delta_T(i)]$

-**求S序列**： $q_t^* = \varphi_{t+1}(q_{t+1}^*), \quad t = T-1, T-2, \dots, 1$

转移概率 a_{ij} 与上一步最大局部概率 $\delta_{t-1}(i)$ 之积，记录下其中最大的一个

$\varphi_t(j)$ 代表的是 t 时刻为状态 j 对应的前时刻 $t-1$ 状态；与 O_t 无关

基本问题2：解码最佳状态序列


解码：如何根据给定的 O 和 λ 计算最优路径 Q^* ？

➤ **Viterbi算法**: $\delta_t(i) = \max_{q_1, q_2, \dots, q_{t-1}} P(q_1, q_2, \dots, q_t = i, O_1, O_2, \dots, O_t | \lambda)$

-**初始化**: $\delta_1(i) = \pi_i b_i(O_1), \quad 1 \leq i \leq N$
 $\varphi_1(i) = 0, \quad 1 \leq i \leq N$

初始时刻，路径尚未开始

初始时刻，节点局部概率为
初始时刻在状态 i 发射观测符号 O_1 的概率




基本问题2：解码最佳状态序列

解码：如何根据给定的 O 和 λ 计算最优路径 Q^* ？

➤ **Viterbi算法**: $\delta_t(i) = \max_{q_1, q_2, \dots, q_{t-1}} P(q_1, q_2, \dots, q_t = i, O_1, O_2, \dots, O_t | \lambda)$

-迭代: $\delta_2(j) = \max_{1 \leq i \leq N} [\delta_1(i) a_{ij}] b_j(O_2), \quad 1 \leq j \leq N$

$\varphi_2(j) = \arg \max_{1 \leq i \leq N} [\delta_1(i) a_{ij}], \quad 1 \leq j \leq N$




$t = 2$, 以 $j = 1$ 为例, 到该节点的可能状态序列为 $\{1,1\}, \{2,1\}, \{3,1\}$, 选取这三种可能中出现概率最大的情况, 记录其出现概率以及对应路径, 假设是 $\{2,1\}$, 同时记录其到达的路径, 即前时刻 $t = 1$ 时状态为 2. 依此类推, 记录所有 j 对应的 δ_2 和 φ_2

基本问题2：解码最佳状态序列

解码：如何根据给定的 O 和 λ 计算最优路径 Q^* ？

➤ **Viterbi算法**: $\delta_t(i) = \max_{q_1, q_2, \dots, q_{t-1}} P(q_1, q_2, \dots, q_t = i, O_1, O_2, \dots, O_t | \lambda)$

-迭代: $\delta_3(j) = \max_{1 \leq i \leq N} [\delta_2(i) a_{ij}] b_j(O_3), \quad 1 \leq j \leq N$
 $\varphi_3(j) = \arg \max_{1 \leq i \leq N} [\delta_2(i) a_{ij}], \quad 1 \leq j \leq N$



$t = 3$, 以 $j = 3$ 为例, 到该节点的可能状态序列有 N^2 种, 分别为 $\{1,1,3\}, \{1,2,3\}, \dots$ 。假设到该节点的最优路径在 $t = 2$ 时刻为状态1, 则其在 $t = 1, 2$ 时刻的子状态序列必然对应于 $\delta_2(1)$ 和 $\{\varphi_2(1), \varphi_3(3)\} = \{2, 1\}$. 反之, 如果不是, 那么使用 $\{\varphi_2(1), \varphi_3(3)\}$ 代替该段子路径则出现概率更大, 依此类推...


$(S^3_t) \dots (S^3_T)'$

基本问题2：解码最佳状态序列

解码：如何根据给定的 O 和 λ 计算最优路径 Q^* ？

➤ **Viterbi算法**: $\delta_t(i) = \max_{q_1, q_2, \dots, q_{t-1}} P(q_1, q_2, \dots, q_t = i, O_1, O_2, \dots, O_t | \lambda)$

-迭代: $\delta_3(j) = \max_{1 \leq i \leq N} [\delta_2(i) a_{ij}] b_j(O_3), \quad 1 \leq j \leq N$
 $\varphi_3(j) = \arg \max_{1 \leq i \leq N} [\delta_2(i) a_{ij}], \quad 1 \leq j \leq N$



到 $t = 3$ 时刻到达 j 节点的最优路径(状态序列)仅考虑 $t = 2$ 时刻最大局部概率 $\delta_2(i)$ 和转移概率 a_{ij} 的乘积, 其最大值对应状态 i 结合 $\varphi_2(i)$ 构成到 j 节点的最优路径; 该乘积最大值乘以 j 节点发射状态 O_3 的概率即为 $\delta_3(j)$


基本问题2：解码最佳状态序列

解码：如何根据给定的 O 和 λ 计算最优路径 Q^* ？

➤ **Viterbi算法**: $\delta_t(i) = \max_{q_1, q_2, \dots, q_{t-1}} P(q_1, q_2, \dots, q_t = i, O_1, O_2, \dots, O_t | \lambda)$

-迭代: $\delta_t(j) = \max_{1 \leq i \leq N} [\delta_{t-1}(i) a_{ij}] b_j(O_t), \quad 2 \leq t \leq T, 1 \leq j \leq N$

如果最优路径在 t 时刻到达节点 j ，则从起始时刻到达到该节点的最优路径对应 $\delta_{t-1}(i)$ 和 a_{ij} 乘积的最小值，并包含从1到 $t-1$ 的到达节点 i 的最优路径。



基本问题2：解码最佳状态序列


解码：如何根据给定的 O 和 λ 计算最优路径 Q^* ？

➤ **Viterbi算法**: $\delta_t(i) = \max_{q_1, q_2, \dots, q_{t-1}} P(q_1, q_2, \dots, q_t = i, O_1, O_2, \dots, O_t | \lambda)$

-终止: $P^* = \max_{1 \leq i \leq N} [\delta_T(i)]$

$q_T^* = \arg \max_{1 \leq i \leq N} [\delta_T(i)]$

$\delta_T(i)$ 对应最大值即为全局最优路径 Q^* 出现概率，即为联合似然概率最大值； q_T^* 为最优路径在 T 时刻状态，结合 φ 从 $T-1$ 时刻到1时刻反向推演可以获取最优路径。



基本问题2：解码最佳状态序列

- 示例：考虑如下HMM，状态集为 $\{H, C, W\}$ ，观测集为 $\{R, B\}$ 。HMM的参数如下。请问观测 $O = (R, B, R)$ 对应的最大似然状态序列？

$$\pi = \begin{matrix} & H & C & W \\ \begin{matrix} H \\ C \\ W \end{matrix} & \begin{bmatrix} 0.3 & 0.3 & 0.4 \end{bmatrix} \end{matrix} \quad A = \begin{matrix} & H & C & W \\ \begin{matrix} H \\ C \\ W \end{matrix} & \begin{bmatrix} 0.5 & 0.1 & 0.4 \\ 0.2 & 0.5 & 0.3 \\ 0.3 & 0.2 & 0.5 \end{bmatrix} \end{matrix} \quad B = \begin{matrix} & R & B \\ \begin{matrix} H \\ C \\ W \end{matrix} & \begin{bmatrix} 0.7 & 0.3 \\ 0.4 & 0.6 \\ 0.5 & 0.5 \end{bmatrix} \end{matrix}$$

- 解答：初始化 $t = 1$

$$\begin{aligned} \delta_1(i) &= \pi_i b_i(O_1), \quad 1 \leq i \leq N \\ \varphi_1(i) &= 0, \quad 1 \leq i \leq N \end{aligned} \quad \delta_1 = \begin{bmatrix} 0.3 \\ 0.3 \\ 0.4 \end{bmatrix} \star \begin{bmatrix} 0.7 \\ 0.4 \\ 0.5 \end{bmatrix} = \begin{bmatrix} 0.21 \\ 0.12 \\ 0.2 \end{bmatrix} \quad \varphi_1 = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

基本问题2：解码最佳状态序列

➤ 示例：考虑如下HMM，状态集为 $\{H, C, W\}$ ，观测集为 $\{R, B\}$ 。HMM的参数如下。请问观测 $O = (R, B, R)$ 对应的最大似然状态序列？

$$\pi = \begin{matrix} & H & C & W \\ \begin{matrix} H \\ C \\ W \end{matrix} & \begin{bmatrix} 0.3 & 0.3 & 0.4 \end{bmatrix} \end{matrix}$$

$$A = \begin{matrix} & H & C & W \\ \begin{matrix} H \\ C \\ W \end{matrix} & \begin{bmatrix} 0.5 & 0.1 & 0.4 \\ 0.2 & 0.5 & 0.3 \\ 0.3 & 0.2 & 0.5 \end{bmatrix} \end{matrix}$$

$$B = \begin{matrix} & R & B \\ \begin{matrix} H \\ C \\ W \end{matrix} & \begin{bmatrix} 0.7 & 0.3 \\ 0.4 & 0.6 \\ 0.5 & 0.5 \end{bmatrix} \end{matrix}$$

➤ 解答： $t = 2$

$$\delta_t(j) = \max_{1 \leq i \leq N} [\delta_{t-1}(i) a_{ij}] b_j(O_t)$$

$$\varphi_t(j) = \arg \max_{1 \leq i \leq N} [\delta_{t-1}(i) a_{ij}]$$

$$\delta_1 \begin{matrix} & H & C & W \\ \begin{bmatrix} 0.21 \\ 0.12 \\ 0.2 \end{bmatrix} & \begin{bmatrix} 0.5 & 0.1 & 0.4 \\ 0.2 & 0.5 & 0.3 \\ 0.3 & 0.2 & 0.5 \end{bmatrix} \end{matrix} = \begin{matrix} & R & B \\ \begin{bmatrix} 0.105 \\ 0.024 \\ 0.06 \end{bmatrix} & \begin{bmatrix} 0.021 & 0.084 \\ 0.06 & 0.036 \\ 0.04 & 0.1 \end{bmatrix} \end{matrix}$$

取每列最大值

$$\delta_2 = \begin{bmatrix} 0.105 \\ 0.06 \\ 0.1 \end{bmatrix} \star \begin{bmatrix} 0.3 \\ 0.6 \\ 0.5 \end{bmatrix} = \begin{bmatrix} 0.0315 \\ 0.036 \\ 0.05 \end{bmatrix} \quad \varphi_2 = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \begin{matrix} H \\ C \\ W \end{matrix}$$

基本问题2：解码最佳状态序列

➤ 示例：考虑如下HMM，状态集为{H,C,W}，观测集为{R,B}。HMM的参数如下。请问观测O = (R,B,R)对应的最大似然状态序列？

$$\pi = \begin{matrix} & H & C & W \\ \begin{matrix} H \\ C \\ W \end{matrix} & \begin{bmatrix} 0.3 & 0.3 & 0.4 \end{bmatrix} \end{matrix}$$
$$A = \begin{matrix} & H & C & W \\ \begin{matrix} H \\ C \\ W \end{matrix} & \begin{bmatrix} 0.5 & 0.1 & 0.4 \\ 0.2 & 0.5 & 0.3 \\ 0.3 & 0.2 & 0.5 \end{bmatrix} \end{matrix}$$
$$B = \begin{matrix} & R & B \\ \begin{matrix} H \\ C \\ W \end{matrix} & \begin{bmatrix} 0.7 & 0.3 \\ 0.4 & 0.6 \\ 0.5 & 0.5 \end{bmatrix} \end{matrix}$$

➤ 解答： t = 3

$$\delta_t(j) = \max_{1 \leq i \leq N} [\delta_{t-1}(i) a_{ij}] b_j(O_t)$$
$$\varphi_t(j) = \arg \max_{1 \leq i \leq N} [\delta_{t-1}(i) a_{ij}]$$

$$\delta_2$$

0.0315	0.5	0.1	0.4
0.036	0.2	0.5	0.3
0.05	0.3	0.2	0.5

取每列最大值

0.01575	0.00315	0.0126
0.0072	0.018	0.0108
0.015	0.01	0.025

$$\delta_3 = \begin{bmatrix} 0.01575 \\ 0.018 \\ 0.025 \end{bmatrix} \star \begin{bmatrix} 0.7 \\ 0.4 \\ 0.5 \end{bmatrix} = \begin{bmatrix} 0.011025 \\ 0.0072 \\ 0.0125 \end{bmatrix}$$
$$\varphi_3 = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \begin{matrix} H \\ C \\ W \end{matrix}$$

基本问题2：解码最佳状态序列

- 示例：考虑如下HMM，状态集为 $\{H, C, W\}$ ，观测集为 $\{R, B\}$ 。HMM的参数如下。请问观测 $O = (R, B, R)$ 对应的最大似然状态序列？

$$\pi = \begin{matrix} & H & C & W \\ \begin{matrix} H & C & W \end{matrix} & \begin{bmatrix} 0.3 & 0.3 & 0.4 \end{bmatrix} \end{matrix}$$
$$A = \begin{matrix} & H & C & W \\ \begin{matrix} H \\ C \\ W \end{matrix} & \begin{bmatrix} 0.5 & 0.1 & 0.4 \\ 0.2 & 0.5 & 0.3 \\ 0.3 & 0.2 & 0.5 \end{bmatrix} \end{matrix}$$
$$B = \begin{matrix} & R & B \\ \begin{matrix} H \\ C \\ W \end{matrix} & \begin{bmatrix} 0.7 & 0.3 \\ 0.4 & 0.6 \\ 0.5 & 0.5 \end{bmatrix} \end{matrix}$$

➤ 解答：

$$P^* = \max_{1 \leq i \leq N} [\delta_T(i)],$$

$$q_T^* = \arg \max_{1 \leq i \leq N} [\delta_T(i)]$$

取最大值

$$\delta_3 = \begin{bmatrix} 0.011025 \\ 0.0072 \\ 0.0125 \end{bmatrix}$$

$$q_3 = W$$

基本问题2：解码最佳状态序列

- 示例：考虑如下HMM，状态集为 $\{H, C, W\}$ ，观测集为 $\{R, B\}$ 。HMM的参数如下。请问观测 $O = (R, B, R)$ 对应的最大似然状态序列？

$$\pi = \begin{matrix} & H & C & W \\ \begin{matrix} H \\ C \\ W \end{matrix} & \begin{bmatrix} 0.3 & 0.3 & 0.4 \end{bmatrix} \end{matrix} \quad A = \begin{matrix} & H & C & W \\ \begin{matrix} H \\ C \\ W \end{matrix} & \begin{bmatrix} 0.5 & 0.1 & 0.4 \\ 0.2 & 0.5 & 0.3 \\ 0.3 & 0.2 & 0.5 \end{bmatrix} \end{matrix} \quad B = \begin{matrix} & R & B \\ \begin{matrix} H \\ C \\ W \end{matrix} & \begin{bmatrix} 0.7 & 0.3 \\ 0.4 & 0.6 \\ 0.5 & 0.5 \end{bmatrix} \end{matrix}$$

➤ 解答：

$$q_t^* = \varphi_{t+1}(q_{t+1}^*), t = T-1, T-2, \dots, 1$$

$$q_3 = W$$

$$\varphi_3 = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}$$

$$q_2 = \varphi_3(W) = W$$

$$q_1 = \varphi_2(W) = W$$

$$\varphi_2 = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}$$

因此观测 $O = (R, B, R)$ 对应的最大似然状态序列为 $Q = (q_1 q_2 q_3) = (WWW)$

基本问题3：学习模型参数问题

学习：如何根据观测序列样本集合 O_{training} 进行模型 $\lambda = (A, B, \pi)$ 的参数估计？

- 目标：求 $\lambda=(A,B,\pi)$, 使 $P(O|\lambda)$ 最大化
- **Baum-Welch算法** 是一种EM算法, 即从不完整数据（样本特征序列与隐含状态序列的对齐关系未知）求解模型参数的最大似然估计方法：
 - ◆ 初始化HMM参数 λ_0 ;
 - ◆ **E步(Expectation)**: 利用给定的HMM参数求样本特征序列的状态对齐结果;
 - ◆ **M步(Maximization)**: 根据上一步的状态对齐结果, 利用最大似然估计更新HMM参数 λ ;
 - ◆ 重复E步、M步, 直到算法收敛:

$$\log P(O | \lambda_{\tau+1}) - \log P(O | \lambda_{\tau}) < threshold$$


Baum-Welch算法

$$\alpha_t(i) = P(O_1, \dots, O_t, q_t = s_i | \lambda)$$
$$\beta_t(i) = P(O_{t+1} O_{t+2} \cdots O_T | q_t = s_i, \lambda)$$

➤ 给定模型 λ 和观测序列条件下:

◆ 定义从状态 i 到 j 的转移概率

$$\xi_t(i, j) = P(q_t = i, q_{t+1} = j | O, \lambda)$$
$$= \frac{\alpha_t(i) a_{ij} b_j(O_{t+1}) \beta_{t+1}(j)}{\sum_{i=1}^N \sum_{j=1}^N \alpha_t(i) a_{ij} b_j(O_{t+1}) \beta_{t+1}(j)}$$



$$\gamma_t(i) = \sum_{j=1}^N \xi_t(i, j) = P(q_t = i | O, \lambda) \quad t \text{时刻处于状态 } s_i \text{ 的概率}$$

$$\sum_{t=1}^{T-1} \gamma_t(i) = \text{整个过程中从状态 } s_i \text{ 转出的次数的预期}$$

$$\sum_{t=1}^{T-1} \xi_t(i, j) = \text{整个过程中从状态 } s_i \text{ 跳转至状态 } s_j \text{ 的次数的预期}$$

Baum-Welch算法(续)

➤ 重估公式

$$\hat{a}_{ij} = \frac{\text{expected count of transitions from } i \text{ to } j}{\text{expected count of stays at } i}$$

$$= \frac{\sum_t \xi_t(i, j)}{\sum_t \sum_j \xi_t(i, j)}$$

$$\hat{b}_j(k) = \frac{\text{expected number of times in state } j \text{ and observe symbol } k}{\text{expected number of times in state } j}$$

$$= \frac{\sum_{t, O_t=k} \gamma_t(j)}{\sum_t \gamma_t(j)}$$

$$\hat{\pi}_i = \gamma_1(i) \quad t = 1 \text{ 时刻处于状态 } s_i \text{ 的概率}$$

$$\begin{aligned} \alpha_t(i) &= P(O_1, \dots, O_t, q_t = s_i | \lambda) \\ \beta_t(i) &= P(O_{t+1} O_{t+2} \cdots O_T | q_t = s_i, \lambda) \\ \xi_t(i, j) &= P(q_t = s_i, q_{t+1} = s_j | O, \lambda) \\ &= \frac{\alpha_t(i) a_{ij} b_j(O_{t+1}) \beta_{t+1}(i)}{\sum_{j=1}^N \sum_{i=1}^N \alpha_t(i) a_{ij} b_j(O_{t+1}) \beta_{t+1}(i)} \\ \gamma_t(i) &= \sum_{j=1}^N \xi_t(i, j) = P(q_t = i | O, \lambda) \end{aligned}$$

直观：如果状态序列已知，那么如何评估 a_{ij} 和 b_{jk} ？

形式：利用从状态 i 转移到状态 j 的频次作为 a_{ij} 的估计值；利用从状态 j 产生观测 k 的频次作为 b_{jk} 的估计值。

7.4.4 HMM应用：自然语言处理

➤ 基于GMM-HMM的语音识别

- ◆ 输入语音信号 X
- ◆ 输出由字词组成的文字序列 W






The sound of ...

$$W^* = \arg \max_W P(W|X)$$


$$W^* = \arg \max_W \frac{P(X|W)P(W)}{P(X)} = \arg \max_W \underbrace{P(X|W)}_{\text{Acoustic Model}} \underbrace{P(W)}_{\text{Language Model}}$$

➤ 声学模型：GMM-HMM




➤ 语言模型：N-gram


7.4.4 HMM应用：手写文字识别



7.4.4 HMM应用：手写文字识别




7.4.4 HMM应用：手写文字识别




training data set

<rar>



**
**




<brother>



⋮

7.4.4 HMM应用：2D/3D Talking Head



- Small training set (<30 minutes video recording)
- Fully automatic, data driven statistical modeling, real sample rendering
- Lip-sync with natural or TTS synthesized speech



第7讲 模式识别基础

7.1 基本概念


7.2 特征提取与变换

7.3 贝叶斯决策


7.4 参数估计方法

7.5 模式识别系统


7.5 模式识别系统




例如：摄像机、麦克风阵列传感器
因素：带宽、灵敏度、失真、信噪比、延迟等等



7.5 模式识别系统



例如：传感器的感兴趣基元文本切割、脑电波的时长等等
关注部分与整体关系





7.5 模式识别系统

类内一致性：来自同一类别的不同样本特征值相近

类间差异性：来自不同类别的样本特征值有很大差异
表征能力、鉴别性、特征维度

例如：基于深度神经网络的特征表征学习






7.5 模式识别系统

根据特征提取器提取的特征向量给被测试对象(样本)赋予类别标记

例如：贝叶斯决策(最小欧式/马氏距离分类器)、隐含马尔科夫模型


例如：支持向量机、感知器模型、
Logistic回归



7.5 模式识别系统

根据上下文信息对分类进行调整


上下文信息：
鱼在水里游
鸟在天空飞
人在地上走



7.5 模式识别系统



统计模式识别系统的一般流程

- 数据获取：信号空间
- 预处理
- 特征提取和选择：特征空间
- 分类决策：模式空间



7.5 模式识别系统：示例

➤ 人脸认证/识别



7.5 模式识别系统：示例

➤ 人脸认证/识别

◆ 第0步：数据准备

利用摄像头采集图像；

从网络等开放媒体搜集数据；

人工标注数据；

划分训练集、验证集和测试集



7.5 模式识别系统： 示例

➤ 人脸认证/识别


◆ 第0步： 数据准备

利用摄像头采集图像；

从网络等开放媒体搜集数据；

人工标注数据；

划分训练集、验证集和测试集



7.5 模式识别系统： 示例

➤ 人脸认证/识别

◆ 第0步： 数据准备

利用摄像头采集图像；

从网络等开放媒体搜集数据；

人工标注数据；

划分训练集、验证集和测试集



7.5 模式识别系统： 示例

➤ 人脸认证/识别

◆ 第0步： 数据准备

利用摄像头采集图像；
从网络等开放媒体搜集数据；
人工标注数据；
划分训练集、验证集和测试集

训练集



测试集



7.5 模式识别系统：示例

➤ 人脸认证/识别

◆ 第1步：特征提取

- 基于深度神经网络的特征表征学习

深度神经网络设计


卷积神经网络：

卷积层+池化层

全连接前馈神经网络：

全连接层

非线性激活函数



7.5 模式识别系统：示例

➤ 人脸认证/识别

◆ 第1步：特征提取

- 基于深度网络的特征表征学习

深度神经网络设计

典型卷积神经网络：ZFNet

layer	size-in	size-out	kernel	param	FLPS
conv1	220×220×3	110×110×64	7×7×3, 2	9K	115M
pool1	110×110×64	55×55×64	3×3×64, 2	0	
rnorm1	55×55×64	55×55×64		0	
conv2a	55×55×64	55×55×64	1×1×64, 1	4K	13M
conv2	55×55×64	55×55×192	3×3×64, 1	111K	335M
rnorm2	55×55×192	55×55×192		0	
pool2	55×55×192	28×28×192	3×3×192, 2	0	
conv3a	28×28×192	28×28×192	1×1×192, 1	37K	29M
conv3	28×28×192	28×28×384	3×3×192, 1	664K	521M
pool3	28×28×384	14×14×384	3×3×384, 2	0	
conv4a	14×14×384	14×14×384	1×1×384, 1	148K	29M
conv4	14×14×384	14×14×256	3×3×384, 1	885K	173M
conv5a	14×14×256	14×14×256	1×1×256, 1	66K	13M
conv5	14×14×256	14×14×256	3×3×256, 1	590K	116M
conv6a	14×14×256	14×14×256	1×1×256, 1	66K	13M
conv6	14×14×256	14×14×256	3×3×256, 1	590K	116M
pool4	14×14×256	7×7×256	3×3×256, 2	0	
concat	7×7×256	7×7×256		0	
fc1	7×7×256	1×32×128	maxout p=2	103M	103M
fc2	1×32×128	1×32×128	maxout p=2	34M	34M
fc7128	1×32×128	1×1×128		524K	0.5M
L2	1×1×128	1×1×128		0	
total				140M	1.6B

Table 1. NN1. This table show the structure of our Zeiler&Fergus [22] based model with 1×1 convolutions inspired by [9]. The input and output sizes are described in *rows × cols × #filters*. The kernel is specified as *rows × cols, stride* and the maxout [6] pooling size as *p = 2*.

7.5 模式识别系统：示例


➤ 人脸认证/识别

◆ 第1步：特征提取

- 基于深度网络的特征表征学习

深度神经网络设计

典型卷积神经网络：VGGNet





7.5 模式识别系统： 示例

➤ 人脸认证/识别


◆ 第1步：特征提取

- 基于深度网络的特征表征学习

特征提取网络训练



模型输出



真实标签

ID 1

损失函
数设计



$$L(y, \hat{y}), \hat{y} = h(\mathbf{x})$$

$$L_i = - \sum_l y_{il} \log(\hat{y}_{il})$$

7.5 模式识别系统：示例


➤ 人脸认证/识别

◆ 第1步：特征提取

- 基于深度网络的特征表征学习

更加复杂的网络设计

Siamese network



7.5 模式识别系统：示例



➤ 人脸认证/识别

◆ 第1步：特征提取

- 基于深度网络的特征表征学习

损失函数设计

特征提取网络训练



模型输出

d_i : 样本对
间的距离

$$d_i = \left\| f\left(\mathbf{x}_1^{(i)}\right) - f\left(\mathbf{x}_2^{(i)}\right) \right\|$$

真实标签

y_i : 是否属于同一
类别；例如：同一
人人脸 $y_i = 1$ ；不同
人人脸 $y_i = 0$

Contrastive Loss

$$L_i = \frac{1}{2} y_i d_i^2 + (1 - y_i) \max(\text{margin} - d_i, 0)^2$$


7.5 模式识别系统：示例

➤ 人脸认证/识别

◆ 第1步：特征提取

- 基于深度网络的特征表征学习

更更加复杂的网络设计



7.5 模式识别系统：示例



➤ 人脸认证/识别

◆ 第1步：特征提取

- 基于深度网络的特征表征学习

损失函数设计

特征提取网络训练



Triplet Loss

$$L_i = \left[\left\| f(x_i^a) - f(x_i^p) \right\|_2^2 - \left\| f(x_i^a) - f(x_i^n) \right\|_2^2 + \alpha \right]_+$$

7.5 模式识别系统： 示例


➤ 人脸认证/识别

◆ 第1步：特征提取

- 基于深度网络的特征表征学习




Representative Image



Neuron Inversion



Representative Image



Neuron Inversion

7.5 模式识别系统： 示例

➤ 人脸认证/识别

◆ 第1步：特征提取

- 基于深度网络的特征表征学习




Representative Image



Neuron Inversion



Representative Image





Neuron Inversion

7.5 模式识别系统：示例

➤ 人脸认证/识别

◆ 第1.1步：特征降维

- 例如：主成分分析




7.5 模式识别系统：示例

➤ 人脸认证/识别

◆ 第2步：分类器选取与训练

- 基于深度网络的分类决策

端到端的深度网络




7.5 模式识别系统：示例

➤ 人脸认证/识别

◆ 第2步：分类器选取与训练

- 其他分类决策方法

最小欧式距离分类器(贝叶斯决策)




7.5 模式识别系统：示例

➤ 人脸认证/识别

◆ 第2步：分类器选取与训练

- 其他分类决策方法

最小马式距离分类器(贝叶斯决策)




7.5 模式识别系统：示例

➤ 人脸认证/识别

◆ 第2步：分类器选取与训练

- 其他分类决策方法

线性分类器—Logistic回归




7.5 模式识别系统：示例

➤ 人脸认证/识别

◆ 第2步：分类器选取与训练

- 其他分类决策方法

线性分类器—Fisher线性判别




7.5 模式识别系统：示例

➤ 人脸认证/识别

◆ 第2步：分类器选取与训练

- 其他分类决策方法

线性分类器- 支持向量机



7.5 模式识别系统： 示例

➤ 人脸认证/识别


◆ 第3步： 分类决策

- 基于深度网络的分类决策


同一个人



VS



VS



VS



VS



7.5 模式识别系统： 示例

➤ 人脸认证/识别


◆ 第3步： 分类决策

- 基于深度网络的分类决策

不是同一个人





VS




VS



VS




VS



7.5 模式识别系统：示例

➤ 人脸认证/识别

◆ 第4步：系统部署



7.5 模式识别系统： 示例

➤ 人脸认证/识别

◆ 第4步： 系统部署



7.5.2 系统评价指标

➤ 错误率(error rate)与准确率(accuracy):

- ◆ 错误率：分类错误的样本占样本总数的比例
- ◆ 假设 N 个样本中有 a 个样本分类错误，则 $E = a/N$
- ◆ 准确率：1-错误率 $1 - a/N$

➤ 误差(error):

- ◆ 学习器的实际预测输出与样本的真实输出之间的差异
- ◆ 训练误差/**经验误差**(empirical error)
- ◆ 测试误差/**泛化误差**(generalization error)

7.5.2 系统评价指标

➤ 分类结果的混淆矩阵

真实类别	预测类别	
	正例	反例
正例	TP (真正例)	FN (假反例)
反例	FP (假正例)	TN (真反例)

➤ 召回率Recall、精度Precision

$$\text{Recall} = \frac{TP}{TP + FN}, \text{Precision} = \frac{TP}{TP + FP}$$


➤ 真阳性率(True Positive Rate)、假阳性率(False Positive Rate)

$$\text{TPR} = \frac{TP}{TP + FN}, \text{FPR} = \frac{FP}{TN + FP}$$

7.5.2 系统评价指标


➤ ROC曲线

- ◆ ROC (Receiver Operator Characteristic) 曲线, 称为受试者工作特征曲线, 又称为接收者操作特性曲线, 是以真阳性率(true positive rate, TPR)为纵坐标, 假阳性率(false positive rate, FPR) 为横坐标绘制的曲线。



(a)

AUC代表ROC下的面积




(b)

Q2: 思考一下什么样的ROC曲线代表高性能的模式识别系统?

7.5.2 系统评价指标

➤ Precision-Recall 曲线

- ◆ PR (Precision-Recall) 曲线，是以精度(precision)为纵坐标，召回率(recall rate)为横坐标绘制的曲线。



AP代表PR曲线下的面积

$$F_{\beta} = \frac{(\beta^2 + 1)PR}{\beta^2 P + R}$$

$$F_1 = \frac{2PR}{P + R}$$

7.5.2 系统评价指标



➤ 交叉验证方法(Cross Validation)

- ◆ CV是用来验证分类器的性能一种统计分析方法，将原始数据(dataset)进行分组,一部分做为训练集(training set),另一部分做为验证集(validation set)
- ◆ K-折交叉验证 (K-fold Cross Validation)
 - 将原始数据分成K组(一般是均分)，将每个子集数据分别做一次验证集，其余的K-1组子集数据作为训练集，这样得到K个模型
 - K个模型最终的验证集的分类准确率的平均数作为分类器的性能指标
- ◆ 留一法 (Leave-One-Out)
 - 每个样本单独作为验证集,其余的N-1个样本作为训练集

7.5.3 统计模式识别：过拟合

➤ 过拟合(overfitting)与欠拟合(underfitting):

- ◆ 欠拟合：训练样本的性质没学好，表现为训练误差大
- ◆ 过拟合：训练样本学的“太好”，缺乏对本质的理解，出现泛化性能下降



Q1: 思考一下为什么我们需要降低特征的维度?

7.5.4 产生式/鉴别式模型

➤ 产生式模型 Generative models:

- ◆ 建模(联合)概率分布: $p(\mathbf{x}, \omega)$
- ◆ 利用 Bayes' theorem

$$p(\omega | \mathbf{x}) = \frac{p(\mathbf{x} | \omega) p(\omega)}{p(\mathbf{x})}$$

- ◆ 典型方法: Bayes, GMM, HMM等

➤ 判别式模型 Discriminative models:

- ◆ 直接用函数（而非概率）对 $p(\omega|x)$ 来建模
- ◆ 典型方法: LDA, SVM, 神经网络
- ◆ 一般来说, 性能更好

参考文献

- 边肇祺,张学工.模式识别. 清华大学出版社, 2000
- Duda R O, Hart P E, Stork D G. Pattern classification. John Wiley & Sons, 2012.

谢谢大家！

欢迎提出宝贵意见！