


媒体与认知

Media and Cognition

第8讲 视觉感知与认知计算

Visual perception and cognition computing



清华大学电子系 王生进 李亚利

8.1 视觉感知计算模型

8.2 模拟视觉注意的感知计算

8.3 视觉认知计算


图像分类；

图像搜索；

行人再识别（行人检索）；

1. 生物视觉感知模型

通过对猴子视觉生理的研究发现，形状、颜色、运动和深度等视觉信息，在从视网膜、LGN（膝状体核）、V1区到V2、V4区的视觉通道中，进行既平行又分级串行的信息处理（对比CNN结构）





基于生物视觉感知系统的这种生理结构，研究者们提出了各种有效的计算模型

(1) 视网膜细胞响应模型

视觉系统内任何一个神经细胞，都有各自的视网膜代表区，即感受野。

Hubel (1981年诺贝尔生理学 and 医学奖) 最早发现视网膜的A型神经节细胞呈同心圆交替形。即刺激在感受野中心与外围，对细胞响应的影响正好相反，常见的类型有

on-中心型，off-中心型两种




视网膜神经节细胞感受野

(2) 简单感受野模型

V1区第4层简单细胞感受野结构和计算模型，是最近十多年研究的重点，其比同心圆模型要复杂

Hubel和Wiesel发现，当具有一定朝向和宽度的条形刺激出现在简单细胞感受野内某个特定位置时，细胞的响应最强；当刺激偏离该朝向，或位置时，响应急剧减低，甚至消失

即：简单细胞对视觉刺激模式，呈现方向、位置、和空间频率选择性



2、图像感知计算模型

(1) 同心圆感受野计算模型—SIFT特征算子



1965年，Rodieck提出了这种感受野的数学模型，用两个高斯函数的差（DoG）表示

$$DoG(r) = A \exp\left(-\frac{r^2}{\sigma_A^2}\right) - B \exp\left(-\frac{r^2}{\sigma_B^2}\right)$$

r 为感受野中一点与中心点的距离， σ 表示方差。

$A > B$ ， $\sigma_A < \sigma_B$ 对应on-中心，反之对应off-中心

高斯差分函数（DoG）可表示为两邻近尺度高斯函数的差：

$$D(x, y, \sigma)' = G(x, y, k\sigma) - G(x, y, \sigma)$$

SIFT算子

➤ SIFT特征提取算法 (Scale-invariant Feature Transform)

- (1) 尺度空间极值点检测：将尺度空间极值点作为候选特征点
- (2) 特征点的精确定位：用二阶模型拟合得到特征点的亚像素精度的空间坐标和尺度坐标，同时去除不稳定特征点
- (3) 方向分配：以局部梯度方向直方图的极值方向作为特征点的方向，后面的特征描述就以此方向作为参考方向
- (4) 特征描述：从局部梯度方向直方图建立特征点描述





获取特征后，按照特征向量之间的欧氏距离进行匹配，若有3个以上特征点同时正确匹配，则认为物体匹配正确


建立高斯尺度空间 **L** 和高斯差分空间 **D**，以 **D** 空间的极值点作为候选特征点。

归一化的高斯-拉普拉斯算子





$$\begin{aligned}
 & I(x, y) * [(k-1)\sigma^2 \nabla^2 G(x, y, \sigma)] \\
 & \approx I(x, y) * [G(x, y, k\sigma) - G(x, y, \sigma)] \\
 & = L(x, y, k\sigma) - L(x, y, \sigma) \\
 & = D(x, y, \sigma) \quad \text{尺度空间高斯差分函数}
 \end{aligned}$$

忽略k-1






基于SIFT特征的图像匹配、检测与识别



(2) 简单感受野计算模型—Gabor滤波器



简单细胞感受野对视觉刺激模式，呈现方向、位置、和空间频率选择性

Daugman提出，用Gabor函数来模拟简单细胞的感受野结构，定义为高斯包络函数和正弦谐波函数的乘积

$$g(x, y) = K \exp\{-\pi[a^2(x-x_0)_r^2 + b^2(y-y_0)_r^2]\} \times \exp\{j[2\pi(u_0x + v_0y) + P]\}$$

K是归一化参数，P表示相位，r表示方差项。

Gabor滤波器是对高斯函数的正弦或余弦调制，二维Gabor函数可以描述不同位置、不同尺度的感受野，广泛用于自底向上注意信息的提取算法中。

二维Gabor函数表示 $h(x, y) = g(x', y') [\cos(2\pi f_0 x') + j \sin(2\pi f_0 x')]$


其中

$$g(x, y) = \exp\left(-\frac{x'^2}{2\sigma_x^2} - \frac{y'^2}{2\sigma_y^2}\right)$$

$$x' = x \cos \theta + y \sin \theta$$

$$y' = -x \sin \theta + y \cos \theta$$



θ 是朝向， f_0 是中心频率，
 σ_x σ_y 是在空域 x' 和 y' 方向的高斯函数方差



Gabor滤波器，举例，3尺度5方向 12

Gabor滤波器应用实例

1个尺度，6 orientations的Gabor滤波器组进行纹理特征提取



8.1 视觉感知计算模型

8.2 模拟视觉注意的感知计算

8.3 视觉认知计算

图像分类；

图像搜索；

行人再识别（行人检索）；

1. 图像显著性检测

❖ 模拟视觉注意机制的感知计算具有理论研究价值

-机器视觉的核心目标是构建具有视觉功能的处理系统


➤ 显著区域检测正是机器人“眼睛”的基本任务

-图像、视频数据爆炸性增长，信息检索犹如大海捞针


➤ 显著区域检测—重在模拟人类视觉注意机制，快速定位显著区域

❖ 显著区域检测与人类视觉注意机制密切相关

其核心课题，即：注意机制（回忆认知心理的注意）




注意机制与图像显著性




实际问题

- 万物万象；目标种类、大小未知，场景未知
- 寻找一种通用得视觉注意模型，实现显著区域检测：在场景中估计人类视觉感兴趣的区域





2. 介绍一种通用的显著区域检测的方法——基于注意窗估计的显著性检测方法



(1) 图像局部差异度计算


★ 局部显著图实现




(2) 注意窗估计^[1]

(a) 估计视觉注意中心-聚光灯原理

- 局部显著图重点突出显著区域的边界
- 显著区域边界的重心=视觉注意的中心
- 将局部显著图的重心作为视觉注意中心




局部显著图



重心
(x_0, y_0)



[1] Jie Liu, Shengjin Wang, 'Salient Region Detection via Simple Local and Global Contrast Representation', Neurocomputing, Pages 435-443, Volume 147, 5 January 2015

注意窗估计



(b) 局部显著图加权-模拟聚焦区域


$$V'_{i,j} = V_{i,j} \exp \left(-\sqrt{\left(\frac{i - x_0}{k_w \times N} \right)^2 + \left(\frac{j - y_0}{k_w \times M} \right)^2} \right)$$



(x_0, y_0)



注意窗估计





(c) 加权图二值化—进一步去除干扰

- 当区域内的方差小于阈值时，认为其内不含显著部分

$$V''_{i,j} = \begin{cases} 1 & \text{for } V'_{i,j} \geq T \\ 0 & \text{for } V'_{i,j} < T \end{cases}$$

计算二值图的最大包围框




注意窗估计

(d) 注意窗映射


➤ 从局部显著图转换到原始图像上

$$\begin{cases} x_{bb_I} = \frac{N}{\lfloor \frac{2(N-l)}{l} + 1 \rfloor} \times x_{bb_V} \\ y_{bb_I} = \frac{M}{\lfloor \frac{2(M-l)}{l} + 1 \rfloor} \times y_{bb_V} \end{cases}$$

bb_V




注意窗



(3) 显著图生成^[1]

★从注意窗到显著图生成





[1] Jie Liu, Shengjin Wang, 'Salient Region Detection via Simple Local and Global Contrast Representation', Neurocomputing, Pages 435-443, Volume 147, 5 January 2015

显著图生成

(a) 颜色量化

- ① R、G、B每通道量化为12个数
- ② 保留出现频度高的K种颜色：至少覆盖95%的像素，且 $K \geq N_c$
- ③ 其它颜色用相近的颜色代替


N_c 是阈值，实验中200



显著图生成

(b) 颜色集合分类

- ✓ 确定显著的颜色: $c \in U - B$
- ✓ 确定不显著的颜色: $c \in U - F$
- ✓ 不确定的颜色: $c \in B \cap F$





背景中没有的

前景中没有的

背景前景中都有的

U 为颜色全集, F 和 B 分别表示窗内外颜色集合



显著图生成



(c) 颜色显著性计算

★ 对不确定颜色，计算注意窗内外相同颜色的像素数比例：

$$R_c = \frac{n_{c \in F}}{n_{c \in B}}$$


★ 对不确定颜色排序： $k \in \{1, 2, \dots, K_C\}$

k 越小表示比例越低



显著图生成

颜色显著性计算




$$S_c = \begin{cases} 1 & \text{if } c \in U - B \\ \frac{k}{(K_C+1)} & \text{if } R_c \geq R_T \text{ and } c \in B \cap F \\ 0 & \text{otherwise } c \in U - F \end{cases}$$

确定显著的颜色

不确定的颜色

确定不显著的颜色



K_C 表示所有满足
 $K_C > R_T$ 的颜色个数

$k \in \{1, 2, \dots, K_C\}$

阈值 R_T 为8

显著图生成


(d) 像素显著性赋值

✓ 像素显著性=该像素颜色的显著性

$$SM_i = S_{c_i} \quad \text{显著图由颜色显著性表示}$$

后处理

✓ 形态学闭合、开启



(4) 算法结果比较




★ 数据库

MSRA: 单个目标, 目标偏大, 场景简单, 应用最广, CVPR2009




CSSD: 一个或多个目标, 大小不一, 场景复杂, CVPR2013






显著图直观比较

(1) 显著图直观比较 (MSRA)



(2) 显著图直观比较 (CSSD)



3、 注意机制的神经网络模型

- 注意机制可以在深度神经网络中实现——attention map
- 卷积神经网络的注意力模块(Attention Module)，一般是**从通道和空间两个维度计算feature map的attention map**，然后将attention map与输入的feature map相乘来进行特征的自适应学习。
- 可将其融入到各种卷积神经网络中进行端到端训练



(1) 神经网络注意模型

神经网络注意模型，是具备能专注于其输入（或特征）的神经网络，它能选择特定的输入。

将输入设为 $\mathbf{x} \in \mathbb{R}^d$ ，特征向量为 $\mathbf{z} \in \mathbb{R}^k$ ， $\mathbf{a} \in [0,1]^k$ 为注意向量， $f_\phi(\mathbf{x})$ 为注意网络。则 attention 的实现为：

$$\begin{aligned}\mathbf{a} &= f_\phi(\mathbf{x}), \\ \mathbf{z}_a &= \mathbf{a} \odot \mathbf{z},\end{aligned}$$

$\odot$ 代表对应按元素（element-wise）相乘的运算




(2) 硬注意 (hard attention)

hard attention表示mask of values被强制分为0或1两值，即 $a \in \{0,1\}^k$

硬注意力在图像中的应用较多：即图像裁剪 (image cropping)，可建模为：


$$g = I(y:y+h, x:x+w)$$



(3) 软注意 (soft attention)

soft attention是指相乘时 (soft) mask of values在0—1之间

神经网络实际上就是一个函数近似器，典型的神经网络是矩阵乘法构成的链式运算，**注意机制可以用来计算可被用于特征相乘的mask**



8.1 视觉感知计算模型

8.2 模拟视觉注意的感知计算

8.3 视觉认知计算


图像分类；


图像搜索；

行人再识别（行人检索）；



1、 基于CNN特征的图像分类

图像分类，是一个输入图像、输出对该图像内容分类的描述的问题，是计算机视觉的核心，实际应用广泛。单标签，多标签






0	1	0
1	-4	1
0	1	0




白色框是卷积层，红色是池化，蓝色是全连接层，棕色框是预测层。预测层的作用是将全连接层输出的信息转化为相应的类别概率，而起到分类作用。


- 一种特定的卷积核可以计算出图片的轮廓，
- 另一种卷积核能够计算出图像的明暗程度，
- 足够多的卷积核，能形成对原始图片的多样的特征提取。



CNN的96种卷积核的可视化



最初的可可视化工作见于AlexNet[1]论文中。在这篇开创Deep Learning新纪元的论文中，Krizhevsky直接可视化了第一个卷积层的卷积核：



输入(3,224,224)的图像，同时padding 1，外接一圈0；
 卷积有64个(3,3)卷积核，卷积生成新的图像数据64*224*224；
 池化是(2,2)，步长(2,2)，横纵向每次移动2格，数据变成64*112*112；
 依次卷积核为128,256,512，池化，13层卷积池化后，数据为 512*7*7；
 经过Flatten，将数据拉平成向量，变成一维512*7*7=25088
 之后接3个全连接层（2个4096），4096是经验值，1000对应1000种分类

菜品分类实例


对输入的菜品图像进行分类，是一个单标签分类问题

数据集

目标数据集：10类菜品分类，数据集共1.7k张

预训练数据：较大的菜品分类数据集，200类

图片输入尺寸为448 x 448像素



- 0 红烧排骨
- 1 红烧肉
- 2 韭菜炒鸡蛋
- 3 麻婆豆腐
- 4 清炒西兰花
- 5 土豆炖豆角
- 6 土豆牛肉
- 7 土豆丝
- 8 西红柿炒鸡蛋
- 9 鱼香肉丝


1、分类方法

方法一：使用CNN提取图像特征，损失函数使用Softmax Loss

方法二：使用预训练的CNN提取图像特征，采用K近邻KNN分类

使用随机梯度下降（SGD）方法对模型参数进行优化

2、模型结构




和训练集中图像提取的特征进行对比

3、算法流程

目标分类数据集较小，可以利用大规模数据集进行预训练，再使用目标数据集进行微调

模型训练流程


- 采用ImageNet预训练模型
- 在200类菜品数据集上，对CNN进行微调
- 在目标数据集，10类菜品数据集上，仅对最后的全连接fc层进行微调



4、CNN模型

采用ResNet-50，也可以替换为其它模型

ResNet模型结构



layer name	output size	18-layer	34-layer	50-layer	101-layer	152-layer
conv1	112×112	7×7, 64, stride 2				
conv2_x	56×56	3×3 max pool, stride 2				
		$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$
conv3_x	28×28	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 8$
conv4_x	14×14	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 23$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 36$
conv5_x	7×7	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$
	1×1	average pool, 1000-d fc, softmax				
FLOPs		1.8×10^9	3.6×10^9	3.8×10^9	7.6×10^9	11.3×10^9



5、目标数据集分类结果




GT: 土豆炖豆角
 0 土豆炖豆角 pr: 0.9567
 1 土豆牛肉 pr: 0.0262
 2 清炒西兰花 pr: 0.0118



GT: 韭菜炒鸡蛋
 0 韭菜炒鸡蛋 pr: 0.9975
 1 清炒西兰花 pr: 0.0020
 2 土豆丝 score: pr: 0.0004



GT: 麻婆豆腐
 0 麻婆豆腐 pr: 0.9642
 1 韭菜炒鸡蛋 pr: 0.0108
 2 土豆炖豆角 pr: 0.0098



GT: 西红柿炒鸡蛋
 0 西红柿炒鸡蛋 pr: 0.6385
 1 红烧肉 pr: 0.1274
 2 清炒西兰花 pr: 0.1107



wrong example: 10

GT: 红烧排骨
 0 土豆牛肉 score: 3.4831 pr: 0.5590
 1 土豆炖豆角 score: 2.4226 pr: 0.1936
 2 红烧排骨 score: 2.3452 pr: 0.1792
 3 麻婆豆腐 score: 0.8579 pr: 0.0405
 4 清炒西兰花 score: -0.5693 pr: 0.0097

错误分类结果

2、复制和近似图像检索

- 大数据时代，图像数据海量增长
- “平安城市”视频图像急需进行快速索引、查询，民生、社会、国防都是一项重大的国家需求。



250 Billion Images in 2013
6 Billion added monthly



72 hours/minute
in April 2012




6 Billion Images
In 2011

复制和近似图像检索的含义 Near duplicate Image retrieval



(一) 图像检索框架

- 词袋模型 (Bag-of-Words Model)



图像



局部特征




Bag of 'Words'

- 利用了SIFT特征在图像匹配上的优越性
 - 旋转、尺度不变性
 - 实现精确的图像匹配
- 对SIFT进行量化，即生成视觉单词
 - 一幅图像表示成视觉单词的集合
 - 可以利用文本检索的方法进行图像检索
 - 快速，内存开销小

• 图像检索 framework

- 离线：特征提取，词典训练，倒排表建立
- 在线：特征提取，特征量化，倒排表遍历



(1) 特征提取 Feature extraction

• 局部特征

Li et al, A survey of recent advances in visual feature detection, Neurocomputing, 2014.

- 检测子: Harris, Harris-Affine, DoG, Hessian-Affine, MSER, SURF (CVIU'08), FAST (ECCV'06), KAZE (ECCV'12), SIFER (IJCV'13)
- 描述子: SIFT, GLOH, Shape Context (NIPS'00), SURF (CVIU'08), BRIEF (ECCV'10), ORB (ICCV'11), FREAK (CVPR'12), BRISK (ICCV'11)
- 可复制性、紧凑型、显著性和局部性

• 区域和全局特征

- VLAD, Fisher vector: 将区域中的SIFT特征汇聚成一个向量
- 以CNN为代表的深度学习特征。
 - 在物体分类、目标检测、OCR、人脸识别上取得重大进展
 - 在语音识别、手写数字识别上日渐成熟

Cai et al, Stochastic pooling maxout networks for low-resource speech recognition, ICASSP, 2014.

Krizhevsky et al, Imagenet classification with deep convolutional neural networks, NIPS, 2012.


Girshick et al, Rich feature hierarchies for accurate object detection and semantic segmentation, CVPR, 2014.

(2) 词典生成 Dictionary generation

- 本质：寻找特征空间的一组基，可以表达提取的特征
- 方法：k-means
- 大规模数据下，近似k-means
 - Approximate K-means (Philbin et al, CVPR'07)
 - Hierarchical K-means (Nister et al, CVPR'06)
- 改进方法：
 - Hamming Embedding (Jegou et al, ECCV'08)
 - Approximate hierarchical K-means (Mikulik et al, ECCV'10)
 - K-means via cluster closures (Wang et al, CVPR'12)
 - Recursive clustering (Arvritthis et al, ICCV'13)


(3) 特征量化 Feature Quantization

- 本质：使用词典中的词条来表达特征
- 目标：
 - 相似的特征量化为相同的单词
 - 不相似的特征量化为不同的单词
- 方法：
 - 硬量化：误差较大
 - 软量化 (Gemert, PAMI09)
 - Fisher Kernel Coding (Perronnin et al, CVPR07, ECCV10)
 - Sparse coding (Yang et al, CVPR09)
 - Locality Constrained Coding (Wang et al, CVPR10)
 - Manifold soft assignment (Liu et al, ICCV11)
 - Constrained quantization (Yang et al, MM'12)
 - Scalar quantization (Zhou et al, MM'12)



(4) 索引策略 Index Strategy

• 经典倒排表



最新的索引策略

- Zhang et al, ICCV 2013, 联合索引 (Co-Indexing)
- Liu et al, TIP 2014, 交叉索引 (Cross-Index)
- Xia et al, ICCV 2013, 共同索引 (Joint Index)

• 经典倒排表


图片得分


视觉单词

量化


查询图片

被索引的图片






So An image is represented as a
“bag of words”



A query image is also described as a “bag of words”. By Comparing the query image to database images, the system returns most similar ones


(二) 图像特征提取与鉴别性视觉表达 Feature description




(1) 鉴别性视觉表达 - 多层次特征融合

- SIFT特征描述局部梯度特征，因此，采用多特征融合方法，增强特征描述


局部梯度特征




局部颜色特征



全局GIST特征



区域、全局CNN特征




(2) 局部特征融合

- 【方法】将局部颜色特征与SIFT进行融合

一对关键点，SIFT相似，但颜色不相似



Color Names局部描述子



一对正确匹配的关键点：SIFT相似，局部颜色也相似


(2) 局部特征融合

• 特征匹配规则

一对关键点，其SIFT视觉单词相同


- 如果他们二进制特征（SIFT+颜色）之间的汉明距离小于阈值，则为正确匹配；
- 如果大于阈值，则为错误匹配

Baseline




Rank: 45


Ours



Rank: 2




Rank: 3



Rank: 98

(3) 区域和全局特征融合

- 完美的匹配要求
 - 在局部、区域、全局三个层次上都要匹配



局部匹配

区域匹配

全局匹配


(3) 区域和全局特征融合

- 特征提取


- 局部特征为SIFT
- 区域和全局特征提取如下：



全局特征



区域特征，尺度1




区域特征，尺度2


- 每个图像块被缩放成 $227 \times 227 \times 3$ ，并减去均值
- 对每个图像块，提取一个4096维的特征向量
 - 我们使用DeCaf框架来提取CNN特征
 - 特征从DeCaf的第六层或第七层中提取

(3) 区域和全局特征融合


- 深度学习网络CNN特征优于颜色特征
- *表示使用浮点数，否则使用二进制特征



(a) Holidays



(b) Oxford5k



(c) Ukbench

CNN特征计算速度慢，适合描述区域和全局特征
颜色特征计算速度快，适合描述局部特征

• 图像检索结果示例



Query



Baseline



汉明嵌入



Ours



Query



Baseline



汉明嵌入




Ours

3、行人再识别（行人检索）

➤ 视频身份识别的一种途径—行人再识别

- 行人再识别(person re-identification, ReID): 利用计算机视觉技术在图像或视频中检索特定行人的任务

2018 sees a breakthrough in person re-identification performance




1. R. R. Varior, M. Haloi, and G. Wang. Gated Siamese convolutional neural network architecture for human reidentification. In ECCV, 2016.
2. Z. Zheng, L. Zheng, and Y. Yang. Unlabeled samples generated by gan improve the person re-identification baseline in vitro. In ICCV, 2017.
3. Y. Sun, L. Zheng, W. Deng, and S. Wang. SVDNet for pedestrian retrieval. In ICCV, 2017.
4. X. Bai, M. Yang, T. Huang, Z. Dou, R. Yu, and Y. Xu. DeepPerson: Learning discriminative deep features for person reidentification. In arXiv: 1711.10658, 2017.
5. X. Zhang, H. Luo, X. Fan, W. Xiang, Y. Sun, et al., AlignedReID: Surpassing human-level performance in person re-identification. In arXiv:1711.0818, 2017
6. Y. Sun, L. Zheng, Y. Yang, Q. Tian, and S. Wang. Beyond part models: Person retrieval with refined part pooling. In ECCV, 2018.

视频身份识别的一种途径

继人脸识别之后的智能视频安防核心技术，有迫切的应用需求，学术研究面临艰巨挑战

- 跨视域多摄像头轨迹信息获取
- 提供了从背影确定人脸ID的实现可能



学术界研究热点





行人再识别的算法关键：

行人检测，行人配准，表观特征提取，度量匹配


➤ 有鉴别力的行人特征描述子

➤ 学习合适的距离度量




* 局部缺失的行人再识别

- 局部缺失的行人再识别Partial Re-ID—实际re-ID严峻挑战
 - 当前主流方法难以解决
- 问题形成原因
 - 行人受到遮挡
 - 行人正好走出相机视场，产生截断



难点及动机

• 局部缺失行人再识别难点




• 我们的思路（图c）

- ✓ 通过自监督，学习注意可见区域
- ✓ 聚焦在共同区域以比较两幅图像



- Visibility-aware Part Model (VPM) 可见性敏感的部位模型



1. 在完整图像上预定义部件分割策略（图中分成3块）
2. 卷积产生3D张量T，区域定位器使用一个1*1 卷积层及一个后缀Softmax函数，预测T上每个像素属于区域 R_i 概率预测值


$$P(R_i|g) = \text{softmax}(W^T g) = \frac{\exp W_i^T g}{\sum_{j=1}^p \exp W_j^T g}, \quad (1)$$

p幅概率图的尺寸为 $h \times w$ （p=Ri数）

$$C_i = \sum_{f \in T} P(R_i|g),$$

可见性得分

• Visibility-aware Part Model (VPM)



1. 在完整图像上预定义部件分割策略（图中分成3块）

2. 截取部分图像，卷积产生

3. 模型输出：


$$f_i = \frac{\sum_{g \in T} P(R_i|g)g}{C_i}, \forall i \in \{1, 2, \dots, p\},$$

✓ p 个部件特征—每个区域所有像素经池化加权产生部件特征向量 f_i

✓ p 个区域可见性得分—各区域像素对应概率和为该区域可见性得分 C_i

算法介绍

• 调用VPM（特征提取+匹配）



从区域-区域距离 D_i^{kl} 归纳两幅图像 k, l 间的总体距离:

$$D^{kl} = \frac{\sum_{i=1}^p C_i^k C_i^l D_i^{kl}}{\sum_{i=1}^p C_i^k C_i^l}.$$


$$f_i = \frac{\sum_{g \in T} P(R_i|g)g}{C_i}, \forall i \in \{1, 2, \dots, p\},$$

部件特征
计算部件距离

$$D_i^{kl} = |f_i^k - f_i^l|$$

算法介绍

- 调用VPM（特征提取+匹配）




$$D^{kl} = \frac{\sum_{i=1}^p C_i^k C_i^l D_i^{kl}}{\sum_{i=1}^p C_i^k C_i^l}.$$

算法特性：

1. 部件特征计算部件距离
2. 部件可见性得分决定重要程度
3. 最终效果——关注共同区域

• 训练VPM ——自监督学习



$$L_R = - \sum_{g \in T} \mathbb{1}_{i=L} \log(P(R_i|g)),$$

交叉熵损失函数，
自监督信号L 作为
训练真值

自监督辅助
特征学习：

每个像素所属部件的ground truth
自动产生，构成自监督学习

- 1) 仅有可见部件特征贡献给分类loss;
- 2) 仅有共享部件特征贡献给metric loss



主要实验结果

- 在大规模合成数据集上，超越IDE基线及PCB基线
(图像缺失30%时+8.0%mAP@Duke)

Dataset	γ	baseline				PCB				VPM			
		R-1	R-5	R-10	mAP	R-1	R-5	R-10	mAP	R-1	R-5	R-10	mAP
Market-1501	0.5	64.5	82.2	88.1	44.4	0.9	3.2	5.6	1.7	70.9	86.5	92.1	48.8
	0.6	79.0	91.4	94.3	57.9	8.1	16.5	23.2	6.6	84.4	94.3	96.1	62.5
	0.7	83.9	93.9	95.9	63.7	36.5	58.9	67.4	26.8	88.2	95.8	97.2	71.7
	0.8	85.7	94.3	96.4	66.1	71.9	87.3	91.4	56.8	90.1	95.8	97.7	74.7
	0.9	87.1	95.5	97.4	67.8	88.8	95.8	97.1	77.2	91.7	96.6	98.0	78.7
	1.0	86.8	95.3	97.4	67.7	93.4	97.8	98.4	83.0	93.0	97.8	98.8	80.8
DukeMTMC-reID	0.5	65.0	81.1	86.7	47.2	5.0	10.1	13.6	4.0	69.5	83.1	87.9	52.2
	0.6	76.2	87.3	90.4	55.4	13.1	25.6	33.5	10.5	78.2	89.0	91.3	60.9
	0.7	76.3	87.3	90.6	90.6	35.9	57.0	65.4	28.4	80.3	89.5	92.0	63.1
	0.8	76.3	88.3	91.9	58.8	64.0	82.6	87.7	52.3	80.3	89.3	92.4	63.5
	0.9	77.0	88.1	91.7	59.0	81.6	90.4	93.0	70.3	81.7	90.9	93.1	70.7
	1.0	76.2	87.3	91.2	58.6	84.1	92.4	94.5	73.2	83.6	91.7	94.2	72.6

Table 1. Comparison between VPM, baseline and PCB. For VPM, we use $p = 6 \times 1$ pre-defined regions. For PCB, we adopt the code released by the authors and append an extra triplet loss, for fair comparison with VPM. On Market-1501, the extra triplet loss enables PCB to gain +1.1% rank-1 accuracy over the original 92.3% reported by the authors [22].

刷新国际最好水平

Top表示保留身体头部分

Methods	Partial-REID		Partial-iLIDS	
	R-1	R-3	R-1	R-3
MTRC [15]	23.7	27.3	17.7	26.1
AMC+SWM [36]	37.3	46.0	21.0	32.8
DSR [7]	50.7	70.0	58.8	67.2
SFR [8]	56.9	78.5	63.9	74.8
VPM (Bottom)	53.2	73.2	53.6	62.3
VPM (Top)	64.3	83.6	67.2	76.5
VPM (Bilateral)	67.7	81.9	65.5	74.8

用Gabor函数可以模拟简单细胞的感受野结构，以提取自然图像中对朝向敏感的初级视觉特征，广泛用于自底向上注意信息的提取算法中。

试自选5张图像，用Gabor函数做2尺度、6方向的滤波器组进行纹理特征提取。

二维Gabor函数

$$h(x, y) = g(x', y') [\cos(2\pi f_0 x') + j \sin(2\pi f_0 x')]$$

其中

$$g(x, y) = \exp\left(-\frac{x^2}{2\sigma_x^2} - \frac{y^2}{2\sigma_y^2}\right)$$

$$x' = x \cos \theta + y \sin \theta$$

$$y' = -x \sin \theta + y \cos \theta$$