

Digital Signal Processing

数字信号处理

(第12讲)

有限字长效应


刘一民

yiminliu@tsinghua.edu.cn

电子工程系

清华大学 罗姆楼 11-102

数字系统的误差来源



有限字长效应的研究价值

- 引起有限字长的误差源
 - A/D变换引入的误差：量化误差等
 - 用有限精度的数表示系统系数引入的误差
 - 为限制乘法运算位数扩展进行尾数处理引入的误差
 - 为防止加法运算溢出而压缩信号电平引入的误差
 - 由尾数舍入和溢出带来的极限环现象
- 研究有限字长效应的用途
 - 确定A/D、D/A变换器的位数
 - 选择合适的系统实现结构
 - 确定处理数据的表示方式与字长等


1. 二进制数的表示和量化误差

• 1.1 数的表示

• 浮点数

$$x = 2^c \times M$$

32bit单精度浮点



动态范围大、误差小。

Matlab®默认是采用的双精度(64bit)浮点型


1. 二进制数的表示和量化误差

• 1.1 数的表示

- 定点数

- 补码表示

符号位



$$[x] = \begin{cases} |x|, & 0 \leq x < 1 \\ 2 - |x|, & -1 \leq x < 0. \end{cases}$$

二进制补码($b_0, b_1, b_2, \dots$)与真值:

$$x = -b_0 + \sum_{i=1}^{\infty} b_i \times 2^{-i}$$

$$b_0 = \begin{cases} 0, & x > 0 \\ 1, & x < 0 \end{cases}$$

当总共用 $1+B$ 个bit表示时, 量化误差为

$$q = 2^{-B}$$

1. 二进制数的表示和量化误差

• 1.2 有限位定点数的量化误差

• 截尾法 (floor, $\lfloor \cdot \rfloor$)

真值: $x = -b_0 + \sum_{i=1}^{\infty} b_i \times 2^{-i}$


1+B位表示: $\hat{x} = -b_0 + \sum_{i=1}^B b_i \times 2^{-i}$

误差: $e_T = -\sum_{i=B+1}^{\infty} b_i \times 2^{-i}$

最“小”误差: $q = \sum_{i=B+1}^{\infty} 2^{-i} = 2^{-B}$

可将误差建模为均匀分布,
其概率密度函数为:

$$p_T(e) = \begin{cases} \frac{1}{q}, & -q \leq e \leq 0 \\ 0, & \text{others} \end{cases}$$



1. 二进制数的表示和量化误差

- 1.2 有限位定点数的量化误差
 - 舍入法(round)


1+B位表示: $\hat{x} = -b_0 + \sum_{i=1}^B b_i \times 2^{-i} + b_{B+1} 2^{-B}$

误差: $e_R = -\sum_{i=B+1}^{\infty} b_i \times 2^{-i} + b_{B+1} 2^{-B}$

误差范围: $e_R \in [-2^{-(B+1)}, 2^{-(B+1)}]$

可将误差建模为均匀分布,
其概率密度函数为:

$$p_T(e) = \begin{cases} \frac{1}{q}, & -\frac{q}{2} \leq e \leq \frac{q}{2} \\ 0, & \text{others} \end{cases}$$



1. 二进制数的表示和量化误差

- 1.2 有限位定点数的量化误差
 - 量化误差的统计特性

$$Q\{x[n]\} = x[n] + e[n]$$


量化后 真值 量化误差


	截尾	舍入
均值	$m_T = -\frac{1}{2}q = -2^{B+1}$	$m_T = 0$
方差	$\sigma_e^2 = \frac{1}{12}q^2 = \frac{1}{12} \times 2^{-2B}$	
协方差	$C_e[n] = \sigma_e^2 \delta[k]$	

2. 量化误差的统计分析

• 2.1 系统直接实现方式的误差分析

误差来源 { 采样量化误差
计算量化误差

采样量化误差



假设采样位数为 $1+B$, 则

- 采样误差均值 $E\{e[n]\} = 0$
- 采样误差功率 $\sigma_Q^2 = \frac{1}{12} q^2 = \frac{1}{12} \times 2^{-2B}$
- 采样误差功率谱密度 $S_Q(\omega) = \sigma_Q^2$ (白噪声)
- 误差与信号可以认为是统计独立的

2. 量化误差的统计分析


• 2.1 系统直接实现方式的误差分析

若信号没有限幅（溢出），信噪（量化噪声）比

$$\frac{S}{N} = \frac{\sigma_a^2}{\sigma_e^2} = \frac{\sigma_a^2}{2^{-2B}/12} \xrightarrow{\text{dB}} 10 \lg \frac{\sigma_a^2}{2^{-2B}/12} = 6.02B + 10.79 + 10 \lg \sigma_a^2$$

有效位数


ADC有效位数 < 量化位数



例如：一般14bitADC，噪声位有3~3.5bit，有效位数为10.5~11bit。


注意：ADC的有效位数是先测量量化SNR，再计算有效位数。

测量方法



2. 量化误差的统计分析

- 2.1 系统直接实现方式的误差分析
 - 采样量化误差传播



$$y_Q[n] = [x(n) + e(n)] * h[n] = y[n] + f_Q[n]$$

$$y[n] = x[n] * h[n]$$
$$f_Q[n] = e[n] * h[n]$$

误差

真值

与信号一样，噪声同样通过LTI系统。

输出误差均值： $E\{h[n] * e[n]\} = 0$

输出误差功率谱密度： $S_f(\omega) = S_Q(\omega) |H(e^{j\omega})|^2 = \sigma_Q^2 |H(e^{j\omega})|^2$

维纳-辛钦
定理


输出误差功率： $\sigma_f^2 = \frac{1}{2\pi} \int_{-\pi}^{\pi} S_f(\omega) d\omega = \sigma_Q^2 \cdot \sum_{n=0}^{\infty} |h[n]|^2$

Parseval 定理


2. 量化误差的统计分析

• 2.1 系统直接实现方式的误差分析

• 计算量化误差：单个乘法器



- 理想系统: $y[n] = x[n] + \alpha y[n - 1]$
- 量化后: $y[n] = x[n] + Q\{\alpha y[n - 1]\}$



- 假设采用 B 位输出的乘法器, 则

- 截断误差功率: $\sigma_e^2 = \frac{1}{12} \times 2^{-2B}$


- 输出误差功率: $\sigma_f^2 = \frac{1}{2\pi} \int_{-\pi}^{\pi} S_f(\omega) d\omega = \sigma_e^2 \cdot \sum_{n=-\infty}^{\infty} |g[n]|^2$

$g[n]$ 为噪声源到输出的冲激响应

2. 量化误差的统计分析

• 2.1 系统直接实现方式的误差分析

• 计算量化误差：多个乘法器



- 第 i 个噪声源 $e_i[n]$, $i = 1, 2, \dots, K$
- 第 i 个噪声源到输出的单位冲击响应 $g_i[n]$

总的计算量化误差

$$\sigma_f^2 = \sum_{i=1}^K \sigma_{ei}^2 \sum_{n=-\infty}^{\infty} |g_i[n]|^2$$

$e_1[n], e_2[n]$ 等价



输出噪声 $(e_1[n] + e_2[n]) * h[n]$

$e_3[n], e_4[n], e_5[n]$ 等价



输出噪声 $(e_3[n] + e_4[n] + e_5[n])$

对于直接II型IIR, 总输出噪声功率:


$$H(z) = \frac{\sum_{k=0}^M b_k z^{-k}}{1 + \sum_{r=1}^N a_r z^{-r}}$$

$$\sigma_f^2 = \frac{2^{-2B}}{12} \left(N \sum_{n=-\infty}^{\infty} |h[n]|^2 + (M + 1) \right)$$

2. 量化误差的统计分析

• 2.1 系统直接实现方式的误差分析


- 总误差：采样量化误差和各处计算误差经过误差传递后的加和。




2. 量化误差的统计分析

• 2.2 并联/级联/乘加结构的量化误差分析

• 并联结构




子系统误差功率: $\sigma_{f_i}^2 = (\sigma_{A_i}^2 \sum_{n=-\infty}^{\infty} |h_i[n]|^2 + \sigma_{C_i}^2)$



系统误差功率: $\sigma_f^2 = \sum_{i=1}^K (\sigma_{A_i}^2 \sum_{n=-\infty}^{\infty} |h_i[n]|^2 + \sigma_{C_i}^2)$

2. 量化误差的统计分析

- 2.2 并联/级联/乘加结构的量化误差分析
 - 级联结构




误差逐级放大/衰减

$$\begin{aligned} \text{系统误差功率: } \sigma_f^2 = & \frac{\sigma_{A1}^2}{2\pi} \int_{-\pi}^{\pi} \prod_{k=1}^K |H_k(e^{j\omega})|^2 d\omega \quad \text{采样量化误差} \\ & + \sum_{m=2}^K (\sigma_{Am}^2 + \sigma_{C_{m-1}}^2) \frac{1}{2\pi} \int_{-\pi}^{\pi} \prod_{k=m}^K |H_k(e^{j\omega})|^2 d\omega \\ & + \sigma_{C_K}^2 \quad \text{输出计算量化误差} \quad \text{输入计算量化误差} \end{aligned}$$

注意系统增益与噪声的合理安排。

2. 量化误差的统计分析

- 2.2 并联/级联/乘加结构的量化误差分析
 - 乘加(MAC)结构




采用MAC结构实现II型IIR

$$\text{系统误差功率: } \sigma_f^2 = \frac{2^{-2B}}{12} (\sum_{n=-\infty}^{\infty} |h[n]|^2 + 1)$$


3. 计算溢出及其避免

• 3.1 什么是溢出




补码表示范围 $|x| < 1$

溢出：
计算过程中，结果超过了表示范围



主要介绍加法溢出

简单一阶
反馈的IIR
滤波器



$$w[n] = x[n] + 0.75w[n - 1]$$

$$L(z) = \frac{W(z)}{X(z)} = \frac{1}{1 - 0.75z^{-1}}$$

$$l[n] = (0.75)^n u[n]$$

$$|w[n]| = \left| \sum_{m=0}^{\infty} l[m]x[n - m] \right| \leq \max|x[n]| \sum_{m=0}^{\infty} |l[m]| \leq 1$$

3. 计算溢出及其避免


• 3.2 压缩比例因子

$$|w[n]| = \left| \sum_{m=0}^{\infty} l[m]x[n-m] \right| \leq \max|x[n]| \sum_{m=0}^{\infty} |l[m]| \leq 1$$

若希望该加法节点不溢出，则输入信号幅度不能超过

$$\max|x[n]| \leq \frac{1}{\sum_{n=0}^{\infty} |l[n]|} = \frac{1}{\|l[n]\|_1}$$

其中 $\|\cdot\|_1$ 是 l -1范数，即序列的绝对值的和。



$$\|l[n]\|_1 = \sum_{n=0}^{\infty} (0.75)^n = 4$$

$$\max|x[n]| \leq 4$$

为了保证不溢出，先将输入“压缩” β 倍。

$$\text{压缩因子 } \beta = \|l[n]\|_1$$




先缩小，后放大
保持系统传输特性不变

3. 计算溢出及其避免

- 3.2 压缩比例因子

- 第I类压缩比例因子

$$\beta = \|l[n]\|_1 = \sum_{n=0}^{\infty} |l[n]|$$



若输入信号 $x[n]$ 是窄带信号

$$x[n] = \cos(\omega_0 n + \varphi)$$

则输出为

$$|w[n]| = |L(e^{j\omega_0}) \cos(\omega_0 n + \varphi + \arg L(e^{j\omega_0}))| \leq |L(e^{j\omega_0})| \leq 1$$

当信号频率在 $[-\pi, \pi]$ 之间变化时，压缩比例因子

$$\beta = \max_{-\pi \leq \omega_0 \leq \pi} |L(e^{j\omega_0})|$$

本例中，

$$|L(e^{j\omega})| = \left| \frac{1}{1 - 0.75e^{j\omega}} \right| \quad \Rightarrow \quad \beta = 4$$

3. 计算溢出及其避免

- 3.2 压缩比例因子
 - 第II类压缩比例因子

当第I类压缩比例因子难以计算时，可以通过第II类压缩因子近似

假设输入信号 $x[n]$ 是能量受限信号

$$\begin{aligned}\sum_{n=0}^{\infty} |x[n]|^2 &\leq 1 \\ |w[n]| &= \left| \frac{1}{2\pi} \int_{-\pi}^{\pi} L(e^{j\omega}) X(e^{j\omega}) e^{j\omega n} d\omega \right| \leq \frac{1}{2\pi} \int_{-\pi}^{\pi} |L(e^{j\omega}) X(e^{j\omega})| d\omega \\ &\leq \sqrt{\frac{1}{2\pi} \int_{-\pi}^{\pi} |L(e^{j\omega})|^2 d\omega} \sqrt{\frac{1}{2\pi} \int_{-\pi}^{\pi} |X(e^{j\omega})|^2 d\omega} \\ &\leq \sqrt{\frac{1}{2\pi} \int_{-\pi}^{\pi} |L(e^{j\omega})|^2 d\omega} = \sqrt{\sum_{n=0}^{\infty} |l[n]|^2} = \|l[n]\|_2\end{aligned}$$

其中 $\|\cdot\|_2$ 是 l_2 范数，即序列的平方和的平方根。

3. 计算溢出及其避免

• 3.2 压缩比例因子

若要求 $|w[n]| < 1$ ，同时考虑到输入信号一般不为能量有限信号，则


第II类压缩比例因子： $\beta = C \cdot \|l[n]\|_2$

其中， C 为常系数， $C > 1$ (书中一般取 $C = 5$)

不能完全保证不溢出

$$\|l[n]\|_2 \leq \max_{-\pi \leq \omega \leq \pi} |L(e^{j\omega})| \leq \|l[n]\|_1$$

• 2.3 压缩因子的加入



从输入 $x[n]$ 到第 i 个加法节点的系统函数为 $L_i(z)$ ，单位冲击响应 $l_i[n]$

对应的第II类压缩比例因子： $\beta_i = C \cdot \sqrt{\frac{1}{2\pi} \int_{-\pi}^{\pi} |L_i(e^{j\omega})|^2 d\omega} = C \cdot \|l_i[n]\|_2$


3. 计算溢出及其避免

• 3.3 压缩因子的加入


假设系统共有 I 个加法结点，所有加法结点对应的压缩比例因子集合为

$$\{\beta_1, \beta_2, \dots, \beta_I\}$$


• 方式一：集中式



在系统输入端统一进行最“保险”的比例压缩，在输出端统一补回。



$$\beta_{\max} = \max\{\beta_1, \beta_2, \dots, \beta_I\}$$



- 优点：简单
- 问题：计算过程中信号所占有有效位数较少，信噪比衰减。

3. 计算溢出及其避免


• 3.3 压缩因子的加入

输出量化噪声功率:

- 输出端乘 β_{max} , 增加了一个噪声源
- 传输函数变为原来的 β_{max} 倍
- 输入乘以 $1/\beta$ 将成为一个噪声源

$$\sigma_f^2 = \frac{2^{-2B}}{12} \left[\beta_{max}^2 \sum_{i=1}^I \sum_{n=-\infty}^{\infty} |g_i[n]|^2 + 1 \right]$$

• 方式二：分布式



- 进入节点 w_i 前, 加入对应的压缩因子 $\frac{1}{\beta_i}$
- 离开节点 w_i 后, 乘以 β_i

输出量化噪声功率:


- 各结点传输函数变为原来的 β_i 倍

$$\sigma_f^2 = \frac{2^{-2B}}{12} \left[\sum_{i=1}^I \sum_{n=-\infty}^{\infty} \beta_i^2 |g_i[n]|^2 + 1 \right]$$

3. 计算溢出及其避免

• 3.3 压缩因子的加入

- 例：IIR系统的压缩比例因子与量化噪声功率。



$$x[n] \text{到节点A输出端的系统函数: } L_1(z) = \frac{1}{1 - 0.81z^{-2}} = \frac{0.5}{(1 - 0.9z^{-1})} + \frac{0.5}{(1 + 0.9z^{-1})}$$

$$\text{单位冲击响应: } l_1[n] = \frac{1}{2} 0.9^n u[n] + \frac{1}{2} (-0.9)^n u[n]$$

$$\text{第II类比例压缩因子}(C = 5): \beta_1 = C \cdot \|l_1[n]\|_2 \approx 8.53$$

$$x[n] \text{到节点C输出端的单位冲击响应: } l_2[n] = h[n] = \frac{1}{18} 0.9^n u[n] + \frac{17}{18} (-0.9)^n u[n]$$


$$\|l_2[n]\|_2 = \sqrt{4.769} = 2.184$$

$$\text{第II类比例压缩因子}(C = 5): \beta_2 = C \cdot \|l_2[n]\|_2 \approx 10.92$$

3. 计算溢出及其避免

• 3.3 压缩因子的加入

分布式比例因子加入后



未加入比例压缩因子时，输出噪声： $\sigma_f^2 = \frac{2^{-2B}}{12} \left[\sum_{n=-\infty}^{\infty} |h[n]|^2 + 1 \right] = 0.48 \times 2^{-2B}$


加入比例压缩因子后，输出噪声：

$$\sigma_f^2 = \frac{2^{-2B}}{12} \left[2\beta_1^2 \sum_{n=-\infty}^{\infty} |h[n]|^2 + 2\beta_2^2 + 1 \right] = 77.8 \times 2^{-2B}$$

节点A输入 节点C输入 节点C输出

4. 系数量化误差对滤波器响应的影响

- 4.1 对极点位置的影响
 - 量化会影响零极点位置
 - 极点位置变化对系统性能影响较大



滤波器系统函数
$$H(z) = \frac{\sum_{r=0}^M b_r z^{-r}}{1 + \sum_{k=1}^N a_k z^{-k}}$$

系数量化误差
$$\begin{cases} \hat{a}_k = Q\{a_k\} = a_k + \Delta a_k \\ \hat{b}_r = Q\{b_r\} = b_r + \Delta b_r \end{cases}$$

实际计算的是
$$\hat{H}(z) = \frac{\sum_{r=0}^M \hat{b}_r z^{-r}}{1 + \sum_{k=1}^N \hat{a}_k z^{-k}}$$

评估 Δa_k 、 Δb_r 对极点位置的影响

第 j 个极点全微分：
$$\Delta p_j = \sum_{k=1}^N \frac{\partial p_j}{\partial a_k} \Delta a_k$$

4. 系数量化误差对滤波器响应的影响

• 4.1 对极点位置的影响

求灵敏度： $\frac{\partial p_j}{\partial a_k}$

假设只有一阶极点，则 $H(z)$ 的分母可写做

$$A(z) = 1 + \sum_{k=1}^N a_k z^{-k} = \prod_{k=1}^N (1 - p_k z^{-1})$$

两边求导

$$\left. \frac{\partial A(z)}{\partial a_k} \right|_{z=p_j} = \left. \frac{\partial A(z)}{\partial p_j} \right|_{z=p_j} \cdot \frac{\partial p_j}{\partial a_k}$$

那么

$$\frac{\partial p_j}{\partial a_k} = \left[\left. \frac{\partial A(z)}{\partial a_k} \right|_{z=p_j} \right] / \left[\left. \frac{\partial A(z)}{\partial p_j} \right|_{z=p_j} \right]$$

其中，

$$\left. \frac{\partial A(z)}{\partial a_k} \right|_{z=p_j} = p_j^{-k}$$
$$\left. \frac{\partial A(z)}{\partial p_j} \right|_{z=p_j} = -p_j^{-1} \prod_{\substack{k=1 \\ k \neq j}}^N (1 - p_k p_j^{-1}) = -p_j^{-N} \prod_{\substack{k=1 \\ k \neq j}}^N (p_j - p_k)$$


4. 系数量化误差对滤波器响应的影响

• 4.1 对极点位置的影响

$$\frac{\partial p_j}{\partial a_k} = - \frac{p_j^{N-k}}{\prod_{\substack{k=1 \\ k \neq j}}^N (p_j - p_k)}$$

极点 p_j 的偏移量
$$\Delta p_j = - \sum_{k=1}^N \frac{p_j^{N-k}}{\prod_{\substack{k=1 \\ k \neq j}}^N (p_j - p_k)} \Delta a_k, \quad j = 1, 2, \dots, N$$

- 极点紧密，则对系数量化误差灵敏度高
- 极点稀疏，则对系数量化误差灵敏度低
- 高阶滤波器，系数量化误差灵敏度高
- 低阶滤波器，系数量化误差灵敏度低
- 极点离实轴越近(低、高通滤波器)
 - 系数量化误差灵敏度高
- 极点离实轴越远（带通滤波器）
 - 系数量化误差灵敏度低



4. 系数量化误差对滤波器响应的影响

• 4.1 对极点位置的影响

例：滤波器系统函数 $H(z) = \frac{0.0373}{1-1.7z^{-1}+0.745z^{-2}} = \frac{0.0373}{1-a_1z^{-1}-a_2z^{-2}}$

若要使对系数 a_2 的量化引起极点的位置变化不超过 0.5%，试确定最小的系数量化位数。

系统极点位置： $p_{1,2} = 0.836e^{\pm j170^\circ}$

极点的全微分：

极点对 a_2 的灵敏度为

$$\begin{cases} \Delta p_1 = \frac{p_1^{2-1}}{p_2 - p_1} \Delta a_1 + \frac{p_1^{2-2}}{p_1 - p_2} \Delta a_2 \\ \Delta p_2 = \frac{p_2^{2-1}}{p_2 - p_1} \Delta a_1 + \frac{p_2^{2-2}}{p_2 - p_1} \Delta a_2 \end{cases}$$
$$\begin{cases} \frac{\partial p_1}{\partial a_2} = \frac{1}{p_1 - p_2} = \frac{-j}{0.3} \\ \frac{\partial p_2}{\partial a_2} = \frac{1}{p_2 - p_1} = \frac{j}{0.3} \end{cases}$$

仅考虑 a_2 引起的极点变化 $|\Delta p_1| = |\Delta p_2| = \left| \frac{\partial p_2}{\partial a_2} \right| \Delta a_2 = 0.836 \times 0.5\%$

$$\Delta a_2 = \frac{0.836 \times 0.5\%}{10/3} = 1.3 \times 10^{-3}$$

向上取整！

系数量化位数 B

$$\frac{1}{2} \times 2^{-B} = 1.3 \times 10^{-3}$$

$B = 8.6 \approx 9\text{bit}$

4. 系数量化误差对滤波器响应的影响

• 4.2 不同实现结构对系数量化的不同敏感性

假设实系数二阶IIR滤波器

$$H(z) = \frac{1}{1 - 2r \cos \theta z^{-1} + r^2 z^{-2}}$$

共轭极点为 $p_{1,2} = r \cdot e^{\pm j\theta}$


若直接对系数进行量化（B+1位），则半径 r 和实部 $r\cos\theta$ 应该分别在满足 r^2 和 $r\cos\theta$ 均在 2^{-B} 格点上的要求。例如，若 $B = 3$

二进制 量化值	0.000	0.001	0.010	0.011	0.100	0.101	0.110	0.111
$ r\cos\theta $	0.0	0.125	0.250	0.375	0.5	0.625	0.75	0.875
$r = \sqrt{r^2}$	0.0	0.345	0.5	0.612	0.707	0.791	0.866	0.935

r^2 在格点上



4. 系数量化误差对滤波器响应的影响

• 4.2 不同实现结构对系数量化的不同敏感性




r^2 在格点上

可能的零极点位置



系数为
 $r \cdot \sin \theta, r \cdot \cos \theta$



系数量化引起的几点偏移较小

5. DFT/FFT计算中的有限字长效应

- 5.1 DFT的量化误差
 - 舍入误差

$$X[k] = \sum_{n=0}^{N-1} x[n] W_N^{nk}, k = 0, 1, \dots, N-1$$

一次复数乘法 $\Rightarrow$ 四次实数乘法  复乘舍入误差: $\sigma_B^2 = 4\sigma_e^2 = \frac{1}{3} \times 2^{-2B}$

每个 $X[k]$ 需要 $N(N = 2^m)$ 次复乘, 则结果中的舍入噪声方差为

$$\sigma_k^2 = N\sigma_B^2 = \frac{2^{m-2B}}{3}$$

DFT点数增加4倍, 位数B增加1位, 则误差不变

- 溢出


$$|X[k]| = \left| \sum_{n=0}^{N-1} x[n] W_N^{nk} \right| \leq \sum_{n=0}^{N-1} |x[n]| \leq 1$$

压缩因子 $\beta = N$ 。当点数较多时, 动态范围/输出信噪比降低严重。


5. DFT/FFT计算中的有限字长效应

- 5.2 定点FFT量化误差
 - 舍入误差


蝶形图



一个 $X[k]$ 的“诞生”



蝶形计算单元的误差模型



量化
误差

$$\begin{cases} \hat{X}_m[p] = X_{m-1}[p] + X_{m-1}[q]W_N^r + e[m, p] \\ \hat{X}_m[q] = X_{m-1}[p] - X_{m-1}[q]W_N^r + e[m, q] \end{cases}$$

$$\text{每次蝶形产生的误差为 } \sigma_B^2 = \frac{2^{-2B}}{3}$$


一共要经历 $1 + 2 + \dots + \frac{N}{2} = N - 1$ 蝶形运算
误差源到输出的增益为1，则输出误差

$$\sigma_{f[k]}^2 = (N - 1)\sigma_B^2 \approx N\sigma_B^2 = \frac{N}{3} \times 2^{-2B}$$

5. DFT/FFT计算中的有限字长效应


• 5.2 定点FFT量化误差

• 溢出



蝶形运算的放大倍数不超过2

压缩因子分布式逐级加入 $\beta = 2$



最后统一放大

每次乘以1/2需要2次实数乘法, 引入量化噪声 $2\sigma_e^2 = \frac{1}{6} \times 2^{-2B}$

每个蝶形的总量化噪声

$$\sigma_{BI}^2 = 2\sigma_e^2 + 4\sigma_e^2 = \frac{1}{2} \times 2^{-2B}$$

压缩因子

旋转因子

用移位实现

加入压缩因子 $\beta = 2$ 后, 前级噪声到后级方差衰减为1/4:

总误差:

$$\sigma_{f[k]}^2 = \sigma_{BI}^2 + \left(\frac{1}{4} \times 2\right) \sigma_{BI}^2 + \left(\frac{1}{4} \times 2\right)^2 \sigma_{BI}^2 + \dots + \left(\frac{1}{4} \times 2\right)^{m-1} \sigma_{BI}^2$$

$$\approx 2\sigma_{BI}^2 = 2^{-2B}$$

与点数无关

小结

- 关键点：
 - 乘法有误差
 - 加法会溢出
 - 噪声独立算
 - 响应要仔细
- 对应教材：《张》书Ch10, 《O》书6.7-6.10
- 作业：《张》2nd :10.1, 10.2, 10.4, 10.6, 10.11
- 下节预告：多采样率处理, 《张》8.1-8.4, 8.6