

§ 3 奇异值分解

学习目标(部分关键词)

什么是矩阵的奇异值分解(SVD分解)?

如何求矩阵的奇异值分解(SVD分解)?

SVD分解的几何意义.

SVD分解的应用: 图像压缩.

3.1 引言

- 对角阵是我们最喜爱的一类矩阵.
- n 阶矩阵 A 相似于对角阵 $\Leftrightarrow A$ 存在 n 个线性无关的特征向量.
- 实对称矩阵 必能 正交相似于对角阵

3.1 引言

问题:如何“对角化” $m \times n$ 矩阵?

3.2 奇异值分解(Singular Value Decomposition)

设A是一个 $m \times n$ 矩阵, 则存在m阶正交矩阵U和n阶正交矩阵V, 满足

$$A = U \begin{pmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_r & \\ & & & 0 \end{pmatrix}_{m \times n} V^T =: U \Sigma V^T,$$

其中 $r = \text{rank}(A)$. 习惯上, 取 $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$. 称 $\sigma_1, \cdots, \sigma_r$ 为奇异值(singular value). 称U和V的前r列向量为奇异向量(singular vector). 这个分解称为奇异值分解, 简称**SVD**.(参看中文书, 下, P62)

3.2 奇异值分解

$$A = U\Sigma V^T, \quad \Sigma = \begin{pmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_r & \\ & & & 0 \end{pmatrix}$$

$$\text{令 } U = (\mathbf{u}_1, \cdots, \mathbf{u}_r, \mathbf{u}_{r+1}, \cdots, \mathbf{u}_m), \quad V = (\mathbf{v}_1, \cdots, \mathbf{v}_r, \mathbf{v}_{r+1}, \cdots, \mathbf{v}_n).$$

$$\begin{aligned} \text{SVD分解} \Rightarrow & \begin{cases} A\mathbf{v}_i = \sigma_i \mathbf{u}_i, \\ A^T \mathbf{u}_i = \sigma_i \mathbf{v}_i, \end{cases} & (i = 1, \cdots, r) \\ & \begin{cases} A\mathbf{v}_j = \mathbf{0} \quad (j = r+1, \cdots, n), \\ A^T \mathbf{u}_k = \mathbf{0} \quad (k = r+1, \cdots, m). \end{cases} \end{aligned}$$

$$\Rightarrow \quad A^T A \mathbf{v}_i = \sigma_i^2 \mathbf{v}_i, \quad A A^T \mathbf{u}_i = \sigma_i^2 \mathbf{u}_i \quad (1 \leq i \leq r).$$

$m \times n$ 阶实矩阵 A 的奇异值分解

设 A 是秩为 r 的 $m \times n$ 实矩阵, 则 AA^T 为 m 阶实对称矩阵, $A^T A$ 为 n 阶实对称矩阵.

(1) AA^T 与 $A^T A$ 的特征值为非负数.

证明: 设 $A^T A \mathbf{x} = \lambda \mathbf{x} (\mathbf{x} \neq \mathbf{0})$, 则 $\mathbf{x}^T A^T A \mathbf{x} = \lambda \mathbf{x}^T \mathbf{x}$, 即

$$\|A\mathbf{x}\|^2 = \lambda \|\mathbf{x}\|^2,$$

故 $\lambda \geq 0$. 同理 AA^T 的特征值也全是非负数.

$m \times n$ 阶实矩阵 A 的奇异值分解

(2) AA^T 与 $A^T A$ 的非零特征值集合相同.

证明: 因为 $r(AA^T) = r(A^T A) = r(A) = r$, 故

$(\{A^T A \text{ 的非零特征值}\} \text{ 的个数}) = r = (\{AA^T \text{ 的非零特征值}\} \text{ 的个数})$

设 λ 是 $A^T A$ 的非零特征值. 即 $\exists \mathbf{x} \neq \mathbf{0}$, 使得 $A^T A \mathbf{x} = \lambda \mathbf{x}$, 且 $A \mathbf{x} \neq \mathbf{0}$.

则有 $AA^T A \mathbf{x} = \lambda A \mathbf{x}$. 故 λ 也是 AA^T 的非零特征值. 反之亦然.

因此, AA^T 与 $A^T A$ 具有相同的非零特征值.

m x n 阶实矩阵A的奇异值分解

不妨设 AA^T 和 $A^T A$ 的这r个非零特征值为 $\sigma_1^2 \geq \cdots \geq \sigma_r^2 > 0$, 其中 $\sigma_i > 0$.

(3) 设 $\mathbf{v}_1, \cdots, \mathbf{v}_n \in \mathbb{R}^n$ 为n阶实对称方阵 $A^T A$ 的单位正交特征向量,

$$A^T A(\mathbf{v}_1 \cdots \mathbf{v}_n) = (\mathbf{v}_1 \cdots \mathbf{v}_n) \begin{pmatrix} \sigma_1^2 & & & \\ & \ddots & & \\ & & \sigma_r^2 & \\ & & & 0 \end{pmatrix}.$$

记 $V = (\mathbf{v}_1, \cdots, \mathbf{v}_n)$, 则 $V^T V = I_n$.

m x n阶阵A的SVD分解

$$A = U\Sigma V^T, \quad \Sigma = \begin{pmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_r & \\ & & & 0 \end{pmatrix}$$

注意到 $A^T A \mathbf{v}_i = \sigma_i^2 \mathbf{v}_i$, $\|\mathbf{v}_i\| = 1$, $(1 \leq i \leq r)$.

故 $\mathbf{v}_i^T A^T A \mathbf{v}_i = \sigma_i^2 \mathbf{v}_i^T \mathbf{v}_i$, 即 $\|A \mathbf{v}_i\|^2 = \sigma_i^2$.

令 $\mathbf{u}_i := \frac{A \mathbf{v}_i}{\sigma_i} \in \mathbb{R}^m (1 \leq i \leq r)$, 则 $AA^T \mathbf{u}_i = \sigma_i^2 \mathbf{u}_i$, 并且

$$\mathbf{u}_i^T \mathbf{u}_j = \frac{(A \mathbf{v}_i)^T}{\sigma_i} \frac{A \mathbf{v}_j}{\sigma_j} = \frac{\mathbf{v}_i^T (A^T A \mathbf{v}_j)}{\sigma_i \sigma_j} = \frac{\sigma_j^2 \mathbf{v}_i^T \mathbf{v}_j}{\sigma_i \sigma_j} = \begin{cases} 0, & i \neq j, \\ 1, & i = j. \end{cases}$$

故 $\{\mathbf{u}_i \mid 1 \leq i \leq r\}$ 是 AA^T 的单位正交特征向量.

m x n阶阵A的SVD分解

$$A = U\Sigma V^T, \quad \Sigma = \begin{pmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_r & \\ & & & 0 \end{pmatrix}$$

又

$$A\mathbf{v}_i = \sigma_i\mathbf{u}_i, \quad A^T\mathbf{u}_i = \sigma_i\mathbf{v}_i, \quad 1 \leq i \leq r = \text{rank}(A).$$

故

$\{\mathbf{u}_1, \cdots, \mathbf{u}_r\}$ 为 $C(A)$ 的一组单位正交基;

$\{\mathbf{v}_1, \cdots, \mathbf{v}_r\}$ 为 $C(A^T)$ 的一组单位正交基.

m x n阶阵A的SVD分解

$$A(\mathbf{v}_1 \cdots \mathbf{v}_r) = (\mathbf{u}_1 \cdots \mathbf{u}_r) \begin{pmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{pmatrix}$$

记为 $A_{m \times n} V_{n \times r} = U_{m \times r} \Sigma_{r \times r}$.

由 $\mathbb{R}^n = C(A^T) + N(A)$, $C(A^T) \perp N(A)$, $\mathbb{R}^m = C(A) + N(A^T)$, $C(A) \perp N(A^T)$,
扩充 $\{\mathbf{v}_1, \cdots, \mathbf{v}_r\}$ 为 $\mathbb{R}^n$ 的一组单位正交基 $\{\mathbf{v}_1, \cdots, \mathbf{v}_r, \mathbf{v}_{r+1}, \cdots, \mathbf{v}_n\}$,
扩充 $\{\mathbf{u}_1, \cdots, \mathbf{u}_r\}$ 为 $\mathbb{R}^m$ 的一组单位正交基 $\{\mathbf{u}_1, \cdots, \mathbf{u}_r, \mathbf{u}_{r+1}, \cdots, \mathbf{u}_m\}$.

$m \times n$ 阶阵A的SVD分解

$$\Rightarrow A(\mathbf{v}_1 \cdots \mathbf{v}_r \mathbf{v}_{r+1} \cdots \mathbf{v}_n) = (\mathbf{u}_1 \cdots \mathbf{u}_r \mathbf{u}_{r+1} \cdots \mathbf{u}_m) \begin{pmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_r & \\ & & & 0 \end{pmatrix}_{m \times n}$$

记为 $A_{m \times n} V_{n \times n} = U_{m \times m} \Sigma_{m \times n}$, 其中 $V^T V = I_n$, $U^T U = I_m$.

$$\Rightarrow A = U \Sigma V^T, \quad (SVD)$$
$$A = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \cdots + \sigma_r \mathbf{u}_r \mathbf{v}_r^T.$$

3.3 例题

例: 求矩阵 $A = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & -1 \end{pmatrix}$ 的奇异值分解.

解:

因 $A^T A = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & -1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & -1 \end{pmatrix} = \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix},$

故 $A^T A$ 的特征多项式为

$$|\lambda I - A^T A| = \begin{vmatrix} \lambda - 2 & 1 \\ 1 & \lambda - 2 \end{vmatrix} = (\lambda - 1)(\lambda - 3).$$

3.3 例题

$$A = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & -1 \end{pmatrix}$$

因此 $A^T A$ 的特征值为 $\sigma_1^2 = 3, \sigma_2^2 = 1$. 它们相应的单位特征向量分别为

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix}, \quad \mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

AA^T 的三个特征值分别为 $\sigma_1^2 = 3, \sigma_2^2 = 1, 0$, 且属于它们的单位特征向量分别为

$$\mathbf{u}_1 = \frac{1}{\sigma_1} A \mathbf{v}_1 = \frac{1}{\sqrt{6}} \begin{pmatrix} 1 \\ -1 \\ 2 \end{pmatrix}, \quad \mathbf{u}_2 = \frac{1}{\sigma_2} A \mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}, \quad \mathbf{u}_3 = \frac{1}{\sqrt{3}} \begin{pmatrix} 1 \\ -1 \\ -1 \end{pmatrix}.$$

3.3 例题

$$A = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & -1 \end{pmatrix}$$

$$\text{令 } V = (\mathbf{v}_1 \ \mathbf{v}_2), \quad U = (\mathbf{u}_1 \ \mathbf{u}_2, \mathbf{u}_3), \quad \Sigma = \begin{pmatrix} \sqrt{3} & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix},$$

$$\text{则 } A = U\Sigma V^T = \begin{pmatrix} \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \\ -\frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{3}} \\ \frac{2}{\sqrt{6}} & 0 & -\frac{1}{\sqrt{3}} \end{pmatrix} \begin{pmatrix} \sqrt{3} & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix}^T.$$

3.3 例题

例 (奇异值分解的几何意义):

设 $A = \begin{pmatrix} 3 & -4 \\ 5 & 0 \end{pmatrix}$, 则线性变换 $\mathbf{x} \mapsto A\mathbf{x}$ 把 $\mathbb{R}^2$ 中的单位圆周

$S^1 = \{(x, y) \in \mathbb{R}^2 \mid x^2 + y^2 = 1\}$ 映成 $\mathbb{R}^2$ 中的一个椭圆.

事实上, 由于 $A^T A = \begin{pmatrix} 34 & -12 \\ -12 & 16 \end{pmatrix}$ 的特征值为 $\sigma_1^2 = 40, \sigma_2^2 = 10$,

它们相应的单位特征向量分别为 $\mathbf{v}_1 = \frac{1}{\sqrt{5}} \begin{pmatrix} 2 \\ -1 \end{pmatrix}, \quad \mathbf{v}_2 = \frac{1}{\sqrt{5}} \begin{pmatrix} 1 \\ 2 \end{pmatrix}.$

3.3 例题

$$A = \begin{pmatrix} 3 & -4 \\ 5 & 0 \end{pmatrix}, \quad \mathbf{v}_1 = \frac{1}{\sqrt{5}} \begin{pmatrix} 2 \\ -1 \end{pmatrix}, \quad \mathbf{v}_2 = \frac{1}{\sqrt{5}} \begin{pmatrix} 1 \\ 2 \end{pmatrix},$$

AA^T 的特征值也为 $\sigma_1^2 = 40, \sigma_2^2 = 10$, 且属于它们的单位特征向量分别为

$$\mathbf{u}_1 = \frac{1}{\sigma_1} A \mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad \mathbf{u}_2 = \frac{1}{\sigma_2} A \mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} -1 \\ 1 \end{pmatrix}.$$

$$\text{令 } V = (\mathbf{v}_1 \ \mathbf{v}_2), \quad U = (\mathbf{u}_1 \ \mathbf{u}_2), \quad \Sigma = \begin{pmatrix} \sigma_1 & \\ & \sigma_2 \end{pmatrix} = \begin{pmatrix} 2\sqrt{10} & \\ & \sqrt{10} \end{pmatrix},$$


则A的奇异值分解为

$$A = U \Sigma V^T = \begin{pmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix} \begin{pmatrix} 2\sqrt{10} & \\ & \sqrt{10} \end{pmatrix} \begin{pmatrix} \frac{2}{\sqrt{5}} & -\frac{1}{\sqrt{5}} \\ \frac{1}{\sqrt{5}} & \frac{2}{\sqrt{5}} \end{pmatrix}.$$

3.3 例题

$$A = \begin{pmatrix} 3 & -4 \\ 5 & 0 \end{pmatrix} = U\Sigma V^T = (\mathbf{u}_1, \mathbf{u}_2) \begin{pmatrix} \sigma_1 & 0 \\ 0 & \sigma_2 \end{pmatrix} (\mathbf{v}_1, \mathbf{v}_2)^T,$$

矩阵A在单位圆周 S^1 上的作用可被分解成三步:



3.3 例题

注: 一般地, 设秩为 r 的 $m \times n$ 矩阵 A 有SVD: $A_{m \times n} = U\Sigma V^T$, 则从 $\mathbb{R}^n$ 到 $\mathbb{R}^m$ 的线性变换 $\mathbf{x} \mapsto A\mathbf{x}$ 可看成是以下三步的复合:

① $\mathbb{R}^n$ 中的旋转 $\mathbf{x} \mapsto V^T \mathbf{x}$,

② $\mathbb{R}^n$ 中的向量 $V^T \mathbf{x}$ 的前 r 个分量做伸缩, 其余分量变为0:

$$V^T \mathbf{x} \mapsto \Sigma V^T \mathbf{x},$$

③ 再在 $\mathbb{R}^m$ 中做旋转 $\Sigma V^T \mathbf{x} \mapsto U\Sigma V^T \mathbf{x}$.

$m \times n$ 阶阵 A 的伪逆 (pseudoinverse)

设 $m \times n$ 实矩阵 A 有SVD分解: $A = U\Sigma V^T$. (SVD)

其中 U, V 分别为 m 阶, n 阶正交阵; Σ 为 $m \times n$ 矩阵,

前 $r = r(A)$ 个“对角元”为 A 的奇异值 $\sigma_1 \geq \cdots \geq \sigma_r > 0$.

即:

$$A = U \begin{pmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_r & \\ & & & 0 \end{pmatrix}_{m \times n} V^T,$$

定义: A 的伪逆(pseudoinverse)为

$$A^+ = V \begin{pmatrix} \sigma_1^{-1} & & & \\ & \ddots & & \\ & & \sigma_r^{-1} & \\ & & & 0 \end{pmatrix}_{n \times m} U^T,$$

可以证明: $Ax = b$ 的长度最短的最小二乘解是 A^+b . (参见中文书, 下, P69)

3.4 奇异值分解的应用

(1) SVD与矩阵的四个基本子空间:

设 $A = U\Sigma V^T$ 是 $m \times n$ 实矩阵 A 的奇异值分解, $r = r(A)$, 则

- ◆ 正交矩阵 U 的前 r 列是 $C(A)$ 的一组标准正交基;
- ◆ 正交矩阵 U 的后 $m-r$ 列是 $N(A^T)$ 的一组标准正交基;
- ◆ 正交矩阵 V 的前 r 列是 $C(A^T)$ 的一组标准正交基;
- ◆ 正交矩阵 V 的后 $n-r$ 列是 $N(A)$ 的一组标准正交基.

3.4 奇异值分解的应用

(2) SVD与图像压缩:

设秩 r 的 $m \times n$ 矩阵 A 的奇异值分解为

$$A = U\Sigma V^T = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \cdots + \sigma_r \mathbf{u}_r \mathbf{v}_r^T,$$

其中 $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$.

令 $A_k = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \cdots + \sigma_k \mathbf{u}_k \mathbf{v}_k^T$ ($1 \leq k < r$),

称为 A 的 k 阶逼近. 特别地, $k = 1$ 时, A_1 是 1 阶逼近.

3.4 奇异值分解的应用

例：一幅规格是 $m \times n$ 像素的照片可用一个 $m \times n$ 矩阵来储存。利用矩阵的奇异值分解，只需存储矩阵的奇异值 σ_i ，奇异向量 $\mathbf{u}_i, \mathbf{v}_i$ 的分量，总计 $r \cdot (m + n + 1)$ 个数据，而不是原始的 $m \cdot n$ 个数据。通常 $r \ll m, r \ll n$ ，则 $r \cdot (m + n + 1) \ll m \cdot n$ 。

比值 $\frac{m \cdot n}{r \cdot (m + n + 1)}$ 称为图像的压缩比 (其倒数称为数据压缩率)。

若 $\sigma_1, \dots, \sigma_k$ 远大于 $\sigma_{k+1}, \dots, \sigma_r$ ，则 $A_k \approx A$ ，图像失真小且压缩了存储量。

3.4 奇异值分解的应用



(1)



(2)



(3)

(1) 原图, 像素(512 x 512); (2) 用前10个特征值重构, 压缩比25.6;
(3) 用前80个特征值重构, 压缩比3.2;

<http://www.cnblogs.com/tiandsp/archive/2012/10/24/2737769.html>

<http://blog.csdn.net/bluecol/article/details/45971423>

3.4 奇异值分解的应用

(3) SVD与特征值:

命题: 设 $|\lambda|_{\max}$ 是矩阵 $A = (a_{ij})_{m \times n}$ 特征值的模长的最大值, 则

$$\sigma_1 \geq |\lambda|_{\max}, \quad \sigma_1 \geq |a_{ij}|, \quad \forall i, j.$$

证明: 设A有奇异值分解 $A = U\Sigma V^T$, 则对任意向量 $\mathbf{x}$, 有

$$\|A\mathbf{x}\| = \|U\Sigma V^T \mathbf{x}\| = \|\Sigma V^T \mathbf{x}\| \leq \sigma_1 \|V^T \mathbf{x}\| = \sigma_1 \|\mathbf{x}\|.$$

$$A = (a_{ij})_{m \times n}$$

3.4 奇异值分解的应用

$$\|A\mathbf{x}\| = \|U\Sigma V^T \mathbf{x}\| = \|\Sigma V^T \mathbf{x}\| \leq \sigma_1 \|V^T \mathbf{x}\| = \sigma_1 \|\mathbf{x}\|.$$

若 $A\mathbf{x} = \lambda\mathbf{x}$, $\|\mathbf{x}\| \neq 0$,

则 $\|A\mathbf{x}\| = |\lambda| \cdot \|\mathbf{x}\|$, 故 $\sigma_1 \geq |\lambda|$, 特别有 $\sigma_1 \geq |\lambda|_{\max}$.

又若取 $\mathbf{x} = (1, 0, \dots, 0)$, 则 $A\mathbf{x}$ 表示 A 的第一列向量, 且 $\|A\mathbf{x}\| \leq \sigma_1 \|\mathbf{x}\| = \sigma_1$, 而

$$|a_{i1}| \leq \sqrt{a_{11}^2 + \dots + a_{n1}^2} \leq \sigma_1.$$

同理, $|a_{ij}| \leq \sigma_1$.

3.4 奇异值分解的应用

注：矩阵的奇异值较之其特征值的一个优点是 非零奇异值的个数恰好是矩阵的秩，而矩阵的非零特征值的个数一般比其秩小（如幂零矩阵无非零特征值），故常以此来计算矩阵的秩.